

Autora: Mireia Consarnau Pallarés.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Preprocesamiento de datos. Preparando la base del aprendizaje automático.....	1
Introducción.....	1
Lección 1. Importancia del preprocesamiento calidad y consistencia de los datos.....	1
Por qué es importante la calidad de los datos para cualquier proyecto de aprendizaje automático.....	2
Qué implica la consistencia en un conjunto de datos y cómo influye en la construcción de modelos.....	2
Cómo un preprocesamiento adecuado mejora la precisión y evita errores o sesgos (desviaciones que pueden alterar los resultados).....	3
Cómo trabajar de forma estructurada con los datos antes de usar técnicas más avanzadas.....	3
Qué herramientas ayudan en el preprocesamiento de los datos.....	4
Lección 2. Limpieza de datos detección y tratamiento de valores nulos duplicados y errores.....	6
Por qué es importante la limpieza de datos para garantizar la fiabilidad de los modelos..	6
Qué son los valores nulos y cómo afectan a la calidad de los datos.....	6
Cómo identificar y tratar los datos duplicados para evitar sesgos y resultados poco fiables.....	7
Cómo detectar y corregir errores en los datos para mejorar su consistencia y precisión..	7
Qué herramientas permiten realizar estas tareas de limpieza de forma eficiente y segura.	7
Lección 3. Visualización exploratoria distribuciones correlaciones y detección de problemas.....	9
Por qué es importante la visualización para entender los datos antes de entrenar modelos.....	9
Qué muestran las distribuciones y cómo ayudan a detectar patrones.....	9
Tipos principales de distribuciones que podemos encontrar.....	9
Importancia del tipo de distribución y cómo actuar según cada caso.....	12
Valores atípicos (outliers).....	12
¿Dónde se pueden detectar los valores atípicos?.....	13
¿Qué es un boxplot y cómo ayuda?.....	13
¿Por qué es importante detectar y tratar valores atípicos?.....	14
¿Qué hacer al detectar valores atípicos?.....	14
Relaciones entre variables y su impacto en el modelo.....	15
Qué es la correlación y su importancia.....	15
Cómo se calcula y qué significa su valor.....	16
Tipos de correlación y cómo influyen en el análisis.....	16
Correlación de las características con el objetivo y su utilidad.....	20
Cómo detectar problemas en los datos mediante gráficos y análisis visuales.....	21
Valores faltantes y su impacto.....	21
Desequilibrio de clases en la variable objetivo.....	22
Desequilibrio de clases en las características.....	23
Lección 4. Transformación de datos normalización codificación y escalado.....	25

Por qué es importante transformar los datos antes de entrenar modelos de aprendizaje automático.....	25
Transformaciones logarítmicas y de potencia.....	25
Qué significa normalizar los datos y cómo mejora la comparabilidad entre variables.....	26
Qué implica estandarizar y escalar los datos y cómo ayuda a mejorar la eficiencia y estabilidad de los modelos.....	26
Por qué es necesario codificar las variables categóricas para que los algoritmos puedan usarlas correctamente.....	27
Cómo usar pipelines para encadenar limpieza codificación y escalado de forma reproducible.....	28
Cómo aplicar la secuencia de transformación de datos.....	29

Lección 5. Selección y reducción de características filtrado PCA y técnicas avanzadas

30

Por qué es importante seleccionar las características más relevantes en un conjunto de datos.....	30
Qué es el filtrado y cómo ayuda a identificar las variables que aportan valor al modelo.	30
Cómo funciona el Análisis de Componentes Principales y qué aporta a la reducción de características.....	31
Qué técnicas avanzadas ayudan a simplificar los datos sin perder información esencial...	32

Preprocesamiento de datos. Preparando la base del aprendizaje automático

Introducción

El preprocesamiento de datos es un paso esencial antes de cualquier análisis o modelado. No basta con tener muchos datos, es necesario revisarlos, limpiarlos y transformarlos para que los modelos puedan aprender de ellos de forma eficiente y sin sesgos (desviaciones que pueden alterar los resultados o la interpretación). Esta unidad explica cómo convertir datos en bruto en una base sólida y coherente, lo que mejora la calidad de los resultados y reduce el riesgo de que los modelos aprendan patrones incorrectos o irrelevantes.

Cada paso, desde la limpieza de valores nulos o duplicados hasta la selección de las variables más importantes, forma parte de un proceso que define el éxito o el fracaso de un proyecto de aprendizaje automático. Este proceso no es solo cuestión de técnicas automáticas, también implica comprender cómo los datos pueden influir en los resultados y cómo trabajarlos de forma estructurada para garantizar modelos fiables y precisos.

Lección 1. Importancia del preprocesamiento calidad y consistencia de los datos

Por qué es importante la calidad de los datos para cualquier proyecto de aprendizaje automático

La calidad de los datos es clave porque los modelos de aprendizaje automático aprenden a partir de la información que reciben. Si los datos están mal organizados o contienen errores, el modelo aprenderá cosas incorrectas, lo que puede hacer que las predicciones sean poco precisas o muy alejadas de la realidad. Por ejemplo, si hay muchos errores o valores faltantes, el modelo no podrá detectar patrones reales y fiables.

Tener datos de calidad significa que estén completos (sin huecos), bien organizados y representen lo que realmente queremos analizar. Si los datos no reflejan correctamente la situación real, el modelo fallará. Además, datos bien preparados aceleran el proceso de entrenamiento y mejoran la eficiencia del modelo.

Antes de aplicar técnicas avanzadas, es fundamental asegurarse de que los datos están en buen estado. Esto evita resultados erróneos y mejora la precisión del modelo.

Imagina que quieres entrenar un modelo para predecir el precio de las casas. Si los datos contienen errores —como direcciones mal escritas, precios faltantes o registros duplicados—, el modelo no aprenderá bien. Podría predecir que una casa pequeña vale más que una grande o dar valores totalmente fuera de lugar, porque solo aprende de los datos que tiene. Si esos datos no son correctos, el modelo no acertará.

Otro ejemplo: si trabajas con un sistema para predecir la demanda de un producto según la estación del año y tus datos no incluyen todas las estaciones o están incompletos, las predicciones pueden ser muy erróneas.

Estos casos muestran cómo datos de mala calidad llevan a modelos poco fiables. Por eso es tan importante revisar y corregir los datos.

Qué implica la consistencia en un conjunto de datos y cómo influye en la construcción de modelos

La consistencia significa que toda la información está alineada y no se contradice. Por ejemplo, en una tabla de ventas, si una columna muestra “€ 1,000” y otra “1000 euros” para la misma cantidad, aunque es lo mismo, las diferencias pueden confundir al modelo. Otro caso común es que nombres de ciudades aparezcan escritos de distintas formas (“Nueva York” y “New York”) o fechas en formatos diferentes (“01-01-2020” y “2020/01/01”).

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Si los datos no son consistentes, el modelo no sabe cuál forma es la correcta y puede dar resultados poco fiables. Mantener la consistencia permite que el modelo entienda mejor la información y la procese sin errores.

Además, la consistencia también implica evitar contradicciones internas. Por ejemplo, si en una base de datos una persona tiene 10 años y en otro registro tiene 25, esto genera problemas cuando el modelo intenta aprender.

Con datos consistentes, el entrenamiento es más fácil. El modelo aprende patrones reales y no se confunde con formatos o datos contradictorios, mejorando la calidad y precisión de las predicciones.

Cómo un preprocesamiento adecuado mejora la precisión y evita errores o sesgos (desviaciones que pueden alterar los resultados)

Un preprocesamiento adecuado es como ordenar y preparar los datos antes de entrenar un modelo. Cuando los datos están completos, organizados y equilibrados, el modelo aprende de forma más clara y efectiva. Así se evita que se confunda con datos faltantes, valores extremos o diferencias en formatos.

Por ejemplo, si hay registros duplicados, el modelo puede contar la misma información varias veces y aprender patrones falsos. Si faltan datos, no entenderá bien las relaciones. Si los datos están escritos de formas distintas, como “10 %” y “0.1” para un 10 %, el modelo puede confundirse al comparar.

Corregir sesgos también es fundamental. Si hay más datos de un grupo que de otro, el modelo puede favorecer a ese grupo. Detectar y equilibrar esto durante el preprocesamiento ayuda a que el modelo sea justo.

La precisión mejora directamente tras un buen preprocesamiento, porque el modelo trabaja con datos claros y sin errores, aprendiendo patrones reales que permiten hacer predicciones fiables y decisiones seguras.

Cómo trabajar de forma estructurada con los datos antes de usar técnicas más avanzadas

Trabajar estructuralmente con los datos es esencial para que el proyecto funcione bien. Esto implica una serie de pasos clave para preparar los datos correctamente.

Primero, exploramos los datos para entender qué contienen, cómo se distribuyen y qué relaciones hay entre variables. Se analizan distribuciones, valores atípicos y correlaciones para detectar problemas o patrones importantes.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Luego, limpiamos los datos, corrigiendo valores nulos, duplicados o errores que afecten la calidad. Por ejemplo, rellenamos huecos con valores representativos o eliminamos duplicados. También corregimos formatos incorrectos.

Después, transformamos los datos para que tengan formatos y escalas compatibles. Esto incluye normalizar, escalar y codificar variables de texto en números. Algunas transformaciones necesitan “aprender” cómo deben cambiar los datos solo con los datos de entrenamiento, y luego se aplican al conjunto de prueba para evitar que el modelo acceda a información que no debería durante el entrenamiento.

Este proceso no es siempre un paso a paso rígido. Según el algoritmo, el problema o la calidad de los datos, algunos pasos pueden cambiar de orden, aplicarse juntos o incluso omitirse. Cada paso es una herramienta que se adapta a cada caso, no una receta fija.

Luego, se revisa la selección y reducción de características para elegir las variables más importantes. Técnicas como el filtrado o PCA pueden ayudar, pero no siempre se usan. A veces eliminar valores atípicos o reducir variables puede hacer perder información útil, por eso se decide cuándo aplicarlas.

Finalmente, los datos se dividen en conjuntos de entrenamiento y prueba para asegurar que el modelo generalice y no memorice. El preprocesamiento es dinámico, ya que tras entrenar el modelo, se pueden probar otras limpiezas o transformaciones para optimizar resultados.

Qué herramientas ayudan en el preprocesamiento de los datos

Para el preprocesamiento usaremos herramientas clave que son base en casi todos los modelos y proyectos porque facilitan preparar, analizar y entender datos de forma eficiente.

NumPy es ideal para trabajar con arrays y operaciones matemáticas rápidas. Permite manejar grandes cantidades de datos numéricos y hacer cálculos complejos, base para preparar datos antes de procesamientos avanzados.

Pandas es esencial para manejar datos tabulares, similar a hojas de cálculo. Facilita detectar valores nulos, duplicados y transformar columnas para que tengan el formato adecuado. Es la herramienta para limpiar y organizar datos antes de entrenar.

Matplotlib ayuda a visualizar datos mediante gráficos que muestran distribuciones, relaciones y valores atípicos. Visualizar es clave para detectar problemas no evidentes solo con números.

Scikit-learn, además de sus modelos, incluye funciones para preprocesar datos: codificar variables, escalar, seleccionar características y crear pipelines que automatizan preparación y modelado, ahorrando tiempo y reduciendo errores.

Estas son herramientas básicas y habituales, aunque hay muchas otras según el proyecto, complejidad y entorno.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Estas herramientas básicas son las que se utilizan con más frecuencia, aunque existen muchas otras según el proyecto, la complejidad y el entorno de trabajo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)

