

Lección 2. Limpieza de datos detección y tratamiento de valores nulos duplicados y errores

Por qué es importante la limpieza de datos para garantizar la fiabilidad de los modelos

La limpieza de datos es un proceso imprescindible porque la calidad final del modelo depende directamente de la calidad de los datos que se le entregan. Datos con errores, valores faltantes o duplicados pueden introducir sesgos o ruido que afectan la capacidad del modelo para aprender patrones reales. Por ejemplo, un conjunto de datos con muchos valores erróneos puede hacer que el modelo dé predicciones inconsistentes o con baja precisión.

Además, la limpieza reduce el riesgo de que el modelo aprenda relaciones irrelevantes que solo están presentes por errores en los datos. Limpiar los datos también facilita que el proceso de entrenamiento sea más eficiente y estable, evitando problemas como valores extremos que pueden desestabilizar el aprendizaje o sesgos que favorecen ciertos grupos o clases de forma injusta.

Por todo esto, dedicar tiempo a una limpieza cuidadosa es fundamental para que el modelo pueda entrenarse con datos representativos y de calidad, y así lograr resultados fiables y robustos.

Qué son los valores nulos y cómo afectan a la calidad de los datos

Los valores nulos representan datos ausentes o no registrados, que aparecen como celdas vacías, "NaN" o con valores especiales según la fuente. Estos huecos generan incertidumbre para el modelo porque no sabe qué interpretar en esos casos, lo que puede afectar negativamente el aprendizaje.

Si se dejan tal cual, muchos algoritmos no pueden procesarlos correctamente y pueden generar errores o resultados erráticos. Por eso, identificar los valores nulos es el primer paso para decidir cómo tratarlos.

Las formas de tratar valores nulos varían según el contexto, se pueden eliminar filas o columnas con muchos datos faltantes, rellenar los huecos con medias, medianas o valores más representativos, o utilizar técnicas avanzadas como imputación basada en modelos estadísticos o de aprendizaje. Cada opción tiene ventajas y desventajas, y elegir la adecuada depende del tipo de datos, su volumen y la importancia de la variable para el modelo.

Un buen tratamiento de valores nulos mejora la calidad del dataset y permite que el modelo aproveche toda la información disponible sin sesgos derivados de los datos incompletos.

Cómo identificar y tratar los datos duplicados para evitar sesgos y resultados poco fiables

Los datos duplicados son registros repetidos que, si no se detectan y eliminan, pueden causar que el modelo le dé un peso excesivo a ciertos casos. Esto genera un sesgo en el aprendizaje, porque el modelo interpreta que esos patrones o resultados ocurren con mayor frecuencia de lo real.

Detectar duplicados implica buscar filas idénticas o casi idénticas, considerando todas o algunas columnas clave. No siempre es tan sencillo porque en ocasiones pueden existir registros similares pero no iguales, lo que requiere análisis más profundo.

Una vez identificados, los duplicados se eliminan o consolidan para que solo haya una única representación de esa información. Esto mejora la representatividad y la calidad del conjunto de datos, haciendo que el modelo aprenda patrones reales y no repetidos artificialmente.

En proyectos grandes, automatizar esta detección es clave para evitar que la duplicidad afecte la construcción del modelo, especialmente cuando se combinan datos de distintas fuentes o se realizan actualizaciones frecuentes.

Cómo detectar y corregir errores en los datos para mejorar su consistencia y precisión

Los errores en los datos pueden ser variados: formatos incorrectos (fechas mal escritas, números con caracteres extra), valores fuera de rango (edad negativa, precios imposibles), inconsistencias lógicas (datos contradictorios entre columnas), o errores humanos y de entrada.

Detectar estos errores requiere realizar análisis exploratorios, revisar distribuciones, comprobar reglas de negocio y detectar valores que no tienen sentido. Herramientas como la visualización gráfica o estadísticas resumen son útiles para identificar valores atípicos o inconsistentes.

Corregir estos errores puede implicar transformar formatos para unificar, reemplazar valores fuera de rango, validar datos cruzándolos con otras fuentes o, en algunos casos, eliminar registros que no pueden corregirse. Esta corrección mejora la calidad y coherencia del dataset, lo que repercute directamente en la precisión y robustez del modelo.

Mantener la consistencia evita que el modelo aprenda patrones erróneos o contradicciones, y facilita interpretaciones claras y fiables de los resultados.

Qué herramientas permiten realizar estas tareas de limpieza de forma eficiente y segura

Existen muchas herramientas diseñadas para facilitar y automatizar la limpieza de datos, garantizando eficiencia y minimizando errores humanos. Aunque hay diversas opciones, en nuestro

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



caso utilizaremos principalmente librerías de Python como Pandas, que ofrecen funciones muy prácticas para detectar valores nulos (`isna()`, `fillna()`), identificar duplicados (`duplicated()`, `drop_duplicates()`) y manejar datos únicos (`unique()`).

Estas funciones permiten realizar operaciones precisas y eficientes para limpiar los datos, desde detectar y tratar valores faltantes hasta eliminar registros repetidos que podrían sesgar el modelo.

Estas son las principales herramientas que emplearemos para asegurar que el proceso de limpieza sea claro, reproducible y efectivo, aunque existen muchas otras según la complejidad y necesidades del proyecto.