

Lección 3. Visualización exploratoria distribuciones correlaciones y detección de problemas

Por qué es importante la visualización para entender los datos antes de entrenar modelos

La visualización es una herramienta fundamental para comprender los datos antes de aplicar cualquier modelo. Representar la información gráficamente nos permite detectar patrones, tendencias o problemas que no se aprecian con simples tablas o números. Esta comprensión previa ayuda a tomar decisiones informadas sobre qué técnicas de preprocesamiento aplicar y cómo ajustar los modelos para obtener mejores resultados.

Qué muestran las distribuciones y cómo ayudan a detectar patrones

La distribución de una variable describe cómo se organizan sus valores dentro del conjunto de datos. Entender la distribución es fundamental porque muchos algoritmos de aprendizaje automático asumen ciertos comportamientos estadísticos, y la forma de la distribución puede influir en la calidad del modelo.


Tipos principales de distribuciones que podemos encontrar

- **Distribución normal (gaussiana):** Es la más conocida y común, con forma de campana simétrica. La mayoría de los valores se concentran alrededor de la media y la probabilidad disminuye hacia los extremos. Muchos modelos funcionan mejor cuando las variables se acercan a esta distribución porque representa un comportamiento “esperado” y equilibrado.
- **Distribución sesgada (asimétrica):** Ocurre cuando los datos se “desplazan” hacia un lado, formando una cola más larga en la derecha (sesgo positivo) o en la izquierda (sesgo negativo). Esto puede hacer que algunos valores extremos tengan más peso y afectar la estabilidad del modelo. Es común en variables económicas como ingresos o precios.
- **Distribución uniforme:** Los datos están distribuidos de forma homogénea a lo largo de un rango, sin concentrarse en ningún valor específico. Esto puede indicar que no hay un patrón claro o que la variable tiene valores igualmente probables.
- **Distribución multimodal:** Presenta varios picos o modos, lo que indica que la variable puede estar formada por diferentes subgrupos o poblaciones mezcladas. Por ejemplo, la distribución de alturas en una población que combina niños y adultos puede ser multimodal.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- **Distribución discreta:** Datos que toman valores concretos y separados, como el número de visitas o la cantidad de productos comprados. La forma de la distribución discreta puede variar mucho y afecta cómo se modelan estas variables.



En esta imagen vemos cuatro gráficos que muestran diferentes tipos de distribuciones de datos. Cada gráfico combina un **histograma** con una **curva de densidad** para facilitar la comprensión.

Histograma: Son las barras grises que ves. Muestran cuántos datos hay en cada rango o "bin". Cuanto más alta es una barra, más valores hay en ese rango.

Curva de densidad: Es la línea negra suave que recorre las barras. Representa la forma general de la distribución, mostrando cómo se "extienden" los datos de forma continua. Nos ayuda a ver patrones que no siempre se ven con el histograma solo.

Primera imagen (arriba izquierda) — Distribución normal (gaussiana): La forma clásica de campana simétrica. La mayoría de los datos se agrupan alrededor del centro (la media) y disminuyen

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




gradualmente hacia los extremos. Esta es la distribución “ideal” que muchos modelos esperan para funcionar bien.

Segunda imagen (arriba derecha) — Distribución sesgada a la derecha: Aquí la curva está desplazada hacia la izquierda, con una cola larga que se extiende hacia valores altos a la derecha. Esto indica que hay pocos valores muy grandes que pueden influir mucho en el modelo si no se tratan bien.

Tercera imagen (abajo izquierda) — Distribución multimodal: Se observan dos picos o “modos” en la curva, lo que indica que los datos provienen de dos grupos diferentes. Esto puede significar que estamos mezclando poblaciones o situaciones distintas que podrían necesitar tratamiento separado.

Cuarta imagen (abajo derecha) — Distribución uniforme: La curva es bastante plana, y las barras tienen alturas similares. Esto indica que los datos están distribuidos de manera casi igual en todo el rango, sin un valor o rango que predomine.



En este gráfico vemos la distribución del número de llamadas recibidas en un centro de atención durante un período determinado.

Las **barras grises** representan la frecuencia de cada número de llamadas. Por ejemplo, la barra sobre el número 3 indica cuántas veces exactamente se recibieron 3 llamadas. Como los valores son discretos y enteros, cada barra corresponde a un valor específico y no hay valores intermedios entre ellos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



La **línea azul** es una curva de densidad que suaviza la información de las barras para mostrar la tendencia general de la distribución. Aunque en variables discretas la curva no es tan precisa como en variables continuas, ayuda a visualizar cómo se agrupan los datos y si existen valores más comunes o agrupaciones.

Podemos observar que los números 2, 3 y 4 son los que más frecuencia tienen, indicando que recibir esa cantidad de llamadas es lo más habitual en este centro.

Este tipo de análisis es útil para entender variables que representan conteos o categorías ordenadas. Saber cómo se distribuyen los valores ayuda a decidir si es necesario agrupar ciertos valores, transformar la variable o aplicar técnicas específicas en el modelado.

Importancia del tipo de distribución y cómo actuar según cada caso

Conocer el tipo de distribución que presentan las variables en un conjunto de datos es fundamental porque influye directamente en cómo se deben preparar los datos y qué modelos serán más efectivos.

Por ejemplo, cuando una variable tiene una distribución muy sesgada —es decir, que sus valores se concentran en un extremo y se extienden hacia el otro—, esto puede dificultar que el modelo aprenda patrones claros. En estos casos, aplicar transformaciones matemáticas como el logaritmo, la raíz cuadrada o la transformación Box-Cox ayuda a equilibrar la distribución, haciéndola más simétrica y facilitando el aprendizaje.

Si la distribución es multimodal, con varios picos que indican la existencia de subgrupos o poblaciones distintas, es recomendable segmentar los datos según estos grupos o utilizar modelos que puedan capturar esta diversidad, como modelos basados en clústeres o ensamblajes.

Cuando la distribución es uniforme, donde los valores están distribuidos de manera homogénea sin concentrarse en rangos específicos, puede ser necesario realizar ingeniería de características para extraer información significativa que no es evidente solo con la distribución original. Esto puede incluir crear variables derivadas o combinar atributos para mejorar la capacidad predictiva.

Además, en todos los casos, entender la distribución ayuda a anticipar problemas como valores atípicos, la necesidad de normalización o escalado, y a seleccionar técnicas de modelado adecuadas, ya sea modelos lineales, no lineales, o basados en árboles, entre otros.

Valores atípicos (outliers)

Los valores atípicos o *outliers* son observaciones que se encuentran muy alejadas del resto de datos en una variable. Estos valores pueden ser muy diferentes en magnitud o en comportamiento respecto a la mayoría de la muestra, y pueden afectar negativamente el entrenamiento y el rendimiento de los modelos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




¿Dónde se pueden detectar los valores atípicos?

Aunque algunos valores atípicos pueden verse ya en los histogramas cuando muestran barras muy separadas o colas largas, la forma más clara y precisa de detectar outliers es a través de diagramas de caja o *boxplots*.

¿Qué es un boxplot y cómo ayuda?

Un boxplot es un gráfico que resume la distribución de una variable mostrando información clave como la mediana, los cuartiles y los valores extremos. En él, una caja representa el rango intercuartílico, que contiene la mitad central de los datos, mientras que una línea dentro de la caja señala la mediana, el valor central. Desde la caja se extienden los “bigotes”, que llegan hasta un límite definido, normalmente 1.5 veces el rango intercuartílico, y cualquier punto que quede fuera de estos bigotes se considera un valor atípico o outlier. Este tipo de gráfico facilita visualizar rápidamente la dispersión y detectar valores que se alejan significativamente del resto.



- La **caja gris** representa el rango donde está el 50 % central de los datos, entre el primer cuartil (Q1) y el tercer cuartil (Q3).
- La **línea negra dentro de la caja** marca la mediana, que divide los datos en dos partes iguales.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- Los **bigotes** se extienden hasta los valores más extremos dentro de un rango considerado “normal” ($Q1 - 1.5 \times IQR$ y $Q3 + 1.5 \times IQR$).
- Los **puntos fuera de los bigotes** (los que están arriba y abajo) son los valores atípicos o *outliers*. En este caso, se ven varios puntos aislados, que indican observaciones muy alejadas del resto.

Este gráfico ayuda a identificar rápidamente si hay datos extremos que podrían afectar el modelo y que merecen atención o tratamiento especial.

¿Por qué es importante detectar y tratar valores atípicos?

Detectar y tratar los valores atípicos es fundamental porque estos pueden tener diversas causas y efectos en el análisis de datos y en la construcción de modelos. En algunos casos, los valores atípicos son el resultado de errores de medición o entrada, es decir, datos incorrectos que deben ser corregidos o eliminados para evitar que contaminen el conjunto de datos. En otras situaciones, estos valores extremos pueden reflejar la variabilidad natural del fenómeno que estamos estudiando y, por tanto, aportar información valiosa sobre casos excepcionales o poco frecuentes. Además, los valores atípicos pueden indicar que el conjunto de datos está mezclando diferentes poblaciones o grupos, lo que sugiere la necesidad de segmentar o tratar estas subpoblaciones por separado.

Si no se identifican y gestionan correctamente, los valores atípicos pueden distorsionar el modelo, haciendo que aprenda patrones erróneos o poco representativos, lo que afecta la capacidad predictiva y la generalización. También pueden influir negativamente en métricas estadísticas como la media o la desviación estándar, que son sensibles a valores extremos, dando una impresión equivocada sobre el comportamiento general de los datos. Por último, la presencia de outliers puede causar inestabilidad durante el proceso de entrenamiento, dificultando la convergencia y haciendo que el modelo sea menos robusto. Por eso, es esencial analizar con detenimiento estos valores para decidir cómo tratarlos según el contexto y los objetivos del proyecto.

¿Qué hacer al detectar valores atípicos?

Al detectar valores atípicos, el primer paso es verificar si se deben a errores, revisando su origen para corregirlos o eliminarlos si es necesario, evitando así que datos incorrectos afecten el análisis. Luego, es importante evaluar la relevancia de esos outliers, considerando si aportan información valiosa sobre casos excepcionales o si simplemente representan ruido que puede distorsionar el modelo. En función de esta valoración, se pueden aplicar técnicas robustas que utilicen métricas menos sensibles a valores extremos, como la mediana, o emplear modelos diseñados para manejar outliers de forma eficaz. Además, transformar los datos mediante escalados o funciones matemáticas puede ayudar a reducir la influencia de estos valores extremos, favoreciendo un aprendizaje más estable y preciso. Cada una de estas acciones debe adaptarse al contexto del problema y a las características específicas del conjunto de datos.

Relaciones entre variables y su impacto en el modelo

En un conjunto de datos, las características no están aisladas entre sí. Muchas veces existe algún tipo de relación entre ellas, como si una depende de la otra o si ambas se mueven de forma parecida o contraria. Entender estas relaciones ayuda a descubrir patrones que no siempre son evidentes y permite preparar mejor los datos antes de construir cualquier modelo de aprendizaje automático. Además, conocer cómo interactúan las características entre sí evita que la información se repita o se confunda, lo que puede afectar negativamente la calidad de los resultados.

Por ejemplo, si tenemos un conjunto de datos con las características altura y peso de personas, es común que estas dos estén relacionadas. En general, a mayor altura, mayor peso, lo que se traduce en una correlación positiva. Esto no quiere decir que la altura cause un cambio directo en el peso, pero sí que ambas comparten una tendencia común. Si esta relación no se tiene en cuenta en un modelo, podría generar resultados poco fiables o dar más importancia de la necesaria a una característica duplicada.

La correlación es una medida que nos ayuda a detectar estas relaciones de forma cuantitativa. Aunque no indica si una característica causa cambios en otra, sí nos da pistas de cuánto se parecen o se oponen en su comportamiento. Por eso, estudiar las correlaciones forma parte esencial de cualquier análisis exploratorio de datos. Esto permite ver más allá de los valores individuales y entender cómo se conectan las distintas piezas del conjunto.

Al tener una idea clara de las correlaciones, podemos tomar decisiones más seguras sobre qué características conservar, transformar o eliminar. También nos ayuda a evitar problemas como la multicolinealidad, que puede complicar los modelos de regresión o hacer que ciertos algoritmos se comporten de forma inestable. Así, el análisis de correlación es clave para construir modelos sólidos, fiables y con predicciones más acertadas.

Qué es la correlación y su importancia

La correlación muestra cómo dos características numéricas se relacionan y cómo cambian juntas. Indica si una tiende a subir o bajar cuando la otra lo hace o si no tienen ninguna relación entre ellas. Cuando la correlación es positiva, ambas características se mueven en la misma dirección. Por ejemplo, la cantidad de horas de ejercicio semanal y la energía diaria que se siente suelen subir juntas, reflejando una relación positiva. Una correlación negativa significa que cuando una sube, la otra baja. Por ejemplo, el tiempo de espera en una tienda y la satisfacción del cliente: cuanto más tiempo espera una persona, menos satisfecho suele estar. Si la correlación es nula, no existe relación aparente, como puede pasar entre el número de letras del nombre de una persona y la distancia que recorre cada día para ir a trabajar.

Conocer la correlación es importante porque ayuda a entender cómo está organizada la información en un conjunto de datos. Permite identificar duplicidades de información o patrones que se repiten, lo que puede llevar a modelos de aprendizaje automático más estables y con mejores predicciones. Además, si las características tienen una relación muy fuerte, se corre el riesgo de que el modelo se base en información repetida o que sobrevalore ciertas relaciones, algo que puede distorsionar los resultados finales.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



La correlación también ayuda a decidir si es necesario transformar los datos o eliminarlos para evitar errores. Así, antes de entrenar un modelo, revisar la correlación entre las características garantiza que se construya con información útil, completa y sin sesgos innecesarios.

Cómo se calcula y qué significa su valor

El cálculo de la correlación se basa en distintos coeficientes que permiten expresar la fuerza y la dirección de la relación entre dos características. El más utilizado es el coeficiente de Pearson, que mide la relación lineal y funciona bien cuando los datos siguen distribuciones normales o casi simétricas. Su valor varía de -1 a 1, donde valores cercanos a 1 indican una relación positiva fuerte, como podría ser la relación entre la cantidad de ejercicio físico y la capacidad cardiovascular. Valores cercanos a -1 señalan una relación negativa fuerte, como la relación entre el número de días de ausencia y la productividad laboral. Cuando el valor está cerca de 0, no hay relación lineal aparente.

Sin embargo, cuando las distribuciones de las características no son normales o muestran relaciones que no son lineales, el coeficiente de Pearson puede ser engañoso. Para esos casos se utiliza el coeficiente de Spearman, que mide la correlación en función de los rangos y no de los valores exactos. Este enfoque es más robusto ante valores extremos y mejor para detectar relaciones monótonas, donde una característica tiende a subir cuando la otra sube o a bajar cuando la otra baja, aunque no lo haga de manera proporcional. Por ejemplo, el nivel de estrés y la productividad pueden tener una relación que no es recta, pero que muestra una tendencia clara de que cuando sube uno, baja el otro.

Además, existen otros coeficientes como el de Kendall, que también se basa en el orden de los datos y es útil cuando hay muchos empates o datos con posiciones similares.

Es importante recalcar que la elección entre Pearson y Spearman no depende solo de la relación entre las características, sino también de sus distribuciones. Cuando las distribuciones son normales y la relación parece lineal, Pearson suele ser la mejor opción. Si las distribuciones son muy asimétricas o hay valores atípicos, Spearman se adapta mejor y ofrece resultados más fiables. Por ejemplo, si comparamos la antigüedad en la empresa con el nivel de confianza, puede no ser una relación lineal, pero Spearman capturarán si en general más antigüedad significa más confianza.

Por eso, cuando las características tienen distribuciones distintas (una normal y otra muy sesgada), Spearman es una elección más segura, ya que no depende tanto de la forma exacta de las distribuciones y detecta relaciones que van más allá de la linealidad.

Así, revisar las distribuciones antes de elegir qué coeficiente usar garantiza que el análisis sea preciso y que el modelo final trabaje con datos coherentes y fiables.

Tipos de correlación y cómo influyen en el análisis

La correlación puede clasificarse en tres tipos principales según el valor del coeficiente y la dirección de la relación entre dos características. Estos tipos ayudan a entender qué tan estrecha es la relación y cómo se comportan las características entre sí.

Cuando la correlación es positiva, significa que ambas características tienden a moverse en la misma dirección. Por ejemplo, el número de horas de práctica deportiva y el nivel de resistencia física suelen

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




subir juntos, mostrando un patrón de crecimiento compartido. Este tipo de correlación puede indicar que las dos características aportan información parecida, lo que podría llevar a duplicar datos en un modelo si no se revisa antes.

La correlación negativa aparece cuando una característica sube mientras la otra baja. Por ejemplo, el tiempo de espera para ser atendido en un servicio y el nivel de satisfacción del cliente muestran una relación inversa: a mayor espera, menor satisfacción. Este tipo de relación puede ser útil para entender qué características tienen un efecto compensatorio y cómo podría impactar en las predicciones del modelo.

Por último, existe la correlación nula, donde no se observa ningún patrón claro. Esto sucede cuando las características no tienen ninguna relación aparente, como el número de zapatos que tiene una persona y la cantidad de horas que duerme al día. Detectar la falta de correlación es igual de importante, ya que permite identificar qué características realmente no tienen conexión y no deberían influir en la construcción del modelo.

Estos tipos de correlación son fundamentales en el análisis porque permiten saber si conviene mantener o ajustar las características antes de usarlas en un modelo. Así se evita dar más peso a relaciones poco relevantes o dejar que datos duplicados distorsionen los resultados. Además, conocer el tipo de correlación también ayuda a seleccionar el mejor enfoque para visualizar y comparar las características, mejorando la calidad del aprendizaje y la interpretación de los resultados finales.



En este ejemplo se muestran tanto correlaciones positivas fuertes como negativas fuertes, y también un ejemplo de características sin relación clara.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- `actividad_fisica` y `salud_general` tienen una correlación positiva muy alta (valor cercano a 1), lo que indica que cuando una sube, la otra también lo hace casi de forma directa, aunque con un poco de variabilidad natural.
- `actividad_fisica` y `nivel_estres` muestran una relación negativa fuerte (valor cercano a -1), lo que significa que cuando una sube, la otra baja casi de forma proporcional.
- `num_hobbies` no tiene correlaciones fuertes con las otras características, lo que indica que sus valores no están relacionados directamente con el resto.


Este ejemplo ilustra cómo los coeficientes cercanos a 1 o -1 reflejan relaciones claras y consistentes, mientras que valores cercanos a 0 muestran independencia. Estas diferencias son esenciales para decidir qué características pueden aportar información útil y cuáles podrían complicar el modelo o no añadir valor real.

Por ejemplo, la fuerte correlación positiva entre `actividad_fisica` y `salud_general` sugiere que probablemente aportan información similar. Mantener ambas en un modelo de regresión podría generar multicolinealidad, haciendo que los coeficientes sean inestables o difíciles de interpretar. En estos casos, podríamos plantear quedarnos solo con una de ellas o combinarlas en una nueva variable que resuma la información compartida.

Por otro lado, `nivel_estres` tiene una correlación negativa fuerte con `actividad_fisica`, lo que también puede aportar información importante pero de forma opuesta. Aquí conviene mantenerla porque ofrece un punto de vista complementario: aporta valor porque representa un patrón claro, aunque contrario.

Finalmente, `num_hobbies` no tiene correlaciones fuertes con ninguna otra característica. Esta independencia puede ser útil para añadir información única al modelo y enriquecer las predicciones. Por eso, aunque no tenga relación con las otras características, podría ser interesante mantenerla.

Estos resultados muestran que tener correlaciones fuertes no significa que debamos eliminar características automáticamente. Siempre dependerá de la situación y del objetivo del modelo. A veces, la información redundante no afecta o incluso puede ayudar en modelos más complejos. Por eso, la mejor forma de decidir qué características mantener o quitar es hacer pruebas y comparar cómo cambian las métricas de rendimiento. Así se puede ver si la eliminación de características correlacionadas mejora la precisión y la estabilidad o si, por el contrario, se pierde información valiosa. Ajustar el número de características según las correlaciones y la utilidad real de cada una permite construir modelos más claros, interpretables y ajustados a las necesidades de cada problema.



En este ejemplo con cuatro características y sus correlaciones calculadas con el método de Spearman.

- **horas_estudio** y **mejora_nota** muestran una relación monótona positiva (cercana a 1). Aunque no es estrictamente lineal, se ve que más horas de estudio suelen implicar mejores notas, con un patrón general que Spearman detecta bien.
- **horas_estudio** y **nivel_cansancio** presentan una relación negativa fuerte. A medida que suben las horas de estudio, baja el nivel de cansancio, pero de forma no lineal. Aun así, Spearman capta esta relación porque mide si una característica tiende a subir o bajar de manera consistente, aunque no lo haga en proporción directa o con una línea recta.
- **num_amistades** no tiene relación clara con las otras características y por eso muestra correlaciones cercanas a 0, confirmando que no existe una tendencia general.

Este ejemplo demuestra que el coeficiente de Spearman detecta relaciones de orden o tendencia, aunque no sean lineales. Es decir, ve si una característica sube o baja en conjunto con la otra, aunque la relación siga una curva o tenga valores atípicos que desvíen el cálculo de una recta perfecta. Por eso, aunque los gráficos y los valores numéricos en los mapas de calor parezcan similares a los de Pearson, los resultados de Spearman permiten ver patrones reales en datos donde la forma de la relación no es tan clara o no sigue una línea recta.

Estos resultados ayudan a decidir si conviene mantener o quitar características antes de entrenar un modelo. Aunque la correlación sea fuerte, no siempre significa que una característica deba

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



eliminarse. Puede aportar información útil o complementar el análisis. Sin embargo, si la relación es tan fuerte que genera duplicidad o dificulta la interpretación del modelo, conviene agruparlas o quedarse solo con la que más valor aporta. La decisión final depende de la situación, del objetivo del análisis y de las pruebas que confirmen si la reducción mejora la precisión y estabilidad del modelo o si elimina información relevante.

Correlación de las características con el objetivo y su utilidad


Además de ver cómo se relacionan las características entre sí, también es muy útil calcular la correlación directa de cada característica con la variable objetivo. Esta correlación nos dice qué tan fuerte es la relación de cada característica con el resultado que queremos predecir o explicar, ayudándonos a identificar cuáles son más relevantes para el modelo y cuáles no aportan valor real.

A diferencia de la matriz de correlaciones completa, que nos muestra duplicidades o relaciones internas entre las características, la correlación con el objetivo nos ayuda a ver si una característica tiene potencial para mejorar la precisión del modelo o si simplemente es ruido. Por ejemplo, si una característica tiene una correlación cercana a 1 o -1 con el objetivo, es probable que sea importante incluirla en el modelo. Si su correlación es cercana a 0, puede no aportar información clave.

Al elegir el tipo de correlación a usar, es clave tener en cuenta la distribución de las características y la naturaleza de la relación que puedan tener con el objetivo. Si la relación es lineal y las distribuciones de las características y del objetivo son normales o casi simétricas, el coeficiente de Pearson es el más adecuado. Sin embargo, cuando la relación no es lineal pero sigue una tendencia general (por ejemplo, una característica que siempre sube o baja con la otra aunque no sea a ritmo constante), el coeficiente de Spearman funciona mejor porque mide cómo se ordenan los valores, sin depender de que sigan una línea recta.

Esto significa que si los datos son muy asimétricos, tienen muchos valores atípicos o siguen una forma curva, Spearman es más fiable y muestra mejor la relación real. En cambio, Pearson podría subestimar o no detectar la relación en esos casos. Por eso, para asegurar la mejor comprensión y la selección adecuada de las características, conviene revisar las distribuciones de los datos y decidir qué coeficiente se adapta mejor a la naturaleza de cada característica.

Al calcular estas correlaciones, se obtiene una lista clara con la fuerza y la dirección de cada relación. Estos valores sirven como guía para priorizar y probar cuáles características realmente ayudan al modelo y cuáles podrían descartarse o transformarse. Así, se consigue un modelo más sencillo, interpretativo y ajustado a la realidad del problema.



Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Imagina que quieres predecir el rendimiento físico de un grupo de personas a partir de su tiempo de entrenamiento semanal y su consumo de calorías diarias. Ambas características tienen distribuciones normales y la relación parece seguir una línea recta clara. Usando Pearson, ves que la correlación entre el tiempo de entrenamiento y el rendimiento es de 0.85, mientras que la del consumo de calorías con el rendimiento es de 0.3. Esto indica que el tiempo de entrenamiento tiene una relación más fuerte y directa con el objetivo que el consumo de calorías, y se puede priorizar en el modelo.

Ahora supón que analizas cómo influye el nivel de motivación en la productividad de los empleados, pero la relación no es lineal: la productividad sube rápidamente con la motivación al inicio, pero luego se estabiliza. Aquí, aunque los datos no siguen una línea recta, usando Spearman obtienes una correlación de 0.7, lo que refleja bien la tendencia general de que más motivación suele llevar a mayor productividad. Pearson, en cambio, podría no ver esta relación si no es estrictamente lineal y daría un valor más bajo.

Estos dos ejemplos muestran cómo elegir Pearson o Spearman depende de la distribución y la forma de la relación entre las características y el objetivo, y cómo esto ayuda a decidir qué características usar o transformar para construir modelos más ajustados y fiables.

Cómo detectar problemas en los datos mediante gráficos y análisis visuales

La visualización de los datos no solo permite ver distribuciones y relaciones, también ayuda a identificar problemas que pueden afectar el rendimiento del modelo. Dos aspectos importantes son los valores faltantes y el desequilibrio en las clases de la variable objetivo.

Valores faltantes y su impacto


Además de ver los valores faltantes con métodos directos como `isnull()` o `isna()`, los gráficos permiten entender de forma visual dónde se encuentran estos problemas y cómo afectan al conjunto de datos. Un gráfico de barras, como el que muestra el porcentaje de valores faltantes por columna, deja claro qué columnas están más afectadas. En el ejemplo, se ve que `ingresos` y `horas_trabajo` tienen algunos valores vacíos, mientras que `edad` está completa.

Cuando los datos faltantes están concentrados en unas pocas columnas, se pueden tratar de forma dirigida, por ejemplo, imputando los valores con la media o eliminando la columna si no aporta mucho al análisis. Si los valores faltantes están dispersos por todo el conjunto, conviene un enfoque más cuidadoso para no perder información valiosa.

Detectar visualmente estos valores faltantes complementa lo que se ve al revisar los resultados de `isnull().sum()`, y ayuda a decidir cómo manejar la situación antes de construir los modelos. Es importante porque los modelos de aprendizaje automático suelen requerir datos completos para entrenar bien y evitar sesgos. Así, ver los faltantes gráficamente permite entender mejor su magnitud y tomar decisiones más informadas para garantizar la calidad del análisis.


Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)





Desequilibrio de clases en la variable objetivo

Cuando la variable objetivo es categórica, es importante ver si todas las clases tienen la misma cantidad de registros o si algunas están sobrerrepresentadas. Este desequilibrio puede causar que el modelo aprenda solo de la clase mayoritaria y no funcione bien para las demás, generando resultados poco fiables.



En el gráfico circular que se ve aquí, las proporciones de cada clase permiten ver de forma clara cómo están distribuidos los datos. Por ejemplo, la Clase A tiene la mayoría de los registros, mientras que las Clases B y C apenas suman una pequeña parte.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




Este tipo de visualización ayuda a detectar si existe un desequilibrio fuerte y a decidir cómo gestionarlo. Dependiendo del caso, se puede usar un muestreo para equilibrar los datos o ajustar las métricas de evaluación. Entre las técnicas más usadas están el sobremuestreo de las clases minoritarias, que consiste en generar copias o crear ejemplos sintéticos usando métodos como SMOTE o ADASYN. Estas técnicas añaden diversidad a la clase minoritaria y reducen el riesgo de que el modelo la ignore. También se usa el submuestreo de la clase mayoritaria, que implica eliminar registros de la clase más frecuente para equilibrar la proporción, aunque con el riesgo de perder información.

Otra opción es ajustar el entrenamiento del modelo para que tenga en cuenta el desequilibrio sin cambiar los datos. Por ejemplo, en modelos de clasificación, se pueden usar pesos en la función de coste que den más importancia a la clase minoritaria o a las clases con menos ejemplos. Además, se suelen usar métricas que midan bien el rendimiento global, como el f1-score o la balanced accuracy, que tienen en cuenta la precisión de cada clase de forma más justa.

No siempre es necesario equilibrar los datos. Si la clase minoritaria es la que más interesa (como detectar fraude o anomalías), puede ser mejor ajustar solo la métrica y mantener el desequilibrio, ya que refleja la realidad del problema. Por eso es importante ver primero la magnitud del desequilibrio y hacer pruebas para ver qué técnica funciona mejor según los objetivos del análisis y la calidad final que se espera del modelo.

Desequilibrio de clases en las características

Una característica categórica puede tener decenas de valores distintos, pero a veces la mayoría de los registros se concentran en solo unas pocas categorías mientras otras apenas aparecen. Este desequilibrio hace que el modelo apenas reciba ejemplos de las categorías raras y su efecto se vuelva inestable o irrelevante en la predicción.



En el gráfico se observa la distribución de una característica con cinco categorías. Las barras muestran cuántos registros tiene cada una. A y B dominan el conjunto con más de doscientas observaciones entre ambas, mientras que C, D y E apenas suman una treintena. Esta diferencia tan

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



grande indica que el modelo casi no tendrá datos para aprender el comportamiento de las categorías minoritarias.

Cuando una característica categórica presenta un desequilibrio muy acusado, con unas pocas categorías dominando la mayoría de los registros y otras apareciendo apenas en unos pocos casos, el modelo no recibe información suficiente para aprender el comportamiento de los valores raros. Esto provoca dos problemas principales: por un lado, el modelo tiende a ignorar o predecir mal las categorías minoritarias; por otro, cualquier métrica global de rendimiento se ve inflada por el acierto en la clase mayoritaria, ocultando errores importantes en los casos raros.

Tratar este desequilibrio —por ejemplo, agrupando las categorías poco frecuentes en un valor “Otros” o aplicando técnicas de codificación que suavicen su peso— garantiza que el modelo disponga de ejemplos suficientes de cada grupo y tome decisiones más justas y precisas para todas las categorías, no solo para las mayoritarias. No siempre es necesario equilibrar: si las minoritarias representan casos críticos (como un tipo de error grave), puede interesar mantenerlas tal cual. Por eso conviene visualizar primero la distribución, valorar el impacto de cada estrategia y probar varias opciones para encontrar la que ofrezca un modelo más estable y útil.