

Lección 5. Selección y reducción de características filtrado PCA y técnicas avanzadas

Por qué es importante seleccionar las características más relevantes en un conjunto de datos

Al trabajar con datos para entrenar un modelo, no todas las variables aportan información útil o necesaria. Algunas pueden ser irrelevantes o no tener relación directa con lo que queremos predecir. Incluir estas variables poco relevantes no solo aumenta el tamaño del conjunto de datos, sino que también puede confundir al modelo, provocando que pierda precisión y estabilidad.

Cuando las variables irrelevantes están presentes, el modelo puede verse obligado a procesar información que no aporta nada real y que solo introduce ruido. Esto dificulta que aprenda los patrones correctos y puede llevar a un sobreajuste, donde el modelo aprende detalles muy específicos de los datos de entrenamiento pero pierde capacidad para generalizar a datos nuevos. Además, tener más variables de las necesarias incrementa el tiempo de entrenamiento y hace que el modelo sea más difícil de interpretar.

Para evitar esto, es esencial identificar las características que realmente aportan valor al modelo y trabajar solo con ellas. Seleccionar las variables más relevantes mejora la calidad de las predicciones, facilita el análisis de los resultados y permite que el modelo sea más ágil y fácil de mantener.

Además, este proceso no siempre tiene que hacerse manualmente. Existen técnicas y herramientas automáticas que pueden identificar las características más importantes comparando su relación con la variable objetivo y descartando las que no tienen un impacto claro. Estas técnicas permiten que la selección se haga de forma más rápida y objetiva, evitando decisiones subjetivas que podrían no ser las más adecuadas.

Por eso, seleccionar bien las características es uno de los pasos más importantes en el desarrollo de modelos de aprendizaje automático. Permite que el modelo se base en datos realmente útiles y que trabaje de forma más eficiente y confiable.

Qué es el filtrado y cómo ayuda a identificar las variables que aportan valor al modelo

El filtrado es un proceso que se utiliza para decidir qué variables tienen una relación clara con la variable objetivo y cuáles no aportan información útil. Aunque ya hemos visto medidas como la correlación de Pearson o de Spearman, el filtrado va más allá y consiste en revisar todas las variables usando esas medidas y otras pruebas estadísticas como el test de chi-cuadrado para variables categóricas. Sin embargo, en este curso nos centraremos sobre todo en técnicas más generales y potentes como el análisis de componentes principales (PCA).

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



El filtrado evalúa cada variable de forma independiente, sin tener en cuenta cómo interactúan entre sí en el modelo final. Esto permite ver si una variable tiene algún vínculo con la variable objetivo o si solo añade ruido, reduciendo así el tamaño del conjunto de datos y facilitando que el modelo trabaje con la información que realmente importa.

Aunque el filtrado puede ser un paso útil al inicio del análisis, el método que veremos en profundidad en esta lección es el PCA, que permite simplificar los datos sin perder la información esencial y que suele aplicarse después de este filtrado inicial.

Cómo funciona el Análisis de Componentes Principales y qué aporta a la reducción de características

El Análisis de Componentes Principales, conocido como PCA por sus siglas en inglés, es una técnica que se utiliza para simplificar un conjunto de datos mientras se mantiene la mayor parte de la información. Su objetivo es transformar las variables originales en un nuevo conjunto de variables llamadas componentes principales, que son combinaciones lineales de las variables originales y que capturan la mayor variabilidad posible de los datos. Esto permite trabajar con un número más reducido de variables sin perder la esencia de la información.

El PCA busca los ejes o direcciones en el espacio de datos donde los datos están más dispersos, encontrando así las dimensiones que mejor explican las diferencias y dejando fuera las que aportan poca variación o que solo introducen ruido. Cada componente principal combina las variables originales y se ordena de forma que el primero explica la mayor parte de la varianza (es decir, cómo varían los datos entre sí), el segundo un poco menos y así sucesivamente.

Por ejemplo, imagina que estás analizando un conjunto de datos con variables como altura, peso y longitud de pierna de varias personas. Aunque son variables distintas, están muy relacionadas, ya que las personas más altas suelen tener más peso y piernas más largas. El PCA combina estas variables en un nuevo eje, el primer componente, que representa esa relación general de tamaño corporal. Al usar solo este componente principal, se puede explicar casi toda la variabilidad de las tres variables originales, reduciendo el número de dimensiones de tres a una sola y manteniendo la información esencial.

Una de las grandes ventajas del PCA es que reduce la dimensionalidad de los datos, lo que simplifica el modelo y mejora la velocidad de entrenamiento. Además, reduce el riesgo de sobreajuste porque se eliminan detalles poco importantes que solo añaden ruido, algo especialmente útil cuando el conjunto de datos tiene muchas variables y es difícil interpretarlas todas a la vez.

Otra ventaja importante es que los componentes principales están ordenados por la cantidad de varianza que explican, lo que permite elegir de forma objetiva cuántos componentes utilizar. Por ejemplo, si los dos primeros componentes explican el 95% de la varianza, podemos usar solo esos dos y descartar el resto, haciendo el análisis mucho más sencillo.

El PCA se suele aplicar después de un filtrado inicial y de normalizar o estandarizar los datos, ya que funciona mejor cuando las variables están en escalas comparables. En problemas como clasificación o clustering, ayuda a visualizar los datos y a encontrar patrones más claros, mientras que en modelos predictivos mejora la eficiencia sin sacrificar precisión.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



El PCA transforma un conjunto de datos complejo en una versión más sencilla y ordenada, manteniendo casi toda la información útil y eliminando lo que solo añade ruido, lo que lo convierte en una herramienta clave para trabajar con datos de alta dimensión y modelos más estables.

Qué técnicas avanzadas ayudan a simplificar los datos sin perder información esencial

Además del PCA, existen otras técnicas que permiten reducir la cantidad de variables y simplificar los datos sin perder la información clave para el modelo. Estas técnicas ayudan a que el modelo sea más rápido y eficiente, sobre todo cuando se trabaja con conjuntos de datos muy grandes y con muchas variables.

Una de ellas se llama Análisis Discriminante Lineal (LDA), que aunque a primera vista es similar al PCA, tiene un objetivo diferente: en lugar de buscar las direcciones con mayor varianza, busca las direcciones que mejor separan las clases o categorías de la variable objetivo. Esto lo hace especialmente útil para problemas de clasificación, ya que no solo reduce la dimensionalidad sino que también maximiza la separación entre las clases.

Otra técnica avanzada son los Autoencoders, redes neuronales entrenadas para reconstruir los datos de entrada. Durante este proceso, se fuerza a la red a aprender una representación comprimida de los datos, creando así una versión más reducida pero con la misma información importante. Los autoencoders son muy potentes en problemas con datos muy complejos o cuando se quiere aplicar reducción de dimensionalidad no lineal.

También se pueden usar métodos como t-SNE o UMAP, que aunque suelen aplicarse más para visualización de datos que para reducir dimensiones antes de entrenar modelos, permiten ver relaciones en datos de muchas dimensiones y detectar patrones que no se ven fácilmente en un análisis tradicional.

Todas estas técnicas tienen en común que ayudan a simplificar el conjunto de datos y a detectar patrones más claros sin perder lo esencial. Dependiendo del tipo de problema y del modelo que se use, se puede optar por una técnica u otra, ya que cada una tiene sus ventajas y limitaciones.

En la práctica, conviene elegir la técnica que mejor se adapte al tipo de datos y al objetivo del análisis. Cuando se busca reducir dimensiones para mejorar la interpretación o la visualización, técnicas como t-SNE o UMAP son útiles. Si se busca maximizar la separación de clases en clasificación, el LDA es una buena opción. Para representar datos complejos en problemas no lineales, los autoencoders pueden ser muy potentes. Y para mantener la máxima varianza y simplificar variables numéricas, el PCA sigue siendo el método más usado.