

Autora: Mireia Consarnau Pallarés.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Preprocesamiento de datos. Preparando la base del aprendizaje automático.....	1
Introducción.....	1
Lección 1. Importancia del preprocesamiento calidad y consistencia de los datos.....	1
Por qué es importante la calidad de los datos para cualquier proyecto de aprendizaje automático.....	2
Qué implica la consistencia en un conjunto de datos y cómo influye en la construcción de modelos.....	2
Cómo un preprocesamiento adecuado mejora la precisión y evita errores o sesgos (desviaciones que pueden alterar los resultados).....	3
Cómo trabajar de forma estructurada con los datos antes de usar técnicas más avanzadas.....	3
Qué herramientas ayudan en el preprocesamiento de los datos.....	4
Lección 2. Limpieza de datos detección y tratamiento de valores nulos duplicados y errores.....	6
Por qué es importante la limpieza de datos para garantizar la fiabilidad de los modelos..	6
Qué son los valores nulos y cómo afectan a la calidad de los datos.....	6
Cómo identificar y tratar los datos duplicados para evitar sesgos y resultados poco fiables.....	7
Cómo detectar y corregir errores en los datos para mejorar su consistencia y precisión..	7
Qué herramientas permiten realizar estas tareas de limpieza de forma eficiente y segura.	7
Lección 3. Visualización exploratoria distribuciones correlaciones y detección de problemas.....	9
Por qué es importante la visualización para entender los datos antes de entrenar modelos.....	9
Qué muestran las distribuciones y cómo ayudan a detectar patrones.....	9
Tipos principales de distribuciones que podemos encontrar.....	9
Importancia del tipo de distribución y cómo actuar según cada caso.....	12
Valores atípicos (outliers).....	12
¿Dónde se pueden detectar los valores atípicos?.....	13
¿Qué es un boxplot y cómo ayuda?.....	13
¿Por qué es importante detectar y tratar valores atípicos?.....	14
¿Qué hacer al detectar valores atípicos?.....	14
Relaciones entre variables y su impacto en el modelo.....	15
Qué es la correlación y su importancia.....	15
Cómo se calcula y qué significa su valor.....	16
Tipos de correlación y cómo influyen en el análisis.....	16
Correlación de las características con el objetivo y su utilidad.....	20
Cómo detectar problemas en los datos mediante gráficos y análisis visuales.....	21
Valores faltantes y su impacto.....	21
Desequilibrio de clases en la variable objetivo.....	22
Desequilibrio de clases en las características.....	23
Lección 4. Transformación de datos normalización codificación y escalado.....	24

Por qué es importante transformar los datos antes de entrenar modelos de aprendizaje automático.....	24
Transformaciones logarítmicas y de potencia.....	25
Qué significa normalizar los datos y cómo mejora la comparabilidad entre variables.....	25
Qué implica estandarizar y escalar los datos y cómo ayuda a mejorar la eficiencia y estabilidad de los modelos.....	26
Por qué es necesario codificar las variables categóricas para que los algoritmos puedan usarlas correctamente.....	27
Cómo usar pipelines para encadenar limpieza codificación y escalado de forma reproducible.....	28
Cómo aplicar la secuencia de transformación de datos.....	28

Lección 5. Selección y reducción de características filtrado PCA y técnicas avanzadas

29

Por qué es importante seleccionar las características más relevantes en un conjunto de datos.....	29
Qué es el filtrado y cómo ayuda a identificar las variables que aportan valor al modelo.....	30
Cómo funciona el Análisis de Componentes Principales y qué aporta a la reducción de características.....	30
Qué técnicas avanzadas ayudan a simplificar los datos sin perder información esencial...	31

Preprocesamiento de datos. Preparando la base del aprendizaje automático

Introducción

El preprocesamiento de datos es un paso esencial antes de cualquier análisis o modelado. No basta con tener muchos datos, es necesario revisarlos, limpiarlos y transformarlos para que los modelos puedan aprender de ellos de forma eficiente y sin sesgos (desviaciones que pueden alterar los resultados o la interpretación). Esta unidad explica cómo convertir datos en bruto en una base sólida y coherente, lo que mejora la calidad de los resultados y reduce el riesgo de que los modelos aprendan patrones incorrectos o irrelevantes.

Cada paso, desde la limpieza de valores nulos o duplicados hasta la selección de las variables más importantes, forma parte de un proceso que define el éxito o el fracaso de un proyecto de aprendizaje automático. Este proceso no es solo cuestión de técnicas automáticas, también implica comprender cómo los datos pueden influir en los resultados y cómo trabajarlos de forma estructurada para garantizar modelos fiables y precisos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Lección 1. Importancia del preprocesamiento calidad y consistencia de los datos

Por qué es importante la calidad de los datos para cualquier proyecto de aprendizaje automático

La calidad de los datos es clave porque los modelos de aprendizaje automático aprenden a partir de la información que reciben. Si los datos están mal organizados o contienen errores, el modelo aprenderá cosas incorrectas, lo que puede hacer que las predicciones sean poco precisas o muy alejadas de la realidad. Por ejemplo, si hay muchos errores o valores faltantes, el modelo no podrá detectar patrones reales y fiables.

Tener datos de calidad significa que estén completos (sin huecos), bien organizados y representen lo que realmente queremos analizar. Si los datos no reflejan correctamente la situación real, el modelo fallará. Además, datos bien preparados aceleran el proceso de entrenamiento y mejoran la eficiencia del modelo.

Antes de aplicar técnicas avanzadas, es fundamental asegurarse de que los datos están en buen estado. Esto evita resultados erróneos y mejora la precisión del modelo.

Imagina que quieres entrenar un modelo para predecir el precio de las casas. Si los datos contienen errores —como direcciones mal escritas, precios faltantes o registros duplicados—, el modelo no aprenderá bien. Podría predecir que una casa pequeña vale más que una grande o dar valores totalmente fuera de lugar, porque solo aprende de los datos que tiene. Si esos datos no son correctos, el modelo no acertará.

Otro ejemplo: si trabajas con un sistema para predecir la demanda de un producto según la estación del año y tus datos no incluyen todas las estaciones o están incompletos, las predicciones pueden ser muy erróneas.

Estos casos muestran cómo datos de mala calidad llevan a modelos poco fiables. Por eso es tan importante revisar y corregir los datos.

Qué implica la consistencia en un conjunto de datos y cómo influye en la construcción de modelos

La consistencia significa que toda la información está alineada y no se contradice. Por ejemplo, en una tabla de ventas, si una columna muestra “€ 1,000” y otra “1000 euros” para la misma cantidad, aunque es lo mismo, las diferencias pueden confundir al modelo. Otro caso común es que nombres de ciudades aparezcan escritos de distintas formas (“Nueva York” y “New York”) o fechas en formatos diferentes (“01-01-2020” y “2020/01/01”).

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Si los datos no son consistentes, el modelo no sabe cuál forma es la correcta y puede dar resultados poco fiables. Mantener la consistencia permite que el modelo entienda mejor la información y la procese sin errores.

Además, la consistencia también implica evitar contradicciones internas. Por ejemplo, si en una base de datos una persona tiene 10 años y en otro registro tiene 25, esto genera problemas cuando el modelo intenta aprender.

Con datos consistentes, el entrenamiento es más fácil. El modelo aprende patrones reales y no se confunde con formatos o datos contradictorios, mejorando la calidad y precisión de las predicciones.

Cómo un preprocesamiento adecuado mejora la precisión y evita errores o sesgos (desviaciones que pueden alterar los resultados)

Un preprocesamiento adecuado es como ordenar y preparar los datos antes de entrenar un modelo. Cuando los datos están completos, organizados y equilibrados, el modelo aprende de forma más clara y efectiva. Así se evita que se confunda con datos faltantes, valores extremos o diferencias en formatos.

Por ejemplo, si hay registros duplicados, el modelo puede contar la misma información varias veces y aprender patrones falsos. Si faltan datos, no entenderá bien las relaciones. Si los datos están escritos de formas distintas, como “10 %” y “0.1” para un 10 %, el modelo puede confundirse al comparar.

Corregir sesgos también es fundamental. Si hay más datos de un grupo que de otro, el modelo puede favorecer a ese grupo. Detectar y equilibrar esto durante el preprocesamiento ayuda a que el modelo sea justo.

La precisión mejora directamente tras un buen preprocesamiento, porque el modelo trabaja con datos claros y sin errores, aprendiendo patrones reales que permiten hacer predicciones fiables y decisiones seguras.

Cómo trabajar de forma estructurada con los datos antes de usar técnicas más avanzadas

Trabajar estructuradamente con los datos es esencial para que el proyecto funcione bien. Esto implica una serie de pasos clave para preparar los datos correctamente.

Primero, exploramos los datos para entender qué contienen, cómo se distribuyen y qué relaciones hay entre variables. Se analizan distribuciones, valores atípicos y correlaciones para detectar problemas o patrones importantes.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Luego, limpiamos los datos, corrigiendo valores nulos, duplicados o errores que afecten la calidad. Por ejemplo, rellenamos huecos con valores representativos o eliminamos duplicados. También corregimos formatos incorrectos.

Después, transformamos los datos para que tengan formatos y escalas compatibles. Esto incluye normalizar, escalar y codificar variables de texto en números. Algunas transformaciones necesitan “aprender” cómo deben cambiar los datos solo con los datos de entrenamiento, y luego se aplican al conjunto de prueba para evitar que el modelo acceda a información que no debería durante el entrenamiento.

Este proceso no es siempre un paso a paso rígido. Según el algoritmo, el problema o la calidad de los datos, algunos pasos pueden cambiar de orden, aplicarse juntos o incluso omitirse. Cada paso es una herramienta que se adapta a cada caso, no una receta fija.

Luego, se revisa la selección y reducción de características para elegir las variables más importantes. Técnicas como el filtrado o PCA pueden ayudar, pero no siempre se usan. A veces eliminar valores atípicos o reducir variables puede hacer perder información útil, por eso se decide cuándo aplicarlas.

Finalmente, los datos se dividen en conjuntos de entrenamiento y prueba para asegurar que el modelo generalice y no memorice. El preprocesamiento es dinámico, ya que tras entrenar el modelo, se pueden probar otras limpiezas o transformaciones para optimizar resultados.

Qué herramientas ayudan en el preprocesamiento de los datos

Para el preprocesamiento usaremos herramientas clave que son base en casi todos los modelos y proyectos porque facilitan preparar, analizar y entender datos de forma eficiente.

NumPy es ideal para trabajar con arrays y operaciones matemáticas rápidas. Permite manejar grandes cantidades de datos numéricos y hacer cálculos complejos, base para preparar datos antes de procesamientos avanzados.

Pandas es esencial para manejar datos tabulares, similar a hojas de cálculo. Facilita detectar valores nulos, duplicados y transformar columnas para que tengan el formato adecuado. Es la herramienta para limpiar y organizar datos antes de entrenar.

Matplotlib ayuda a visualizar datos mediante gráficos que muestran distribuciones, relaciones y valores atípicos. Visualizar es clave para detectar problemas no evidentes solo con números.

Scikit-learn, además de sus modelos, incluye funciones para preprocesar datos: codificar variables, escalar, seleccionar características y crear pipelines que automatizan preparación y modelado, ahorrando tiempo y reduciendo errores.

Estas son herramientas básicas y habituales, aunque hay muchas otras según el proyecto, complejidad y entorno.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Estas herramientas básicas son las que se utilizan con más frecuencia, aunque existen muchas otras según el proyecto, la complejidad y el entorno de trabajo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Lección 2. Limpieza de datos detección y tratamiento de valores nulos duplicados y errores

Por qué es importante la limpieza de datos para garantizar la fiabilidad de los modelos

La limpieza de datos es un proceso imprescindible porque la calidad final del modelo depende directamente de la calidad de los datos que se le entregan. Datos con errores, valores faltantes o duplicados pueden introducir sesgos o ruido que afectan la capacidad del modelo para aprender patrones reales. Por ejemplo, un conjunto de datos con muchos valores erróneos puede hacer que el modelo dé predicciones inconsistentes o con baja precisión.

Además, la limpieza reduce el riesgo de que el modelo aprenda relaciones irrelevantes que solo están presentes por errores en los datos. Limpiar los datos también facilita que el proceso de entrenamiento sea más eficiente y estable, evitando problemas como valores extremos que pueden desestabilizar el aprendizaje o sesgos que favorecen ciertos grupos o clases de forma injusta.

Por todo esto, dedicar tiempo a una limpieza cuidadosa es fundamental para que el modelo pueda entrenarse con datos representativos y de calidad, y así lograr resultados fiables y robustos.

Qué son los valores nulos y cómo afectan a la calidad de los datos

Los valores nulos representan datos ausentes o no registrados, que aparecen como celdas vacías, "NaN" o con valores especiales según la fuente. Estos huecos generan incertidumbre para el modelo porque no sabe qué interpretar en esos casos, lo que puede afectar negativamente el aprendizaje.

Si se dejan tal cual, muchos algoritmos no pueden procesarlos correctamente y pueden generar errores o resultados erráticos. Por eso, identificar los valores nulos es el primer paso para decidir cómo tratarlos.

Las formas de tratar valores nulos varían según el contexto, se pueden eliminar filas o columnas con muchos datos faltantes, rellenar los huecos con medias, medianas o valores más representativos, o utilizar técnicas avanzadas como imputación basada en modelos estadísticos o de aprendizaje. Cada opción tiene ventajas y desventajas, y elegir la adecuada depende del tipo de datos, su volumen y la importancia de la variable para el modelo.

Un buen tratamiento de valores nulos mejora la calidad del dataset y permite que el modelo aproveche toda la información disponible sin sesgos derivados de los datos incompletos.

Cómo identificar y tratar los datos duplicados para evitar sesgos y resultados poco fiables

Los datos duplicados son registros repetidos que, si no se detectan y eliminan, pueden causar que el modelo le dé un peso excesivo a ciertos casos. Esto genera un sesgo en el aprendizaje, porque el modelo interpreta que esos patrones o resultados ocurren con mayor frecuencia de lo real.

Detectar duplicados implica buscar filas idénticas o casi idénticas, considerando todas o algunas columnas clave. No siempre es tan sencillo porque en ocasiones pueden existir registros similares pero no iguales, lo que requiere análisis más profundo.

Una vez identificados, los duplicados se eliminan o consolidan para que solo haya una única representación de esa información. Esto mejora la representatividad y la calidad del conjunto de datos, haciendo que el modelo aprenda patrones reales y no repetidos artificialmente.

En proyectos grandes, automatizar esta detección es clave para evitar que la duplicidad afecte la construcción del modelo, especialmente cuando se combinan datos de distintas fuentes o se realizan actualizaciones frecuentes.

Cómo detectar y corregir errores en los datos para mejorar su consistencia y precisión

Los errores en los datos pueden ser variados: formatos incorrectos (fechas mal escritas, números con caracteres extra), valores fuera de rango (edad negativa, precios imposibles), inconsistencias lógicas (datos contradictorios entre columnas), o errores humanos y de entrada.

Detectar estos errores requiere realizar análisis exploratorios, revisar distribuciones, comprobar reglas de negocio y detectar valores que no tienen sentido. Herramientas como la visualización gráfica o estadísticas resumen son útiles para identificar valores atípicos o inconsistentes.

Corregir estos errores puede implicar transformar formatos para unificar, reemplazar valores fuera de rango, validar datos cruzándolos con otras fuentes o, en algunos casos, eliminar registros que no pueden corregirse. Esta corrección mejora la calidad y coherencia del dataset, lo que repercute directamente en la precisión y robustez del modelo.

Mantener la consistencia evita que el modelo aprenda patrones erróneos o contradicciones, y facilita interpretaciones claras y fiables de los resultados.

Qué herramientas permiten realizar estas tareas de limpieza de forma eficiente y segura

Existen muchas herramientas diseñadas para facilitar y automatizar la limpieza de datos, garantizando eficiencia y minimizando errores humanos. Aunque hay diversas opciones, en nuestro

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



caso utilizaremos principalmente librerías de Python como Pandas, que ofrecen funciones muy prácticas para detectar valores nulos (`isna()`, `fillna()`), identificar duplicados (`duplicated()`, `drop_duplicates()`) y manejar datos únicos (`unique()`).

Estas funciones permiten realizar operaciones precisas y eficientes para limpiar los datos, desde detectar y tratar valores faltantes hasta eliminar registros repetidos que podrían sesgar el modelo.

Estas son las principales herramientas que emplearemos para asegurar que el proceso de limpieza sea claro, reproducible y efectivo, aunque existen muchas otras según la complejidad y necesidades del proyecto.

Lección 3. Visualización exploratoria distribuciones correlaciones y detección de problemas

Por qué es importante la visualización para entender los datos antes de entrenar modelos

La visualización es una herramienta fundamental para comprender los datos antes de aplicar cualquier modelo. Representar la información gráficamente nos permite detectar patrones, tendencias o problemas que no se aprecian con simples tablas o números. Esta comprensión previa ayuda a tomar decisiones informadas sobre qué técnicas de preprocesamiento aplicar y cómo ajustar los modelos para obtener mejores resultados.

Qué muestran las distribuciones y cómo ayudan a detectar patrones

La distribución de una variable describe cómo se organizan sus valores dentro del conjunto de datos. Entender la distribución es fundamental porque muchos algoritmos de aprendizaje automático asumen ciertos comportamientos estadísticos, y la forma de la distribución puede influir en la calidad del modelo.


Tipos principales de distribuciones que podemos encontrar

- **Distribución normal (gaussiana):** Es la más conocida y común, con forma de campana simétrica. La mayoría de los valores se concentran alrededor de la media y la probabilidad disminuye hacia los extremos. Muchos modelos funcionan mejor cuando las variables se acercan a esta distribución porque representa un comportamiento “esperado” y equilibrado.
- **Distribución sesgada (asimétrica):** Ocurre cuando los datos se “desplazan” hacia un lado, formando una cola más larga en la derecha (sesgo positivo) o en la izquierda (sesgo negativo). Esto puede hacer que algunos valores extremos tengan más peso y afectar la estabilidad del modelo. Es común en variables económicas como ingresos o precios.
- **Distribución uniforme:** Los datos están distribuidos de forma homogénea a lo largo de un rango, sin concentrarse en ningún valor específico. Esto puede indicar que no hay un patrón claro o que la variable tiene valores igualmente probables.
- **Distribución multimodal:** Presenta varios picos o modos, lo que indica que la variable puede estar formada por diferentes subgrupos o poblaciones mezcladas. Por ejemplo, la distribución de alturas en una población que combina niños y adultos puede ser multimodal.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- **Distribución discreta:** Datos que toman valores concretos y separados, como el número de visitas o la cantidad de productos comprados. La forma de la distribución discreta puede variar mucho y afecta cómo se modelan estas variables.



En esta imagen vemos cuatro gráficos que muestran diferentes tipos de distribuciones de datos. Cada gráfico combina un **histograma** con una **curva de densidad** para facilitar la comprensión.

Histograma: Son las barras grises que ves. Muestran cuántos datos hay en cada rango o "bin". Cuanto más alta es una barra, más valores hay en ese rango.

Curva de densidad: Es la línea negra suave que recorre las barras. Representa la forma general de la distribución, mostrando cómo se "extienden" los datos de forma continua. Nos ayuda a ver patrones que no siempre se ven con el histograma solo.

Primera imagen (arriba izquierda) — Distribución normal (gaussiana): La forma clásica de campana simétrica. La mayoría de los datos se agrupan alrededor del centro (la media) y disminuyen

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




gradualmente hacia los extremos. Esta es la distribución “ideal” que muchos modelos esperan para funcionar bien.

Segunda imagen (arriba derecha) — Distribución sesgada a la derecha: Aquí la curva está desplazada hacia la izquierda, con una cola larga que se extiende hacia valores altos a la derecha. Esto indica que hay pocos valores muy grandes que pueden influir mucho en el modelo si no se tratan bien.

Tercera imagen (abajo izquierda) — Distribución multimodal: Se observan dos picos o “modos” en la curva, lo que indica que los datos provienen de dos grupos diferentes. Esto puede significar que estamos mezclando poblaciones o situaciones distintas que podrían necesitar tratamiento separado.

Cuarta imagen (abajo derecha) — Distribución uniforme: La curva es bastante plana, y las barras tienen alturas similares. Esto indica que los datos están distribuidos de manera casi igual en todo el rango, sin un valor o rango que predomine.



En este gráfico vemos la distribución del número de llamadas recibidas en un centro de atención durante un período determinado.

Las **barras grises** representan la frecuencia de cada número de llamadas. Por ejemplo, la barra sobre el número 3 indica cuántas veces exactamente se recibieron 3 llamadas. Como los valores son discretos y enteros, cada barra corresponde a un valor específico y no hay valores intermedios entre ellos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



La **línea azul** es una curva de densidad que suaviza la información de las barras para mostrar la tendencia general de la distribución. Aunque en variables discretas la curva no es tan precisa como en variables continuas, ayuda a visualizar cómo se agrupan los datos y si existen valores más comunes o agrupaciones.

Podemos observar que los números 2, 3 y 4 son los que más frecuencia tienen, indicando que recibir esa cantidad de llamadas es lo más habitual en este centro.

Este tipo de análisis es útil para entender variables que representan conteos o categorías ordenadas. Saber cómo se distribuyen los valores ayuda a decidir si es necesario agrupar ciertos valores, transformar la variable o aplicar técnicas específicas en el modelado.

Importancia del tipo de distribución y cómo actuar según cada caso

Conocer el tipo de distribución que presentan las variables en un conjunto de datos es fundamental porque influye directamente en cómo se deben preparar los datos y qué modelos serán más efectivos.

Por ejemplo, cuando una variable tiene una distribución muy sesgada —es decir, que sus valores se concentran en un extremo y se extienden hacia el otro—, esto puede dificultar que el modelo aprenda patrones claros. En estos casos, aplicar transformaciones matemáticas como el logaritmo, la raíz cuadrada o la transformación Box-Cox ayuda a equilibrar la distribución, haciéndola más simétrica y facilitando el aprendizaje.

Si la distribución es multimodal, con varios picos que indican la existencia de subgrupos o poblaciones distintas, es recomendable segmentar los datos según estos grupos o utilizar modelos que puedan capturar esta diversidad, como modelos basados en clústeres o ensamblajes.

Cuando la distribución es uniforme, donde los valores están distribuidos de manera homogénea sin concentrarse en rangos específicos, puede ser necesario realizar ingeniería de características para extraer información significativa que no es evidente solo con la distribución original. Esto puede incluir crear variables derivadas o combinar atributos para mejorar la capacidad predictiva.

Además, en todos los casos, entender la distribución ayuda a anticipar problemas como valores atípicos, la necesidad de normalización o escalado, y a seleccionar técnicas de modelado adecuadas, ya sea modelos lineales, no lineales, o basados en árboles, entre otros.

Valores atípicos (outliers)

Los valores atípicos o *outliers* son observaciones que se encuentran muy alejadas del resto de datos en una variable. Estos valores pueden ser muy diferentes en magnitud o en comportamiento respecto a la mayoría de la muestra, y pueden afectar negativamente el entrenamiento y el rendimiento de los modelos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




¿Dónde se pueden detectar los valores atípicos?

Aunque algunos valores atípicos pueden verse ya en los histogramas cuando muestran barras muy separadas o colas largas, la forma más clara y precisa de detectar outliers es a través de diagramas de caja o *boxplots*.

¿Qué es un boxplot y cómo ayuda?

Un boxplot es un gráfico que resume la distribución de una variable mostrando información clave como la mediana, los cuartiles y los valores extremos. En él, una caja representa el rango intercuartílico, que contiene la mitad central de los datos, mientras que una línea dentro de la caja señala la mediana, el valor central. Desde la caja se extienden los “bigotes”, que llegan hasta un límite definido, normalmente 1.5 veces el rango intercuartílico, y cualquier punto que quede fuera de estos bigotes se considera un valor atípico o outlier. Este tipo de gráfico facilita visualizar rápidamente la dispersión y detectar valores que se alejan significativamente del resto.



- La **caja gris** representa el rango donde está el 50 % central de los datos, entre el primer cuartil (Q1) y el tercer cuartil (Q3).
- La **línea negra dentro de la caja** marca la mediana, que divide los datos en dos partes iguales.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- Los **bigotes** se extienden hasta los valores más extremos dentro de un rango considerado “normal” ($Q1 - 1.5 \times IQR$ y $Q3 + 1.5 \times IQR$).
- Los **puntos fuera de los bigotes** (los que están arriba y abajo) son los valores atípicos o *outliers*. En este caso, se ven varios puntos aislados, que indican observaciones muy alejadas del resto.

Este gráfico ayuda a identificar rápidamente si hay datos extremos que podrían afectar el modelo y que merecen atención o tratamiento especial.

¿Por qué es importante detectar y tratar valores atípicos?

Detectar y tratar los valores atípicos es fundamental porque estos pueden tener diversas causas y efectos en el análisis de datos y en la construcción de modelos. En algunos casos, los valores atípicos son el resultado de errores de medición o entrada, es decir, datos incorrectos que deben ser corregidos o eliminados para evitar que contaminen el conjunto de datos. En otras situaciones, estos valores extremos pueden reflejar la variabilidad natural del fenómeno que estamos estudiando y, por tanto, aportar información valiosa sobre casos excepcionales o poco frecuentes. Además, los valores atípicos pueden indicar que el conjunto de datos está mezclando diferentes poblaciones o grupos, lo que sugiere la necesidad de segmentar o tratar estas subpoblaciones por separado.

Si no se identifican y gestionan correctamente, los valores atípicos pueden distorsionar el modelo, haciendo que aprenda patrones erróneos o poco representativos, lo que afecta la capacidad predictiva y la generalización. También pueden influir negativamente en métricas estadísticas como la media o la desviación estándar, que son sensibles a valores extremos, dando una impresión equivocada sobre el comportamiento general de los datos. Por último, la presencia de outliers puede causar inestabilidad durante el proceso de entrenamiento, dificultando la convergencia y haciendo que el modelo sea menos robusto. Por eso, es esencial analizar con detenimiento estos valores para decidir cómo tratarlos según el contexto y los objetivos del proyecto.

¿Qué hacer al detectar valores atípicos?

Al detectar valores atípicos, el primer paso es verificar si se deben a errores, revisando su origen para corregirlos o eliminarlos si es necesario, evitando así que datos incorrectos afecten el análisis. Luego, es importante evaluar la relevancia de esos outliers, considerando si aportan información valiosa sobre casos excepcionales o si simplemente representan ruido que puede distorsionar el modelo. En función de esta valoración, se pueden aplicar técnicas robustas que utilicen métricas menos sensibles a valores extremos, como la mediana, o emplear modelos diseñados para manejar outliers de forma eficaz. Además, transformar los datos mediante escalados o funciones matemáticas puede ayudar a reducir la influencia de estos valores extremos, favoreciendo un aprendizaje más estable y preciso. Cada una de estas acciones debe adaptarse al contexto del problema y a las características específicas del conjunto de datos.

Relaciones entre variables y su impacto en el modelo

En un conjunto de datos, las características no están aisladas entre sí. Muchas veces existe algún tipo de relación entre ellas, como si una depende de la otra o si ambas se mueven de forma parecida o contraria. Entender estas relaciones ayuda a descubrir patrones que no siempre son evidentes y permite preparar mejor los datos antes de construir cualquier modelo de aprendizaje automático. Además, conocer cómo interactúan las características entre sí evita que la información se repita o se confunda, lo que puede afectar negativamente la calidad de los resultados.

Por ejemplo, si tenemos un conjunto de datos con las características altura y peso de personas, es común que estas dos estén relacionadas. En general, a mayor altura, mayor peso, lo que se traduce en una correlación positiva. Esto no quiere decir que la altura cause un cambio directo en el peso, pero sí que ambas comparten una tendencia común. Si esta relación no se tiene en cuenta en un modelo, podría generar resultados poco fiables o dar más importancia de la necesaria a una característica duplicada.

La correlación es una medida que nos ayuda a detectar estas relaciones de forma cuantitativa. Aunque no indica si una característica causa cambios en otra, sí nos da pistas de cuánto se parecen o se oponen en su comportamiento. Por eso, estudiar las correlaciones forma parte esencial de cualquier análisis exploratorio de datos. Esto permite ver más allá de los valores individuales y entender cómo se conectan las distintas piezas del conjunto.

Al tener una idea clara de las correlaciones, podemos tomar decisiones más seguras sobre qué características conservar, transformar o eliminar. También nos ayuda a evitar problemas como la multicolinealidad, que puede complicar los modelos de regresión o hacer que ciertos algoritmos se comporten de forma inestable. Así, el análisis de correlación es clave para construir modelos sólidos, fiables y con predicciones más acertadas.

Qué es la correlación y su importancia

La correlación muestra cómo dos características numéricas se relacionan y cómo cambian juntas. Indica si una tiende a subir o bajar cuando la otra lo hace o si no tienen ninguna relación entre ellas. Cuando la correlación es positiva, ambas características se mueven en la misma dirección. Por ejemplo, la cantidad de horas de ejercicio semanal y la energía diaria que se siente suelen subir juntas, reflejando una relación positiva. Una correlación negativa significa que cuando una sube, la otra baja. Por ejemplo, el tiempo de espera en una tienda y la satisfacción del cliente: cuanto más tiempo espera una persona, menos satisfecho suele estar. Si la correlación es nula, no existe relación aparente, como puede pasar entre el número de letras del nombre de una persona y la distancia que recorre cada día para ir a trabajar.

Conocer la correlación es importante porque ayuda a entender cómo está organizada la información en un conjunto de datos. Permite identificar duplicidades de información o patrones que se repiten, lo que puede llevar a modelos de aprendizaje automático más estables y con mejores predicciones. Además, si las características tienen una relación muy fuerte, se corre el riesgo de que el modelo se base en información repetida o que sobrevalore ciertas relaciones, algo que puede distorsionar los resultados finales.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



La correlación también ayuda a decidir si es necesario transformar los datos o eliminarlos para evitar errores. Así, antes de entrenar un modelo, revisar la correlación entre las características garantiza que se construya con información útil, completa y sin sesgos innecesarios.

Cómo se calcula y qué significa su valor

El cálculo de la correlación se basa en distintos coeficientes que permiten expresar la fuerza y la dirección de la relación entre dos características. El más utilizado es el coeficiente de Pearson, que mide la relación lineal y funciona bien cuando los datos siguen distribuciones normales o casi simétricas. Su valor varía de -1 a 1, donde valores cercanos a 1 indican una relación positiva fuerte, como podría ser la relación entre la cantidad de ejercicio físico y la capacidad cardiovascular. Valores cercanos a -1 señalan una relación negativa fuerte, como la relación entre el número de días de ausencia y la productividad laboral. Cuando el valor está cerca de 0, no hay relación lineal aparente.

Sin embargo, cuando las distribuciones de las características no son normales o muestran relaciones que no son lineales, el coeficiente de Pearson puede ser engañoso. Para esos casos se utiliza el coeficiente de Spearman, que mide la correlación en función de los rangos y no de los valores exactos. Este enfoque es más robusto ante valores extremos y mejor para detectar relaciones monótonas, donde una característica tiende a subir cuando la otra sube o a bajar cuando la otra baja, aunque no lo haga de manera proporcional. Por ejemplo, el nivel de estrés y la productividad pueden tener una relación que no es recta, pero que muestra una tendencia clara de que cuando sube uno, baja el otro.

Además, existen otros coeficientes como el de Kendall, que también se basa en el orden de los datos y es útil cuando hay muchos empates o datos con posiciones similares.

Es importante recalcar que la elección entre Pearson y Spearman no depende solo de la relación entre las características, sino también de sus distribuciones. Cuando las distribuciones son normales y la relación parece lineal, Pearson suele ser la mejor opción. Si las distribuciones son muy asimétricas o hay valores atípicos, Spearman se adapta mejor y ofrece resultados más fiables. Por ejemplo, si comparamos la antigüedad en la empresa con el nivel de confianza, puede no ser una relación lineal, pero Spearman capturará si en general más antigüedad significa más confianza.

Por eso, cuando las características tienen distribuciones distintas (una normal y otra muy sesgada), Spearman es una elección más segura, ya que no depende tanto de la forma exacta de las distribuciones y detecta relaciones que van más allá de la linealidad.

Así, revisar las distribuciones antes de elegir qué coeficiente usar garantiza que el análisis sea preciso y que el modelo final trabaje con datos coherentes y fiables.

Tipos de correlación y cómo influyen en el análisis

La correlación puede clasificarse en tres tipos principales según el valor del coeficiente y la dirección de la relación entre dos características. Estos tipos ayudan a entender qué tan estrecha es la relación y cómo se comportan las características entre sí.

Cuando la correlación es positiva, significa que ambas características tienden a moverse en la misma dirección. Por ejemplo, el número de horas de práctica deportiva y el nivel de resistencia física suelen

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




subir juntos, mostrando un patrón de crecimiento compartido. Este tipo de correlación puede indicar que las dos características aportan información parecida, lo que podría llevar a duplicar datos en un modelo si no se revisa antes.

La correlación negativa aparece cuando una característica sube mientras la otra baja. Por ejemplo, el tiempo de espera para ser atendido en un servicio y el nivel de satisfacción del cliente muestran una relación inversa: a mayor espera, menor satisfacción. Este tipo de relación puede ser útil para entender qué características tienen un efecto compensatorio y cómo podría impactar en las predicciones del modelo.

Por último, existe la correlación nula, donde no se observa ningún patrón claro. Esto sucede cuando las características no tienen ninguna relación aparente, como el número de zapatos que tiene una persona y la cantidad de horas que duerme al día. Detectar la falta de correlación es igual de importante, ya que permite identificar qué características realmente no tienen conexión y no deberían influir en la construcción del modelo.

Estos tipos de correlación son fundamentales en el análisis porque permiten saber si conviene mantener o ajustar las características antes de usarlas en un modelo. Así se evita dar más peso a relaciones poco relevantes o dejar que datos duplicados distorsionen los resultados. Además, conocer el tipo de correlación también ayuda a seleccionar el mejor enfoque para visualizar y comparar las características, mejorando la calidad del aprendizaje y la interpretación de los resultados finales.



En este ejemplo se muestran tanto correlaciones positivas fuertes como negativas fuertes, y también un ejemplo de características sin relación clara.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- `actividad_fisica` y `salud_general` tienen una correlación positiva muy alta (valor cercano a 1), lo que indica que cuando una sube, la otra también lo hace casi de forma directa, aunque con un poco de variabilidad natural.
- `actividad_fisica` y `nivel_estres` muestran una relación negativa fuerte (valor cercano a -1), lo que significa que cuando una sube, la otra baja casi de forma proporcional.
- `num_hobbies` no tiene correlaciones fuertes con las otras características, lo que indica que sus valores no están relacionados directamente con el resto.


Este ejemplo ilustra cómo los coeficientes cercanos a 1 o -1 reflejan relaciones claras y consistentes, mientras que valores cercanos a 0 muestran independencia. Estas diferencias son esenciales para decidir qué características pueden aportar información útil y cuáles podrían complicar el modelo o no añadir valor real.

Por ejemplo, la fuerte correlación positiva entre `actividad_fisica` y `salud_general` sugiere que probablemente aportan información similar. Mantener ambas en un modelo de regresión podría generar multicolinealidad, haciendo que los coeficientes sean inestables o difíciles de interpretar. En estos casos, podríamos plantear quedarnos solo con una de ellas o combinarlas en una nueva variable que resuma la información compartida.

Por otro lado, `nivel_estres` tiene una correlación negativa fuerte con `actividad_fisica`, lo que también puede aportar información importante pero de forma opuesta. Aquí conviene mantenerla porque ofrece un punto de vista complementario: aporta valor porque representa un patrón claro, aunque contrario.

Finalmente, `num_hobbies` no tiene correlaciones fuertes con ninguna otra característica. Esta independencia puede ser útil para añadir información única al modelo y enriquecer las predicciones. Por eso, aunque no tenga relación con las otras características, podría ser interesante mantenerla.

Estos resultados muestran que tener correlaciones fuertes no significa que debamos eliminar características automáticamente. Siempre dependerá de la situación y del objetivo del modelo. A veces, la información redundante no afecta o incluso puede ayudar en modelos más complejos. Por eso, la mejor forma de decidir qué características mantener o quitar es hacer pruebas y comparar cómo cambian las métricas de rendimiento. Así se puede ver si la eliminación de características correlacionadas mejora la precisión y la estabilidad o si, por el contrario, se pierde información valiosa. Ajustar el número de características según las correlaciones y la utilidad real de cada una permite construir modelos más claros, interpretables y ajustados a las necesidades de cada problema.



En este ejemplo con cuatro características y sus correlaciones calculadas con el método de Spearman.

- **horas_estudio** y **mejora_nota** muestran una relación monótona positiva (cercana a 1). Aunque no es estrictamente lineal, se ve que más horas de estudio suelen implicar mejores notas, con un patrón general que Spearman detecta bien.
- **horas_estudio** y **nivel_cansancio** presentan una relación negativa fuerte. A medida que suben las horas de estudio, baja el nivel de cansancio, pero de forma no lineal. Aun así, Spearman capta esta relación porque mide si una característica tiende a subir o bajar de manera consistente, aunque no lo haga en proporción directa o con una línea recta.
- **num_amistades** no tiene relación clara con las otras características y por eso muestra correlaciones cercanas a 0, confirmando que no existe una tendencia general.

Este ejemplo demuestra que el coeficiente de Spearman detecta relaciones de orden o tendencia, aunque no sean lineales. Es decir, ve si una característica sube o baja en conjunto con la otra, aunque la relación siga una curva o tenga valores atípicos que desvíen el cálculo de una recta perfecta. Por eso, aunque los gráficos y los valores numéricos en los mapas de calor parezcan similares a los de Pearson, los resultados de Spearman permiten ver patrones reales en datos donde la forma de la relación no es tan clara o no sigue una línea recta.

Estos resultados ayudan a decidir si conviene mantener o quitar características antes de entrenar un modelo. Aunque la correlación sea fuerte, no siempre significa que una característica deba

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



eliminarse. Puede aportar información útil o complementar el análisis. Sin embargo, si la relación es tan fuerte que genera duplicidad o dificulta la interpretación del modelo, conviene agruparlas o quedarse solo con la que más valor aporta. La decisión final depende de la situación, del objetivo del análisis y de las pruebas que confirmen si la reducción mejora la precisión y estabilidad del modelo o si elimina información relevante.

Correlación de las características con el objetivo y su utilidad


Además de ver cómo se relacionan las características entre sí, también es muy útil calcular la correlación directa de cada característica con la variable objetivo. Esta correlación nos dice qué tan fuerte es la relación de cada característica con el resultado que queremos predecir o explicar, ayudándonos a identificar cuáles son más relevantes para el modelo y cuáles no aportan valor real.

A diferencia de la matriz de correlaciones completa, que nos muestra duplicidades o relaciones internas entre las características, la correlación con el objetivo nos ayuda a ver si una característica tiene potencial para mejorar la precisión del modelo o si simplemente es ruido. Por ejemplo, si una característica tiene una correlación cercana a 1 o -1 con el objetivo, es probable que sea importante incluirla en el modelo. Si su correlación es cercana a 0, puede no aportar información clave.

Al elegir el tipo de correlación a usar, es clave tener en cuenta la distribución de las características y la naturaleza de la relación que puedan tener con el objetivo. Si la relación es lineal y las distribuciones de las características y del objetivo son normales o casi simétricas, el coeficiente de Pearson es el más adecuado. Sin embargo, cuando la relación no es lineal pero sigue una tendencia general (por ejemplo, una característica que siempre sube o baja con la otra aunque no sea a ritmo constante), el coeficiente de Spearman funciona mejor porque mide cómo se ordenan los valores, sin depender de que sigan una línea recta.

Esto significa que si los datos son muy asimétricos, tienen muchos valores atípicos o siguen una forma curva, Spearman es más fiable y muestra mejor la relación real. En cambio, Pearson podría subestimar o no detectar la relación en esos casos. Por eso, para asegurar la mejor comprensión y la selección adecuada de las características, conviene revisar las distribuciones de los datos y decidir qué coeficiente se adapta mejor a la naturaleza de cada característica.

Al calcular estas correlaciones, se obtiene una lista clara con la fuerza y la dirección de cada relación. Estos valores sirven como guía para priorizar y probar cuáles características realmente ayudan al modelo y cuáles podrían descartarse o transformarse. Así, se consigue un modelo más sencillo, interpretativo y ajustado a la realidad del problema.



Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Imagina que quieres predecir el rendimiento físico de un grupo de personas a partir de su tiempo de entrenamiento semanal y su consumo de calorías diarias. Ambas características tienen distribuciones normales y la relación parece seguir una línea recta clara. Usando Pearson, ves que la correlación entre el tiempo de entrenamiento y el rendimiento es de 0.85, mientras que la del consumo de calorías con el rendimiento es de 0.3. Esto indica que el tiempo de entrenamiento tiene una relación más fuerte y directa con el objetivo que el consumo de calorías, y se puede priorizar en el modelo.

Ahora supón que analizas cómo influye el nivel de motivación en la productividad de los empleados, pero la relación no es lineal: la productividad sube rápidamente con la motivación al inicio, pero luego se estabiliza. Aquí, aunque los datos no siguen una línea recta, usando Spearman obtienes una correlación de 0.7, lo que refleja bien la tendencia general de que más motivación suele llevar a mayor productividad. Pearson, en cambio, podría no ver esta relación si no es estrictamente lineal y daría un valor más bajo.

Estos dos ejemplos muestran cómo elegir Pearson o Spearman depende de la distribución y la forma de la relación entre las características y el objetivo, y cómo esto ayuda a decidir qué características usar o transformar para construir modelos más ajustados y fiables.

Cómo detectar problemas en los datos mediante gráficos y análisis visuales

La visualización de los datos no solo permite ver distribuciones y relaciones, también ayuda a identificar problemas que pueden afectar el rendimiento del modelo. Dos aspectos importantes son los valores faltantes y el desequilibrio en las clases de la variable objetivo.

Valores faltantes y su impacto


Además de ver los valores faltantes con métodos directos como `isnull()` o `isna()`, los gráficos permiten entender de forma visual dónde se encuentran estos problemas y cómo afectan al conjunto de datos. Un gráfico de barras, como el que muestra el porcentaje de valores faltantes por columna, deja claro qué columnas están más afectadas. En el ejemplo, se ve que `ingresos` y `horas_trabajo` tienen algunos valores vacíos, mientras que `edad` está completa.

Cuando los datos faltantes están concentrados en unas pocas columnas, se pueden tratar de forma dirigida, por ejemplo, imputando los valores con la media o eliminando la columna si no aporta mucho al análisis. Si los valores faltantes están dispersos por todo el conjunto, conviene un enfoque más cuidadoso para no perder información valiosa.

Detectar visualmente estos valores faltantes complementa lo que se ve al revisar los resultados de `isnull().sum()`, y ayuda a decidir cómo manejar la situación antes de construir los modelos. Es importante porque los modelos de aprendizaje automático suelen requerir datos completos para entrenar bien y evitar sesgos. Así, ver los faltantes gráficamente permite entender mejor su magnitud y tomar decisiones más informadas para garantizar la calidad del análisis.


Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)





Desequilibrio de clases en la variable objetivo

Cuando la variable objetivo es categórica, es importante ver si todas las clases tienen la misma cantidad de registros o si algunas están sobrerrepresentadas. Este desequilibrio puede causar que el modelo aprenda solo de la clase mayoritaria y no funcione bien para las demás, generando resultados poco fiables.



En el gráfico circular que se ve aquí, las proporciones de cada clase permiten ver de forma clara cómo están distribuidos los datos. Por ejemplo, la Clase A tiene la mayoría de los registros, mientras que las Clases B y C apenas suman una pequeña parte.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




Este tipo de visualización ayuda a detectar si existe un desequilibrio fuerte y a decidir cómo gestionarlo. Dependiendo del caso, se puede usar un muestreo para equilibrar los datos o ajustar las métricas de evaluación. Entre las técnicas más usadas están el sobremuestreo de las clases minoritarias, que consiste en generar copias o crear ejemplos sintéticos usando métodos como SMOTE o ADASYN. Estas técnicas añaden diversidad a la clase minoritaria y reducen el riesgo de que el modelo la ignore. También se usa el submuestreo de la clase mayoritaria, que implica eliminar registros de la clase más frecuente para equilibrar la proporción, aunque con el riesgo de perder información.

Otra opción es ajustar el entrenamiento del modelo para que tenga en cuenta el desequilibrio sin cambiar los datos. Por ejemplo, en modelos de clasificación, se pueden usar pesos en la función de coste que den más importancia a la clase minoritaria o a las clases con menos ejemplos. Además, se suelen usar métricas que midan bien el rendimiento global, como el f1-score o la balanced accuracy, que tienen en cuenta la precisión de cada clase de forma más justa.

No siempre es necesario equilibrar los datos. Si la clase minoritaria es la que más interesa (como detectar fraude o anomalías), puede ser mejor ajustar solo la métrica y mantener el desequilibrio, ya que refleja la realidad del problema. Por eso es importante ver primero la magnitud del desequilibrio y hacer pruebas para ver qué técnica funciona mejor según los objetivos del análisis y la calidad final que se espera del modelo.

Desequilibrio de clases en las características

Una característica categórica puede tener decenas de valores distintos, pero a veces la mayoría de los registros se concentran en solo unas pocas categorías mientras otras apenas aparecen. Este desequilibrio hace que el modelo apenas reciba ejemplos de las categorías raras y su efecto se vuelva inestable o irrelevante en la predicción.



En el gráfico se observa la distribución de una característica con cinco categorías. Las barras muestran cuántos registros tiene cada una. A y B dominan el conjunto con más de doscientas observaciones entre ambas, mientras que C, D y E apenas suman una treintena. Esta diferencia tan

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



grande indica que el modelo casi no tendrá datos para aprender el comportamiento de las categorías minoritarias.

Cuando una característica categórica presenta un desequilibrio muy acusado, con unas pocas categorías dominando la mayoría de los registros y otras apareciendo apenas en unos pocos casos, el modelo no recibe información suficiente para aprender el comportamiento de los valores raros. Esto provoca dos problemas principales: por un lado, el modelo tiende a ignorar o predecir mal las categorías minoritarias; por otro, cualquier métrica global de rendimiento se ve inflada por el acierto en la clase mayoritaria, ocultando errores importantes en los casos raros.

Tratar este desequilibrio —por ejemplo, agrupando las categorías poco frecuentes en un valor “Otros” o aplicando técnicas de codificación que suavicen su peso— garantiza que el modelo disponga de ejemplos suficientes de cada grupo y tome decisiones más justas y precisas para todas las categorías, no solo para las mayoritarias. No siempre es necesario equilibrar: si las minoritarias representan casos críticos (como un tipo de error grave), puede interesar mantenerlas tal cual. Por eso conviene visualizar primero la distribución, valorar el impacto de cada estrategia y probar varias opciones para encontrar la que ofrezca un modelo más estable y útil.

Lección 4. Transformación de datos normalización codificación y escalado

Por qué es importante transformar los datos antes de entrenar modelos de aprendizaje automático

Cuando se entrena un modelo de aprendizaje automático, es habitual que las características tengan escalas muy diferentes. Por ejemplo, algunas variables pueden medir ingresos en miles o millones, mientras otras registran la edad en años o la puntuación de un examen de 0 a 10. Esta diferencia tan grande provoca que el modelo dé más peso a las variables con valores más altos, aunque no sean necesariamente las más relevantes, lo que puede afectar la calidad y estabilidad del entrenamiento.

Además, muchos algoritmos funcionan mejor si las características tienen distribuciones más uniformes y menos sesgadas. Cuando los datos tienen distribuciones muy asimétricas o incluyen valores extremos, los modelos pueden entrenar más lento, cometer más errores o incluso fallar al predecir datos nuevos.

Por otra parte, muchas variables importantes son categóricas, como colores, niveles educativos o tipos de productos, y los algoritmos no pueden interpretarlas directamente si no están en formato numérico. Por eso es necesario aplicar una transformación adicional llamada codificación, que convierte estos valores en números para que los modelos puedan procesarlos correctamente.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Estas transformaciones permiten que cada variable aporte información de forma justa y equilibrada. Incluyen la normalización, que ajusta los valores para que estén en un mismo rango; la estandarización, que asegura que cada característica tenga una media cercana a cero y una dispersión estándar común; y la codificación de variables categóricas, que permite incorporar información no numérica valiosa.

Transformaciones logarítmicas y de potencia

Cuando las variables numéricas tienen distribuciones muy asimétricas o incluyen valores extremos, también conviene aplicar transformaciones logarítmicas o de potencia. La transformación logarítmica convierte los valores en su logaritmo, lo que acerca los valores extremos al rango principal y logra una distribución más simétrica y una varianza más estable. Las transformaciones de potencia, como la raíz cuadrada o Box-Cox, ayudan a ajustar la distribución y a reducir la influencia de los datos más alejados, encontrando el mejor ajuste posible.

Aplicar estas transformaciones hace que el entrenamiento sea más rápido, las predicciones más precisas y estables, y se reduzca el riesgo de sesgos. Esto garantiza resultados más fiables y modelos que generalizan mejor a datos reales. Además, se pueden automatizar fácilmente mediante herramientas como los pipelines, que permiten reproducir todo el proceso desde la limpieza inicial hasta el entrenamiento final, facilitando mucho el trabajo.

Es importante tener en cuenta que no siempre es necesario aplicar estas transformaciones. Son útiles cuando los datos tienen distribuciones muy sesgadas o valores extremos que afectan al rendimiento, pero si las distribuciones ya son equilibradas, podrían no aportar mejoras y hasta complicar el análisis. Por eso, conviene revisar siempre su impacto de forma práctica y decidir si realmente aportan valor al modelo.

Qué significa normalizar los datos y cómo mejora la comparabilidad entre variables

La normalización es un proceso que ajusta las escalas de las variables y las hace comparables entre sí. Sirve para que, aunque las variables midan cosas distintas o tengan unidades diferentes, podamos analizarlas y compararlas sin que unas influyan más que otras solo por tener valores más grandes. Así, todas las variables aportan información de forma justa y se evita que la magnitud de los números determine su importancia.

Existen varias formas de normalización. Una es la normalización Min-Max, que adapta los valores para que estén dentro de un rango fijo, como de cero a uno. Esto se usa cuando queremos que todas las variables tengan la misma escala, por ejemplo al comparar la altura y el peso de personas, que tienen medidas distintas y que, al llevarlas a la misma escala, facilita el análisis.

También está la estandarización o Z-score, que aunque a veces se considera un tipo de normalización, en realidad va un paso más allá. Ajusta los datos para que tengan una media de cero y una dispersión uniforme, mostrando cuánto se alejan o se acercan a la media. Esto es útil cuando queremos comparar variables que tienen distribuciones distintas y ver su relación con respecto a esa media.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Además, existe el escalado robusto, que se usa cuando hay valores muy altos o muy bajos que distorsionan los datos. Ajusta los valores usando la mediana y los rangos centrales, evitando que esos valores extremos tengan tanto peso y distorsionen el análisis.

Por ejemplo, en un conjunto de datos con información sobre la altura de personas y sus salarios, la altura puede ir de 150 a 200 centímetros y el salario de 0 a 5000 euros. Sin normalizar, el salario pesaría mucho más en cualquier comparación, aunque no sea lo más importante. Al normalizar, la altura y el salario se comparan de forma equilibrada y se puede ver mejor cómo influyen en el análisis.

Qué implica estandarizar y escalar los datos y cómo ayuda a mejorar la eficiencia y estabilidad de los modelos

Antes vimos que transformar los datos antes de entrenar modelos de aprendizaje automático es clave para que las variables tengan la misma importancia y el modelo pueda aprender patrones de forma más equilibrada. También hablamos de las transformaciones logarítmicas y de potencia, que corrigen distribuciones asimétricas y reducen la influencia de valores extremos. Y vimos cómo la normalización ajusta las escalas de las variables para que estén en el mismo rango y así mejorar la comparabilidad entre ellas.

Ahora, estandarizar y escalar los datos es otro paso esencial. Estas técnicas también ajustan los valores de las variables, pero lo hacen para que no solo tengan la misma escala, sino también la misma media y una dispersión uniforme. La normalización adapta los datos a un rango fijo, como de cero a uno, mientras que la estandarización transforma los datos para que su media sea cero y su dispersión estándar sea constante. Escalar, en general, es un término que incluye tanto la normalización como la estandarización y otras formas de ajustar las proporciones de los datos para que ninguna variable pese más solo por tener números más grandes.

Por ejemplo, imagina que tienes datos sobre la duración de llamadas telefónicas, que va de 1 a 20 minutos, y el coste mensual de la factura, que va de 10 a 500 euros. Con la normalización, cada variable se ajusta para que vaya de 0 a 1, haciendo que ambas estén en el mismo rango sin importar que antes tuvieran escalas muy distintas. Con la estandarización, los valores se transforman para que tengan una media de cero y muestren cuánto se alejan de esa media, lo que permite compararlos aunque sus distribuciones sean distintas. Así, las dos variables aportan de forma justa y equilibrada al análisis, sin que ninguna domine solo por tener cifras más grandes.

Estas transformaciones son esenciales para que modelos como redes neuronales, clustering o regresiones trabajen mejor. Cuando las variables tienen magnitudes muy distintas, el modelo puede confundir la magnitud con la importancia real, provocando resultados menos precisos, menos estables y entrenamientos más lentos. Estandarizar y escalar permite que el entrenamiento sea más rápido, las predicciones más fiables y que los patrones reales se detecten mejor. La normalización suele ser más útil cuando las variables ya tienen distribuciones similares y solo varían en la escala, mientras que la estandarización resulta más eficaz cuando las variables tienen distribuciones diferentes o cuando los algoritmos necesitan medias y varianzas equilibradas. Por eso, conviene analizar siempre las características de los datos y el tipo de modelo antes de decidir cuál de estas técnicas aporta más valor en cada caso.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Por qué es necesario codificar las variables categóricas para que los algoritmos puedan usarlas correctamente

Muchos modelos de aprendizaje automático solo pueden trabajar con datos numéricos, pero en la práctica hay muchas variables que no lo son, como colores, niveles educativos o tipos de productos. Estas variables categóricas aportan información muy importante, pero si no las transformamos, los algoritmos no pueden interpretarlas ni extraer patrones reales.

Para que estas variables puedan ser procesadas, se aplican técnicas de codificación que las convierten en números. Una de las más usadas es el LabelEncoder, que asigna un número único a cada categoría. Por ejemplo, si tenemos la variable “color” con valores rojo, azul y verde, LabelEncoder podría transformarlos en 0, 1 y 2. Es un método sencillo que se usa cuando la variable no tiene un orden específico o cuando los modelos no dependen de relaciones de magnitud, como en árboles de decisión.

Otra técnica muy común es el OneHotEncoder, que crea una columna para cada categoría y marca con 1 la categoría correspondiente y con 0 las demás. Siguiendo con el ejemplo del color, se crearían tres columnas: “rojo”, “azul” y “verde”. Si el valor original es “azul”, solo la columna “azul” tendrá un 1 y las otras dos un 0. Este método es muy útil para modelos que no pueden interpretar relaciones de orden y para variables con pocas categorías, como cuando se codifican ciudades o tipos de productos.

En algunas situaciones, especialmente cuando las categorías tienen una relación ordinal (como niveles educativos: básico, medio, avanzado), se pueden aplicar métodos más específicos que respeten ese orden para que los modelos lo tengan en cuenta. Además, existen otras técnicas más avanzadas como el Box-Cox, que aunque suele usarse para transformar distribuciones numéricas muy sesgadas, también puede ayudar cuando queremos que las variables numéricas se comporten más como una distribución normal. Por ejemplo, si tenemos una variable “ingresos” con valores muy elevados y pocos valores bajos, Box-Cox transforma esos datos para que los valores extremos estén más equilibrados con el resto, facilitando que el modelo los use de forma más justa.

Estas no son las únicas técnicas, ya que hay métodos adicionales como el OrdinalEncoder o las codificaciones basadas en frecuencia o en conteo, que pueden ayudar cuando tenemos muchas categorías o cuando queremos que el modelo entienda mejor las relaciones entre ellas.

Elegir la codificación correcta depende del tipo de variable y del modelo que vayamos a utilizar. LabelEncoder se usa cuando la variable es nominal y el modelo no necesita entender distancias entre categorías. OneHotEncoder es más eficaz cuando las categorías no tienen orden y queremos evitar que el modelo suponga relaciones numéricas que no existen. Box-Cox o transformaciones similares se aplican cuando necesitamos corregir distribuciones muy asimétricas en datos numéricos o continuos.

En resumen, codificar las variables categóricas es esencial para que los modelos puedan usar la información que aportan y convertirla en patrones útiles y comparables con el resto de los datos. Elegir el tipo de codificación adecuado mejora la calidad de los datos y la precisión de las predicciones.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Cómo usar pipelines para encadenar limpieza codificación y escalado de forma reproducible

Después de ver cómo la normalización, la estandarización y la codificación de variables categóricas ayudan a que los datos sean comparables y relevantes para los modelos, es importante que todos estos pasos se apliquen siempre igual y en el orden correcto. Aquí es donde entran los pipelines, que permiten encadenar todo este proceso de transformación de datos en un único flujo claro y reproducible. De esta forma, el modelo recibe siempre los datos procesados de la misma manera, sin errores o diferencias inesperadas.

Un pipeline puede incluir desde la limpieza inicial de los datos, eliminando valores nulos o corrigiendo errores, hasta la eliminación de campos que no aportan valor al análisis, como los identificadores. Además, puede incorporar pasos para detectar y ajustar outliers o valores extremos, que podrían distorsionar los cálculos si no se tratan adecuadamente. Después, añade la codificación de variables categóricas, usando herramientas como LabelEncoder para variables con un único valor numérico, OneHotEncoder para crear columnas separadas por categoría o Box-Cox para corregir distribuciones de variables numéricas con valores muy sesgados.

Una vez las variables categóricas están convertidas en formato numérico, el pipeline también puede aplicar la normalización o la estandarización. La normalización ajusta los datos a un rango fijo, como de cero a uno, para que todas las variables tengan la misma escala. La estandarización, en cambio, los transforma para que tengan media cero y varianza constante, ayudando a comparar mejor variables con distribuciones distintas. El escalado, en general, engloba todas estas técnicas que igualan las proporciones y eliminan la influencia de magnitudes artificiales.

Por ejemplo, si tienes un conjunto de datos con la “edad” (numérica), la “ciudad” (categórica), los “ingresos” (numéricos, con valores extremos) y un identificador de cliente, el pipeline podría empezar eliminando el identificador, rellenar los valores nulos de la “edad”, detectar y ajustar los outliers de “ingresos”, aplicar OneHotEncoder a la “ciudad”, corregir la distribución de “ingresos” con Box-Cox y finalmente estandarizar todas las variables numéricas. Con este flujo ordenado y automático, se evitan errores y se garantiza que el modelo reciba siempre los datos en condiciones óptimas para aprender.

En la práctica, los pipelines permiten reproducir todo este flujo fácilmente, facilitando que el análisis sea consistente y fiable, sin necesidad de rehacer los pasos manualmente. Además, ayudan a que los modelos entrenen más rápido y obtengan predicciones más precisas y estables.

En resumen, los pipelines permiten encadenar la limpieza de datos, la eliminación de campos innecesarios, el tratamiento de outliers, la codificación de variables categóricas y el escalado de forma segura y organizada. Son clave para que los modelos aprendan patrones reales y para que los datos se preparen siempre igual, garantizando resultados más consistentes y confiables.

Cómo aplicar la secuencia de transformación de datos

Transformar los datos antes de entrenar modelos es fundamental para que las variables aporten información de forma equilibrada y no generen sesgos artificiales. Aunque existe un orden general en

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



el que se suelen aplicar estos pasos, la secuencia exacta siempre depende de las características concretas de los datos y del tipo de modelo que se use.

Por lo general, primero se limpia la información eliminando errores, valores nulos y campos que no aportan valor. Después se suele revisar la presencia de outliers y decidir si conviene ajustarlos o no, teniendo en cuenta que a veces son valores reales que no deben descartarse. La codificación de variables categóricas suele hacerse a continuación para que los modelos puedan procesarlas como números. Una vez están todas las variables numéricas, se pueden aplicar transformaciones para corregir distribuciones muy sesgadas, como el logaritmo o Box-Cox.

El paso final es la normalización o la estandarización, que ayuda a que todas las variables estén en escalas comparables o que tengan medias y varianzas similares. Sin embargo, no todos estos pasos son imprescindibles en todos los proyectos. Depende mucho de cómo sean las distribuciones de los datos y de las exigencias de cada modelo.

Por eso es clave revisar visualmente las distribuciones y analizar la influencia real de cada paso antes de decidir si aplicarlo o no. Usar herramientas como los pipelines facilita todo este proceso, porque permiten encadenar cada etapa de forma ordenada y reproducible.

Lección 5. Selección y reducción de características filtrado PCA y técnicas avanzadas

Por qué es importante seleccionar las características más relevantes en un conjunto de datos

Al trabajar con datos para entrenar un modelo, no todas las variables aportan información útil o necesaria. Algunas pueden ser irrelevantes o no tener relación directa con lo que queremos predecir. Incluir estas variables poco relevantes no solo aumenta el tamaño del conjunto de datos, sino que también puede confundir al modelo, provocando que pierda precisión y estabilidad.

Cuando las variables irrelevantes están presentes, el modelo puede verse obligado a procesar información que no aporta nada real y que solo introduce ruido. Esto dificulta que aprenda los patrones correctos y puede llevar a un sobreajuste, donde el modelo aprende detalles muy específicos de los datos de entrenamiento pero pierde capacidad para generalizar a datos nuevos. Además, tener más variables de las necesarias incrementa el tiempo de entrenamiento y hace que el modelo sea más difícil de interpretar.

Para evitar esto, es esencial identificar las características que realmente aportan valor al modelo y trabajar solo con ellas. Seleccionar las variables más relevantes mejora la calidad de las predicciones, facilita el análisis de los resultados y permite que el modelo sea más ágil y fácil de mantener.

Además, este proceso no siempre tiene que hacerse manualmente. Existen técnicas y herramientas automáticas que pueden identificar las características más importantes comparando su relación con la variable objetivo y descartando las que no tienen un impacto claro. Estas técnicas permiten que la

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



selección se haga de forma más rápida y objetiva, evitando decisiones subjetivas que podrían no ser las más adecuadas.

Por eso, seleccionar bien las características es uno de los pasos más importantes en el desarrollo de modelos de aprendizaje automático. Permite que el modelo se base en datos realmente útiles y que trabaje de forma más eficiente y confiable.

Qué es el filtrado y cómo ayuda a identificar las variables que aportan valor al modelo

El filtrado es un proceso que se utiliza para decidir qué variables tienen una relación clara con la variable objetivo y cuáles no aportan información útil. Aunque ya hemos visto medidas como la correlación de Pearson o de Spearman, el filtrado va más allá y consiste en revisar todas las variables usando esas medidas y otras pruebas estadísticas como el test de chi-cuadrado para variables categóricas. Sin embargo, en este curso nos centraremos sobre todo en técnicas más generales y potentes como el análisis de componentes principales (PCA).

El filtrado evalúa cada variable de forma independiente, sin tener en cuenta cómo interactúan entre sí en el modelo final. Esto permite ver si una variable tiene algún vínculo con la variable objetivo o si solo añade ruido, reduciendo así el tamaño del conjunto de datos y facilitando que el modelo trabaje con la información que realmente importa.

Aunque el filtrado puede ser un paso útil al inicio del análisis, el método que veremos en profundidad en esta lección es el PCA, que permite simplificar los datos sin perder la información esencial y que suele aplicarse después de este filtrado inicial.

Cómo funciona el Análisis de Componentes Principales y qué aporta a la reducción de características

El Análisis de Componentes Principales, conocido como PCA por sus siglas en inglés, es una técnica que se utiliza para simplificar un conjunto de datos mientras se mantiene la mayor parte de la información. Su objetivo es transformar las variables originales en un nuevo conjunto de variables llamadas componentes principales, que son combinaciones lineales de las variables originales y que capturan la mayor variabilidad posible de los datos. Esto permite trabajar con un número más reducido de variables sin perder la esencia de la información.

El PCA busca los ejes o direcciones en el espacio de datos donde los datos están más dispersos, encontrando así las dimensiones que mejor explican las diferencias y dejando fuera las que aportan poca variación o que solo introducen ruido. Cada componente principal combina las variables originales y se ordena de forma que el primero explica la mayor parte de la varianza (es decir, cómo varían los datos entre sí), el segundo un poco menos y así sucesivamente.

Por ejemplo, imagina que estás analizando un conjunto de datos con variables como altura, peso y longitud de pierna de varias personas. Aunque son variables distintas, están muy relacionadas, ya que las personas más altas suelen tener más peso y piernas más largas. El PCA combina estas variables en un nuevo eje, el primer componente, que representa esa relación general de tamaño

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



corporal. Al usar solo este componente principal, se puede explicar casi toda la variabilidad de las tres variables originales, reduciendo el número de dimensiones de tres a una sola y manteniendo la información esencial.

Una de las grandes ventajas del PCA es que reduce la dimensionalidad de los datos, lo que simplifica el modelo y mejora la velocidad de entrenamiento. Además, reduce el riesgo de sobreajuste porque se eliminan detalles poco importantes que solo añaden ruido, algo especialmente útil cuando el conjunto de datos tiene muchas variables y es difícil interpretarlas todas a la vez.

Otra ventaja importante es que los componentes principales están ordenados por la cantidad de varianza que explican, lo que permite elegir de forma objetiva cuántos componentes utilizar. Por ejemplo, si los dos primeros componentes explican el 95% de la varianza, podemos usar solo esos dos y descartar el resto, haciendo el análisis mucho más sencillo.

El PCA se suele aplicar después de un filtrado inicial y de normalizar o estandarizar los datos, ya que funciona mejor cuando las variables están en escalas comparables. En problemas como clasificación o clustering, ayuda a visualizar los datos y a encontrar patrones más claros, mientras que en modelos predictivos mejora la eficiencia sin sacrificar precisión.

El PCA transforma un conjunto de datos complejo en una versión más sencilla y ordenada, manteniendo casi toda la información útil y eliminando lo que solo añade ruido, lo que lo convierte en una herramienta clave para trabajar con datos de alta dimensión y modelos más estables.

Qué técnicas avanzadas ayudan a simplificar los datos sin perder información esencial

Además del PCA, existen otras técnicas que permiten reducir la cantidad de variables y simplificar los datos sin perder la información clave para el modelo. Estas técnicas ayudan a que el modelo sea más rápido y eficiente, sobre todo cuando se trabaja con conjuntos de datos muy grandes y con muchas variables.

Una de ellas se llama Análisis Discriminante Lineal (LDA), que aunque a primera vista es similar al PCA, tiene un objetivo diferente: en lugar de buscar las direcciones con mayor varianza, busca las direcciones que mejor separan las clases o categorías de la variable objetivo. Esto lo hace especialmente útil para problemas de clasificación, ya que no solo reduce la dimensionalidad sino que también maximiza la separación entre las clases.

Otra técnica avanzada son los Autoencoders, redes neuronales entrenadas para reconstruir los datos de entrada. Durante este proceso, se fuerza a la red a aprender una representación comprimida de los datos, creando así una versión más reducida pero con la misma información importante. Los autoencoders son muy potentes en problemas con datos muy complejos o cuando se quiere aplicar reducción de dimensionalidad no lineal.

También se pueden usar métodos como t-SNE o UMAP, que aunque suelen aplicarse más para visualización de datos que para reducir dimensiones antes de entrenar modelos, permiten ver relaciones en datos de muchas dimensiones y detectar patrones que no se ven fácilmente en un análisis tradicional.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Todas estas técnicas tienen en común que ayudan a simplificar el conjunto de datos y a detectar patrones más claros sin perder lo esencial. Dependiendo del tipo de problema y del modelo que se use, se puede optar por una técnica u otra, ya que cada una tiene sus ventajas y limitaciones.

En la práctica, conviene elegir la técnica que mejor se adapte al tipo de datos y al objetivo del análisis. Cuando se busca reducir dimensiones para mejorar la interpretación o la visualización, técnicas como t-SNE o UMAP son útiles. Si se busca maximizar la separación de clases en clasificación, el LDA es una buena opción. Para representar datos complejos en problemas no lineales, los autoencoders pueden ser muy potentes. Y para mantener la máxima varianza y simplificar variables numéricas, el PCA sigue siendo el método más usado.