

Autora: Mireia Consarnau Pallarés.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Aprendizaje supervisado. Modelos para análisis predictivo.....	1
Introducción.....	1
Lección 1. ¿Qué es el aprendizaje supervisado? Fases de trabajo.....	1
Definición de aprendizaje supervisado, diferencias con programación tradicional.....	2
Tipos de problemas, clasificación y regresión.....	2
Cómo se desarrollan las fases del aprendizaje supervisado.....	3
División de datos, entrenamiento, validación, prueba, validación cruzada.....	4
Concepto de modelo, algoritmo, parámetros, hiperparámetros.....	5
Riesgos habituales, sobreajuste, subajuste, bias-variance.....	6
Lección 2. Modelos supervisados para clasificación: algoritmos, métricas y usos.....	8
Papel de la clasificación, ejemplos de aplicación práctica.....	8
Métricas para evaluar clasificación.....	8
Clasificación binaria y multiclase.....	8
Matriz de confusión para clasificación binaria.....	9
Matriz de confusión para clasificación multiclase.....	10
Exactitud (Accuracy).....	11
Precisión (Precision).....	11
Sensibilidad (Recall).....	11
Especificidad.....	11
F1-Score.....	11
Índice Kappa.....	12
Valor predictivo positivo (PPV).....	12
Valor predictivo negativo (NPV).....	12
Curva ROC y Área bajo la curva (AUC).....	12
Elección de métricas según el contexto del problema.....	13
Detección del sobreajuste en clasificación y análisis visual.....	14
Validación cruzada.....	14
Comparación entre entrenamiento y test.....	15
Curva de aprendizaje.....	16
Validación con datos externos o nuevas observaciones.....	16
Algoritmos de clasificación.....	17
Introducción a los algoritmos de clasificación.....	17
Naive Bayes fundamentos probabilísticos y supuestos.....	17
Idea principal y ejemplos de uso.....	17
Cómo funciona.....	17
Puntos clave del algoritmo.....	18
Cuándo funciona bien y cuándo no.....	18
Particularidades del algoritmo.....	19
K-Nearest Neighbors distancia y maldición de la dimensionalidad.....	19
Idea principal y ejemplos de uso.....	19
Cómo funciona.....	20

Puntos clave del algoritmo.....	21
Cuándo funciona bien y cuándo no.....	21
Particularidades del algoritmo.....	21
Regresión logística decisión lineal y regularización.....	22
Idea principal y ejemplos de uso.....	22
Cómo funciona.....	22
Puntos clave del algoritmo.....	24
Cuándo funciona bien y cuándo no.....	24
Particularidades del algoritmo.....	24
Support Vector Machines margen máximo y kernels.....	25
Idea principal y ejemplos de uso.....	25
Cómo funciona.....	25
Puntos clave del algoritmo.....	27
Cuándo funciona bien y cuándo no.....	27
Particularidades del algoritmo.....	27
Árboles de decisión criterios de división y sobreajuste.....	29
Idea principal y ejemplos de uso.....	29
Cómo funciona.....	30
Puntos clave del algoritmo.....	31
Cuándo funciona bien y cuándo no.....	31
Particularidades del algoritmo.....	31
Random Forest agregación de modelos e importancia de variables.....	32
Idea principal y ejemplos de uso.....	32
Cómo funciona.....	32
Puntos clave del algoritmo.....	33
Cuándo funciona bien y cuándo no.....	33
Particularidades del algoritmo.....	33
AdaBoost ponderación de errores y mejora iterativa.....	34
Idea principal y ejemplos de uso.....	34
Cómo funciona.....	35
Puntos clave del algoritmo.....	35
Cuándo funciona bien y cuándo no.....	36
Particularidades del algoritmo.....	36
Comparación general de algoritmos.....	37
Lección 3. Modelos supervisados para regresión: algoritmos, métricas y usos.....	40
Papel de la regresión, ejemplos de aplicación práctica.....	40
Métricas para evaluar regresión.....	40
MAE, MSE, RMSE, comparación y sensibilidad a valores extremos.....	40
MAE (Error Absoluto Medio).....	40
MSE (Error Cuadrático Medio).....	41
RMSE (Raíz del Error Cuadrático Medio).....	41
R ² y coeficiente de determinación, interpretación y límites.....	42
Funciones de pérdida, error absoluto, error cuadrático, entropía cruzada adaptada	43
Error absoluto (EAM, Error Absoluto Medio).....	43

Error cuadrático (EQM, Error Cuadrático Medio).....	43
Entropía cruzada adaptada.....	44
Comprender la diferencia entre precisión y exactitud en regresión.....	44
Detección del sobreajuste en clasificación y análisis visual.....	46
Evaluación directa de las predicciones.....	47
Gráfico de predicciones frente a valores reales.....	48
Gráfico de residuos.....	48
Curvas de aprendizaje en regresión.....	49
Validación con nuevas observaciones.....	50
Algoritmos de regresión.....	51
Introducción a los algoritmos de regresión.....	51
Regresión lineal simple y múltiple, mínimos cuadrados y regularización.....	52
Idea principal y ejemplos de uso.....	52
Cómo funciona.....	52
Puntos clave del algoritmo.....	53
Cuándo funciona bien y cuándo no.....	53
Particularidades del algoritmo.....	54
Support Vector Regression, margen ϵ y kernels.....	55
Árboles de decisión para regresión, partición de varianza.....	56
Random Forest para regresión, ensamble y reducción de varianza.....	57
Adaboost para regresión, errores ponderados continuos.....	58
Comparación general de algoritmos.....	59

Aprendizaje supervisado. Modelos para análisis predictivo

Introducción

El aprendizaje supervisado parte de la idea de usar datos con ejemplos conocidos para construir modelos que permitan hacer predicciones con datos nuevos. Esta unidad explica cómo se prepara y se organiza la información, cómo se dividen los datos en entrenamiento, validación y prueba, y cómo se revisa si un modelo generaliza bien o no.

Se verán las dos principales áreas que abarca el aprendizaje supervisado, la clasificación y la regresión. En clasificación se estudia cómo asignar a cada dato una categoría o etiqueta, mientras que en regresión se trabaja con valores numéricos continuos. También se presentarán las métricas más importantes que se utilizan para medir el rendimiento y la fiabilidad de estos modelos.

Por último se explicarán los algoritmos más clásicos y utilizados para abordar estos problemas. Entre ellos destacan Naive Bayes, k-Nearest Neighbors, regresión logística, Support Vector Machines, árboles de decisión, Random Forest y Adaboost, tanto en clasificación como en regresión.

Al finalizar, el alumno tendrá una visión clara y ordenada de cómo se desarrolla un proyecto supervisado y cómo se comparan los modelos con las métricas más comunes.

Lección 1. ¿Qué es el aprendizaje supervisado?

Fases de trabajo

Definición de aprendizaje supervisado, diferencias con programación tradicional

El aprendizaje supervisado es un método que consiste en enseñar a un modelo a realizar predicciones a partir de ejemplos conocidos. Cada ejemplo incluye las variables que describen una situación y el resultado que se espera. Durante el proceso de aprendizaje, el modelo busca patrones y relaciones entre las variables de entrada y la salida que se quiere predecir. Una vez entrenado, puede aplicar ese conocimiento a datos nuevos y predecir resultados con un grado de fiabilidad.

Esta forma de trabajar contrasta con la programación tradicional, en la que se escriben instrucciones paso a paso para que el sistema siga reglas fijas. En el aprendizaje supervisado no se programan reglas concretas, sino que el modelo las aprende de los datos. Esto hace que pueda adaptarse a problemas complejos o situaciones donde sería muy difícil o imposible escribir las reglas manualmente.

Además, el aprendizaje supervisado tiene la ventaja de que puede seguir aprendiendo y mejorando a medida que se dispone de más datos. Mientras que en la programación tradicional los cambios suelen requerir reescribir parte del código, en un modelo supervisado basta con actualizar los datos y reentrenarlo para que siga funcionando bien.

Tipos de problemas, clasificación y regresión

En el aprendizaje supervisado se pueden encontrar dos grandes tipos de problemas según el tipo de salida que se quiere predecir. Por un lado está la clasificación, que se usa cuando la variable objetivo tiene un número limitado de valores o clases. Un ejemplo sería clasificar correos electrónicos como "spam" o "no spam". Cada observación se asocia a una de estas clases, y el objetivo del modelo es aprender a predecir correctamente a cuál pertenece cada nueva observación.

Por otro lado está la regresión, que se emplea cuando la variable objetivo es numérica y continua. En este caso el modelo no decide entre clases, sino que calcula un valor concreto. Un ejemplo sería predecir el precio de una casa en función de sus características como el tamaño, la ubicación o la antigüedad. El modelo busca identificar la relación entre las variables y ajustar sus predicciones lo más cerca posible de los valores reales.

Además, existen problemas que pueden plantearse como clasificación o regresión, dependiendo de cómo se interprete la variable objetivo. Por ejemplo, predecir la edad exacta de una persona sería un problema de regresión, pero si la agrupamos en intervalos como "menor de 20", "20 a 40" o "más de 40", se convierte en un problema de clasificación.

Ambos tipos de problemas comparten la idea de aprender de datos conocidos, pero difieren en cómo interpretan el resultado final. La clasificación se centra en etiquetas o categorías, mientras la regresión se orienta a valores numéricos que pueden variar en un rango continuo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Cómo se desarrollan las fases del aprendizaje supervisado

El aprendizaje supervisado sigue un ciclo completo que comienza mucho antes de que un modelo haga predicciones y termina con una revisión a fondo de si ese modelo funciona bien y es capaz de generalizar a datos nuevos. La fase de recopilación de datos es la primera y consiste en reunir información suficiente, relevante y actualizada. Los datos deben representar bien el problema, ya que si tienen sesgos o errores, el modelo también aprenderá esos fallos.


A continuación, está la fase de exploración y preparación de los datos, en la que se revisa su calidad y se hacen transformaciones básicas para dejarlos listos. Esta fase, que ya se trabajó en la unidad anterior, incluye la limpieza de valores nulos o duplicados, la corrección de datos mal introducidos, la normalización o estandarización de las escalas y la codificación de variables categóricas. Después de la limpieza, se exploran las distribuciones y las relaciones entre variables, lo que ayuda a entender los datos y detectar posibles problemas, como valores extremos o correlaciones inesperadas.

La fase de división de los datos permite separar la información en conjuntos de entrenamiento, validación y prueba. Esto es esencial para que el modelo no aprenda de memoria los datos de entrenamiento y se pueda comprobar si generaliza bien a datos que nunca ha visto. Tras la división, se pasa a la fase de entrenamiento del modelo y realización de las predicciones, donde el modelo ajusta sus parámetros internos basándose en los datos de entrenamiento.

Luego viene la fase de validación, en la que se comprueba con datos distintos a los de entrenamiento si el modelo está funcionando correctamente o si está sobreajustando. Después de esta validación, se entra en la fase de optimización, ajustando hiperparámetros, probando otros algoritmos o combinando técnicas para mejorar el rendimiento. Estas fases de validación y optimización no siempre son lineales y pueden repetirse varias veces hasta encontrar la combinación más adecuada.

Una vez elegido el modelo que mejor funciona, se realizan pruebas finales para asegurarse de que no hay sobreajuste y de que el modelo sigue funcionando bien incluso con valores extremos o situaciones poco comunes. Esto confirma que el modelo es estable y puede adaptarse a datos reales más allá del conjunto de entrenamiento.

Finalmente, la fase de conclusiones permite recoger los resultados, interpretar su significado y decidir cómo aplicar el modelo o cómo comunicar sus predicciones a quienes lo van a usar. Todo este ciclo muestra que el aprendizaje supervisado no es solo cuestión de entrenar modelos, sino de preparar y revisar los datos en cada paso para asegurar que las predicciones sean lo más precisas y fiables posible.



Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



División de datos, entrenamiento, validación, prueba, validación cruzada

Una parte esencial en el aprendizaje supervisado es cómo se dividen los datos para que el modelo pueda aprender de forma equilibrada y se pueda comprobar su rendimiento real. Lo habitual es separar el conjunto original en tres partes: datos de entrenamiento, de validación y de prueba. Una división muy común es usar un 70 % de los datos para entrenar y el 30 % restante para validación y prueba. Esta proporción puede variar según el problema, pero siempre se busca que el conjunto de entrenamiento tenga suficiente información para que el modelo pueda ajustar sus parámetros y, más adelante, sus hiperparámetros.

El conjunto de entrenamiento permite que el modelo aprenda las relaciones entre las variables de entrada y la salida. El conjunto de validación sirve para ajustar los hiperparámetros y comprobar que el modelo funciona bien con datos que no ha visto antes, ayudando a detectar problemas como el sobreajuste. El conjunto de prueba es el paso final, donde se evalúa el rendimiento real del modelo antes de aplicarlo a datos futuros.

Además de esta división tradicional, muchas veces se usa la validación cruzada para aprovechar al máximo los datos disponibles y tener una evaluación más completa del modelo. Consiste en dividir el conjunto de datos varias veces en partes diferentes, llamadas “pliegues” o “folds”. Por ejemplo, en una validación cruzada de 5 pliegues, el modelo se entrena cinco veces, cada vez dejando fuera un quinto de los datos como conjunto de validación y usando los cuatro quintos restantes para entrenamiento. Así, se obtiene una media del rendimiento en distintas divisiones, lo que ayuda a ver cómo se comporta el modelo en general y no solo con una partición concreta.

La validación cruzada es especialmente útil cuando se dispone de pocos datos o cuando se quiere tener una medida más robusta de la capacidad real del modelo para generalizar. Todo este proceso asegura que el modelo no solo funcione bien con los datos conocidos, sino que también pueda adaptarse a datos nuevos y seguir siendo útil en la práctica.

Concepto de modelo, algoritmo, parámetros, hiperparámetros

En el aprendizaje supervisado es importante distinguir bien entre varios conceptos que suelen confundirse. El modelo es la representación final que se entrena con los datos y que, una vez listo, se utiliza para hacer predicciones. Por ejemplo, un árbol de decisión entrenado con datos de pacientes para decidir si tienen o no una enfermedad concreta.

Por su parte, el algoritmo es el conjunto de pasos o instrucciones que se siguen para construir ese modelo a partir de los datos. En el caso de un árbol de decisión, el algoritmo define cómo dividir los datos y qué criterios usar para crear las ramas.

El modelo ajusta sus parámetros durante el entrenamiento. Estos son los valores internos que el modelo adapta automáticamente a medida que aprende de los datos. Por ejemplo, en la regresión lineal serían los coeficientes que multiplican las variables de entrada para dar la predicción. En un árbol de decisión serían las condiciones concretas de división en cada nodo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Los hiperparámetros son diferentes porque no se aprenden directamente de los datos. Se establecen antes de entrenar y controlan cómo funciona el algoritmo en general. En el caso de un árbol, un hiperparámetro sería la profundidad máxima permitida o el número mínimo de muestras para hacer una división. A diferencia de los parámetros internos, estos hiperparámetros no cambian durante el entrenamiento: los define la persona que entrena el modelo o se buscan de forma automática con técnicas de búsqueda.

Para encontrar los valores adecuados de los hiperparámetros se suele usar una búsqueda sistemática, como la búsqueda en cuadrícula (grid search), que prueba distintas combinaciones posibles, o la búsqueda aleatoria (random search), que elige combinaciones de manera más flexible. Esta búsqueda ayuda a mejorar el rendimiento final sin que el modelo se adapte demasiado a los datos de entrenamiento.

Entender esta diferencia entre parámetros e hiperparámetros ayuda a ver qué valores puede aprender el modelo y cuáles son decisiones previas que pueden marcar la diferencia entre un modelo que generaliza bien y otro que se queda corto.

Riesgos habituales, sobreajuste, subajuste, bias-variance

Al trabajar con modelos supervisados es habitual encontrarse con problemas como el sobreajuste y el subajuste. El sobreajuste ocurre cuando el modelo se adapta demasiado a los datos de entrenamiento y aprende incluso detalles irrelevantes o ruido. Por ejemplo, si se entrena un árbol de decisión muy profundo, puede memorizar cada dato exacto y funcionar muy bien en el entrenamiento pero fallar con datos nuevos. Esto hace que el modelo parezca muy preciso pero en realidad no generaliza bien.

Por el contrario, el subajuste sucede cuando el modelo no es capaz de captar los patrones principales de los datos, como si se entrenara un árbol de decisión muy poco profundo o una regresión lineal para un problema muy complejo. En este caso, el modelo comete muchos errores incluso con los datos de entrenamiento y tampoco predice bien en datos nuevos.

Estos dos problemas están muy relacionados con el equilibrio entre bias y variance. El bias mide el error que se produce cuando se simplifica demasiado el problema, lo que hace que el modelo no logre captar los patrones importantes y tienda a subajustarse. La variance mide cuánto varían las predicciones del modelo con diferentes datos, y cuando es muy alta hace que el modelo se sobreajuste y se vuelva muy sensible a cambios pequeños.

Para ver si un modelo sufre sobreajuste o subajuste se pueden comparar los resultados de entrenamiento y de validación. Por ejemplo, si el error en entrenamiento es muy bajo pero en validación es muy alto, hay sobreajuste. Si los errores son altos en ambos, el modelo está subajustado. Estos resultados se suelen ver en gráficos de aprendizaje o tablas de métricas.

Existen técnicas básicas para controlar y detectar el sobreajuste, como la validación cruzada, el uso de regularización para que el modelo no se ajuste en exceso a los datos de entrenamiento y la comparación de métricas en conjuntos distintos. Además, se pueden utilizar gráficos como las curvas de aprendizaje, que muestran cómo evolucionan los errores en entrenamiento y validación a medida que aumentan los datos o la complejidad del modelo. Aunque se verán con más detalle en la

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



práctica, estas herramientas permiten mantener un equilibrio entre bias y variance y conseguir modelos más estables y fiables.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)

