

Lección 3. Modelos supervisados para regresión: algoritmos, métricas y usos

Papel de la regresión, ejemplos de aplicación práctica

La regresión es una técnica fundamental en aprendizaje automático supervisado orientada a predecir valores numéricos continuos a partir de variables conocidas. A diferencia de la clasificación, donde se asigna una etiqueta, en regresión el objetivo es estimar una cantidad, como una puntuación, una duración, un coste o una probabilidad.

Este tipo de modelos es muy útil en situaciones donde se necesita prever comportamientos, anticipar resultados o tomar decisiones basadas en magnitudes. La regresión se aplica en campos muy diversos, desde la predicción de resultados académicos, el análisis del consumo energético, la estimación de tiempos de espera o entrega, hasta la modelización de riesgos financieros. También puede usarse en contextos donde interesa calcular precios o rendimientos, como en el caso del mercado inmobiliario, pero este es solo uno de los muchos posibles escenarios.

Para evaluar la calidad de las predicciones no basta con saber si se acercan o no al valor real. Dependiendo del problema, pueden interesar distintos tipos de error. Por eso se utilizan métricas específicas como el error cuadrático medio, el error absoluto medio o el coeficiente de determinación. Estas métricas permiten entender mejor cómo se comporta el modelo en diferentes rangos de valores o si tiende a sobrestimar o subestimar los resultados.

Métricas para evaluar regresión

MAE, MSE, RMSE, comparación y sensibilidad a valores extremos

Cuando se trabaja con modelos de regresión, es fundamental evaluar qué tan cerca están las predicciones del modelo respecto a los valores reales. Para ello se utilizan métricas específicas de error. Las tres más comunes son:

MAE (Error Absoluto Medio)

Calcula la media de las diferencias absolutas entre los valores reales y los predichos. Es decir, mide cuánto se equivoca el modelo en promedio, sin importar si lo hace por arriba o por abajo.

Por ejemplo, si el modelo predice que un coche cuesta 20.000 €, pero en realidad cuesta 22.000 €, la diferencia absoluta es de 2.000 €. Si este tipo de error se repite varias veces, el MAE reflejará ese promedio de forma directa, sin penalizar más los errores grandes.

Es una métrica útil cuando todos los errores tienen la misma importancia, independientemente de si son pequeños o grandes. Se suele usar en contextos donde queremos minimizar el error medio general y donde los valores atípicos no deben influir demasiado, como en estimaciones de consumo, temperaturas o tiempos de entrega.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



MSE (Error Cuadrático Medio)

Es similar al MAE, pero en lugar de tomar el valor absoluto de cada error, eleva las diferencias al cuadrado. Esto provoca que los errores grandes tengan mucho más peso en el resultado final, ya que su impacto se multiplica.

Por ejemplo, si un modelo se equivoca en 500 €, su error cuadrático será 250.000. Si el error es de 2.000 €, el resultado será 4.000.000. Es decir, aunque el segundo error es cuatro veces mayor, su penalización es dieciséis veces más alta. Esta característica hace que el MSE destaque mucho más los errores grandes.

Por eso, es una métrica útil cuando queremos que el modelo evite desviaciones grandes a toda costa. A cambio, puede ser muy sensible a valores atípicos, ya que los penaliza con mucha fuerza.

Se recomienda utilizar el MSE cuando los errores grandes tienen consecuencias más importantes que los pequeños, por ejemplo, en predicción de precios de viviendas, costes médicos o estimaciones económicas donde un error elevado puede tener un gran impacto práctico.

RMSE (Raíz del Error Cuadrático Medio)

Es muy parecido al MSE, pero después de calcular el error cuadrático medio, se aplica una raíz cuadrada. Esto hace que el resultado vuelva a estar en las mismas unidades que la variable a predecir, lo que facilita su interpretación.

Por ejemplo, si un modelo predice que un piso cuesta 180.000 €, pero en realidad cuesta 200.000 €, el error es de 20.000 €. Si este tipo de error se repite, el RMSE dará una media en euros, como el precio original.

El RMSE también penaliza más los errores grandes, igual que el MSE, pero al aplicar la raíz cuadrada se suaviza el efecto y resulta más legible.

Es útil cuando se quiere penalizar los errores grandes, pero se necesita que el resultado esté en la misma escala que los datos. Muy usado cuando importa mucho la precisión y se quiere interpretar el margen medio de error fácilmente.

Cada una de estas métricas responde de forma diferente ante errores grandes.

El MAE da el mismo peso a todos los errores, sean pequeños o grandes. Es una opción equilibrada si se quiere medir la precisión media sin dejar que unos pocos errores extremos influyan demasiado. Por ejemplo, si estamos ajustando un modelo para predecir el precio medio de productos de supermercado, donde pequeñas desviaciones son tolerables y los valores extremos son raros, el MAE puede ser más representativo de la calidad del modelo.

El MSE y el RMSE, en cambio, penalizan más los errores grandes porque elevan al cuadrado las diferencias. Esto hace que una predicción muy alejada del valor real tenga un impacto mucho mayor en el resultado final. Por eso son métricas más sensibles a valores atípicos. Son útiles cuando esos

errores grandes son especialmente importantes, como en la predicción del coste de una cirugía o de la inversión en bolsa, donde una mala predicción puntual puede tener un gran impacto económico.

Elegir una u otra depende del contexto. Si los errores grandes son críticos y se quieren evitar a toda costa, conviene usar MSE o RMSE. Si, en cambio, se prefiere una medida más robusta y estable frente a valores extremos, el MAE es la mejor opción.

R² y coeficiente de determinación, interpretación y límites

El coeficiente de determinación, conocido como R², indica qué proporción de la variabilidad de los valores reales puede explicarse por el modelo. Su valor suele situarse entre 0 y 1, aunque en algunos casos puede ser negativo. Cuanto más alto es, mejor encaja el modelo con los datos. Por ejemplo, un R² de 0.85 significa que el 85% de las diferencias entre los precios reales de unas casas se pueden explicar a partir de las variables utilizadas, como la superficie o el número de habitaciones.

Un R² de 1 indicaría que el modelo predice perfectamente todos los valores, mientras que un R² de 0 implica que el modelo no aporta ninguna mejora respecto a simplemente predecir la media. Si el valor es negativo, es señal de que el modelo está funcionando peor que una predicción constante basada en la media de los datos.

Esta métrica resulta útil cuando se quiere saber cuánto explica un modelo sobre el comportamiento general de los datos, pero no indica si las predicciones son realmente cercanas a los valores reales. Un modelo puede tener un R² alto y aun así cometer errores importantes en valores concretos. Por eso se recomienda usarla siempre junto con métricas como el MAE o el RMSE, que sí reflejan los errores en unidades reales.

R² también puede ser engañoso cuando el modelo tiene muchas variables, ya que su valor puede aumentar aunque las nuevas variables no aporten valor real. Para estos casos existe el R² ajustado, que tiene en cuenta la complejidad del modelo. Además, en problemas con patrones no lineales, puede no ser fiable si no se adapta bien el tipo de modelo.

En definitiva, el R² ayuda a entender qué porcentaje de la variabilidad de los datos estamos explicando, pero no debe utilizarse como único criterio para valorar un modelo de regresión. Sirve para comparar modelos aplicados al mismo problema, pero debe interpretarse con cuidado y complementarse siempre con otras métricas.

A veces, un modelo con un R² ligeramente más bajo puede ser preferible si el RMSE disminuye de forma considerable. Por ejemplo, si un modelo tiene un R² de 0.89 pero un RMSE de 5.000 euros, y otro tiene un R² de 0.85 pero un RMSE de 3.000 euros, es probable que el segundo sea más útil en la práctica, porque comete errores menores en promedio, aunque explique un poco menos de la variabilidad total. Esto es especialmente importante cuando se trabaja con datos sensibles, como precios o cantidades económicas, donde los errores grandes pueden tener más impacto que una ligera pérdida de capacidad explicativa.

Funciones de pérdida, error absoluto, error cuadrático, entropía cruzada adaptada

En los modelos de regresión, las funciones de pérdida son fórmulas que indican cuánto se está equivocando el modelo durante el entrenamiento. No se utilizan solo para evaluar el rendimiento final, sino también para guiar el proceso de aprendizaje. Cada vez que el modelo hace una predicción incorrecta, la función de pérdida calcula la magnitud del error y genera una señal que sirve para ajustar los parámetros internos del modelo (como los coeficientes en una regresión o los nodos en un árbol).

Estos ajustes no afectan a los hiperparámetros, que son valores definidos antes del entrenamiento (como la tasa de aprendizaje o la profundidad máxima del árbol), sino a los parámetros que el modelo va aprendiendo a medida que analiza los datos. Por tanto, una función de pérdida adecuada permite que el modelo se adapte progresivamente para reducir sus errores, mientras que una mal escogida puede llevarlo a sobreajustar, ignorar patrones importantes o tener mal rendimiento en datos nuevos.

Error absoluto (EAM, Error Absoluto Medio)

Esta función mide la diferencia entre el valor real y el valor predicho, sin importar si el error es positivo o negativo. Se le conoce también como *L1 loss*. Es útil cuando se desea una penalización uniforme para todos los errores, ya que trata igual los pequeños y los grandes. Por ejemplo, si un modelo predice 155.000 € y el valor real es 150.000 €, el error absoluto será de 5.000 €.

Error cuadrático (EQM, Error Cuadrático Medio)

También llamado *L2 loss*, eleva al cuadrado la diferencia entre valor real y valor predicho. Esto hace que los errores grandes tengan un peso mucho mayor. Se usa cuando se quiere evitar errores extremos. Siguiendo el ejemplo anterior, un error de 5.000 € pasaría a ser 25.000.000 al elevarse al cuadrado, por lo que el modelo intentará reducir especialmente los errores más grandes.

Ejemplo – Comparación entre EAM y EQM

Imagina un modelo que predice el valor de coches usados. Si un coche vale realmente 10.000 € y el modelo predice 9.000 €, el error es de 1.000 €. Ahora imagina que para otro coche el valor real es 15.000 €, pero el modelo predice 10.000 €, cometiendo un error de 5.000 €.

Si usamos EAM (Error Absoluto Medio), ambos errores se suman sin distinción especial y se promedian. El resultado reflejará un error medio de 3.000 €, tratando los errores por igual. Este enfoque es útil cuando todos los errores son importantes por igual y no queremos que los más grandes influyan demasiado.

En cambio, si usamos EQM (Error Cuadrático Medio), el error de 1.000 € se convierte en 1.000.000, pero el de 5.000 € pasa a ser 25.000.000. Esto hace que el error más grande tenga mucha más influencia sobre la media, elevando el EQM a un valor mucho mayor. Por eso, el EQM se usa cuando se quiere penalizar especialmente los errores grandes y evitar que el modelo se equivoque mucho en casos puntuales.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Entropía cruzada adaptada

Aunque esta función es más común en clasificación, también puede adaptarse a regresión si los valores continuos se agrupan en intervalos o clases. La entropía cruzada (*cross-entropy*) mide la diferencia entre la distribución de probabilidad real y la predicha. Por ejemplo, si se quiere predecir la temperatura en rangos (baja, media, alta), se puede usar entropía cruzada para comparar cuán bien se ajusta la probabilidad estimada con la clase real. Es útil en problemas de regresión que se reformulan como clasificación con rangos definidos.

Ejemplo – Uso de entropía cruzada adaptada

Supón que quieres predecir la temperatura ambiental, pero en lugar de un valor exacto, te interesa saber si será baja, media o alta, ya que es más útil para activar sistemas de ventilación o calefacción.

En este caso, puedes dividir los valores continuos de temperatura en tres rangos y tratar el problema como una clasificación. Si el modelo predice que hay un 60 % de probabilidad de que la temperatura sea “alta”, un 30 % “media” y un 10 % “baja”, y el valor real cae en el rango “alta”, el error será pequeño. Pero si el modelo hubiera asignado un 10 % a “alta” y un 80 % a “baja”, la entropía cruzada sería mucho mayor, porque la predicción está muy lejos de la realidad.

Este enfoque permite trabajar con distribuciones de probabilidad, y es especialmente útil cuando lo importante es anticipar correctamente el nivel o categoría en la que cae el valor, más que la cifra exacta.

Comprender la diferencia entre precisión y exactitud en regresión

Al evaluar modelos de regresión, no solo interesa saber cuánto se equivocan, sino también cómo se comportan sus predicciones entre sí. Dos conceptos que ayudan a entender esto son la **precisión** y la **exactitud**, que aunque suelen asociarse a tareas de clasificación, también tienen sentido en regresión.

En este caso, hablamos de **exactitud** cuando las predicciones se aproximan mucho a los valores reales. En cambio, un modelo es **preciso** si sus predicciones son coherentes entre sí, aunque estén lejos del valor correcto. Es decir, la precisión se relaciona con la dispersión interna del modelo y la exactitud con su capacidad para acertar.

Por ejemplo, si un modelo predice siempre 155.000 € para viviendas que en realidad cuestan 120.000 €, 190.000 € y 155.000 €, podemos decir que es muy preciso, porque repite siempre el mismo valor, pero poco exacto, porque solo acierta en un caso y se equivoca bastante en los otros dos.


Este equilibrio entre coherencia y acierto se representa de forma muy clara en la imagen siguiente, que compara distintos escenarios de precisión y exactitud con la idea de un sistema de puntería.

Alta exactitud y baja precisión

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)




En este gráfico se observa que los puntos (las predicciones del modelo) están repartidos alrededor del centro del objetivo, pero no están agrupados entre sí. Esto significa que el modelo, en promedio, acierta bastante en su estimación (alta exactitud), pero presenta una gran variabilidad entre una predicción y otra (baja precisión). Es decir, aunque las predicciones se acercan al valor real, no son consistentes entre ellas. Este comportamiento puede ser aceptable si interesa un buen promedio, pero puede resultar problemático si se necesita estabilidad en cada predicción individual.



Baja exactitud y baja precisión

En esta imagen, los puntos están dispersos y alejados del centro de la diana. Esto indica que las predicciones del modelo ni son consistentes entre sí (baja precisión), ni se acercan al valor real (baja exactitud). Es el peor de los casos: el modelo no solo se equivoca, sino que lo hace de forma poco uniforme. Una situación así sugiere que el modelo no está captando bien la relación entre las variables y necesita una revisión profunda o un enfoque diferente.




Alta exactitud y alta precisión

En esta representación vemos un caso de alta exactitud y alta precisión. Todos los puntos están agrupados muy cerca entre sí y, además, se sitúan justo en el centro de la diana. Esto indica que el modelo genera predicciones muy consistentes (alta precisión) y que esas predicciones están muy próximas al valor real (alta exactitud). Es el escenario ideal en problemas de regresión, ya que implica que el modelo no solo es fiable en sus resultados, sino también acertado.


Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)





Baja exactitud y alta precisión

Este ejemplo representa un caso de alta precisión pero baja exactitud. Las predicciones del modelo están muy agrupadas entre sí (alta precisión), lo que indica consistencia, pero todas están alejadas del centro de la diana (baja exactitud), es decir, del valor real. Esto puede suceder cuando el modelo aprende un patrón erróneo o tiene un sesgo sistemático. Aunque siempre se equivoca de forma similar, no está acertando en el valor correcto.



Detección del sobreajuste en clasificación y análisis visual

El sobreajuste en regresión comparte el mismo principio que en clasificación: el modelo se ajusta demasiado a los datos de entrenamiento y pierde capacidad para generalizar con datos nuevos. Al igual que en clasificación, se pueden utilizar técnicas como la validación cruzada, la comparación entre entrenamiento y test, o las curvas de aprendizaje para detectar este comportamiento. Sin embargo, la regresión también tiene herramientas propias que permiten analizar mejor cómo se comporta el modelo frente a valores numéricos continuos.

Una señal habitual de sobreajuste en regresión es obtener errores muy bajos sobre el conjunto de entrenamiento y errores significativamente mayores en validación o test. Pero para entender bien este fenómeno, no basta con observar las métricas: es necesario visualizar cómo predice el modelo y cómo se distribuyen los errores.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Evaluación directa de las predicciones

Una forma sencilla de detectar si un modelo está sobreajustado consiste en revisar las primeras predicciones una a una y compararlas con los valores reales. No basta con conocer el error medio. Al revisar caso por caso, se puede ver si el modelo tiene desviaciones sistemáticas, si falla en valores bajos o altos, o si comete errores grandes que podrían pasar desapercibidos en una métrica global. Observar también el porcentaje de error relativo ayuda a identificar si los errores son proporcionales o si el modelo se desajusta más en ciertos rangos.

Este análisis se puede complementar con un criterio práctico basado en márgenes de error relativos. Aunque no existe una norma teórica universal que establezca umbrales exactos, en algunos contextos se utilizan tramos orientativos para facilitar la interpretación. Por ejemplo, se puede considerar una predicción como buena si el error relativo es inferior al 10%, aceptable entre el 10% y el 25%, y mejorable si supera ese valor. Estos porcentajes no provienen de una teoría formal, sino que sirven como guía aproximada, y deben adaptarse según la naturaleza del problema y el impacto que tenga cada error en el contexto real.

A continuación se muestra un ejemplo con las primeras predicciones del conjunto de test. En cada caso se compara el valor real, la predicción, la diferencia y el porcentaje de error:

```
1: Real Time: 90.81 - Predicción Time: 78.84 - Diferencia: 11.97 - Error: 13.18%
2: Real Time: 15.67 - Predicción Time: 25.27 - Diferencia: -9.60 - Error: 61.27%
3: Real Time: 56.23 - Predicción Time: 72.97 - Diferencia: -16.74 - Error: 29.78%
4: Real Time: -3.57 - Predicción Time: -3.03 - Diferencia: -0.54 - Error: 15.11%
5: Real Time: 65.74 - Predicción Time: 64.62 - Diferencia: 1.12 - Error: 1.71%
6: Real Time: 47.95 - Predicción Time: 38.15 - Diferencia: 9.80 - Error: 20.44%
7: Real Time: 20.70 - Predicción Time: 28.64 - Diferencia: -7.94 - Error: 38.36%
8: Real Time: 24.15 - Predicción Time: 32.02 - Diferencia: -7.87 - Error: 32.60%
9: Real Time: 44.75 - Predicción Time: 58.18 - Diferencia: -13.43 - Error: 30.01%
10: Real Time: 53.09 - Predicción Time: 46.76 - Diferencia: 6.33 - Error: 11.92%
11: Real Time: 69.13 - Predicción Time: 71.71 - Diferencia: -2.58 - Error: 3.74%
12: Real Time: 1.38 - Predicción Time: 14.12 - Diferencia: -12.74 - Error: 923.10%
```

Este tipo de revisión permite identificar con precisión en qué casos concretos el modelo falla más, si los errores son razonables o inaceptables, y si hay algún patrón que se repite. Es especialmente útil en contextos donde se requiere precisión en la toma de decisiones, como predicción de tiempos, costes o variables médicas.

A continuación se muestra gráficamente esa misma información, comparando los valores reales y predichos de las primeras 50 muestras. Se puede observar si el modelo mantiene una diferencia constante, si tiende a sobreestimar o infraestimar, o si hay puntos con errores especialmente elevados:




Gráfico de predicciones frente a valores reales

Este gráfico muestra la relación entre los valores predichos por el modelo y los valores reales esperados. En un modelo ideal, todos los puntos se situarían sobre una línea diagonal, indicando que la predicción es igual al valor real. Cuanto más dispersos estén los puntos respecto a esta línea, mayor será el error. Si se observa un patrón de desviación —por ejemplo, si el modelo sistemáticamente subestima los valores altos— puede indicar un problema de sobreajuste o una falta de capacidad para captar relaciones complejas.





Gráfico de residuos

El gráfico de residuos representa la diferencia entre el valor real y el valor predicho. Es una herramienta clave en regresión para detectar errores no visibles en las métricas numéricas. En un modelo que generaliza bien, los residuos deberían distribuirse aleatoriamente alrededor de cero. Si aparecen agrupaciones, formas curvas o una dispersión no homogénea, podría significar que el

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)





modelo no está captando bien la estructura de los datos o que está sobreajustado. Un error sistemático en los residuos suele ser una señal clara de que el modelo no generaliza correctamente.



Curvas de aprendizaje en regresión

Las curvas de aprendizaje permiten observar cómo evoluciona el rendimiento del modelo a medida que aumenta la cantidad de datos disponibles. En un modelo equilibrado, la puntuación en entrenamiento disminuye ligeramente mientras que la de validación mejora, hasta que ambas se estabilizan cerca. Si la puntuación en entrenamiento es muy alta pero la de validación queda muy por debajo, es probable que el modelo esté sobreajustando. En cambio, si ambas puntuaciones son bajas, el modelo puede estar infraajustado, lo que también se detecta visualmente. Observar la forma de las curvas y su distancia ayuda a tomar decisiones sobre el tipo de modelo y el volumen de datos necesario.




Validación con nuevas observaciones

Una prueba esencial es comprobar cómo se comporta el modelo ante nuevos datos. Esto incluye tanto observaciones normales como casos extremos o situaciones poco frecuentes. Si el modelo sigue ofreciendo predicciones razonables, es señal de que ha aprendido patrones generales. En cambio, si las predicciones se desvían mucho, especialmente en casos nuevos o inesperados, puede indicar que el modelo solo ha aprendido a funcionar bien con los datos que ya conocía. Esta

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



validación externa, aunque no siempre se incluye en los primeros ciclos de entrenamiento, es clave para asegurar que el modelo puede aplicarse en contextos reales.



Algoritmos de regresión

Introducción a los algoritmos de regresión

La regresión es una de las tareas principales dentro del aprendizaje supervisado, y su objetivo es predecir un valor numérico continuo a partir de una o más variables de entrada. A diferencia de la clasificación, que asigna etiquetas discretas, la regresión se utiliza para estimar cantidades como el precio de un producto, la duración de un trayecto o el consumo energético de una vivienda.

Aunque existe una gran variedad de algoritmos capaces de realizar tareas de regresión, en este módulo solo estudiaremos en detalle uno propio de este tipo de problemas: la regresión lineal. El resto de algoritmos que ya se han trabajado en el bloque de clasificación también pueden utilizarse para regresión, con ligeras adaptaciones. Es el caso de los árboles de decisión, los modelos de ensamble como Random Forest y Gradient Boosting, o los modelos basados en máquinas de vectores soporte (SVM), que se pueden ajustar para regresión mediante SVR (*Support Vector Regression*).

Además, existen otros algoritmos diseñados exclusivamente para regresión, como los modelos polinómicos, la regresión por mínimos absolutos o técnicas específicas para series temporales. No se abordan en este módulo, pero conocer su existencia puede ayudar a elegir mejor la estrategia en función del problema concreto.

Entender cómo funcionan estos algoritmos y cuándo utilizar cada uno es clave para construir modelos predictivos fiables. Un modelo de regresión no solo debe ofrecer buenas predicciones, sino también generalizar correctamente y ser interpretable en su contexto de uso.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Regresión lineal simple y múltiple, mínimos cuadrados y regularización

Idea principal y ejemplos de uso

La regresión lineal es un modelo supervisado que predice valores numéricos continuos a partir de una o varias variables de entrada. Asume que existe una relación lineal entre las variables independientes y la variable dependiente, y busca encontrar la mejor línea recta (o hiperplano en caso múltiple) que minimice la diferencia entre los valores predichos y los reales.

Funciona bien con datos numéricos, sin valores extremos muy desviados y donde la relación entre variables sea aproximadamente lineal. Puede aplicarse tanto a conjuntos de datos pequeños como grandes, siempre que las variables estén correctamente preparadas y escaladas si es necesario.

Algunos ejemplos habituales son la predicción de precios (como viviendas, productos o acciones), la estimación de tiempos (como el de entrega o reparación), o la proyección de cantidades continuas (como el gasto mensual de un hogar, la temperatura de un sistema o el número de ventas en función de la inversión en marketing).


Cómo funciona

La regresión lineal, tanto simple como múltiple, se basa en ajustar una línea recta (o un plano en espacios de más dimensiones) que relacione las variables independientes con la variable dependiente. El modelo aprende esa relación calculando los coeficientes que mejor explican los datos observados.

En la regresión lineal simple, se utiliza una sola variable independiente para predecir una dependiente. En la múltiple, se usan varias variables independientes. En ambos casos, el modelo estima el valor de salida combinando los valores de entrada mediante una fórmula lineal.

Durante el entrenamiento, el modelo compara sus predicciones con los valores reales y calcula la diferencia entre ellos, llamada residuo. Cuanto más pequeños y equilibrados sean esos residuos, mejor se ajusta el modelo. Por eso, el objetivo del aprendizaje es minimizar la suma de los residuos al cuadrado, es decir, que las predicciones estén lo más cerca posible de los valores reales sin errores sistemáticos.

En la siguiente imagen se puede observar una representación gráfica de una regresión lineal simple. La línea representa la predicción del modelo, mientras que los puntos muestran los datos reales. Las líneas verticales conectan cada punto con la recta y representan los residuos, es decir, el error entre el valor real y el estimado por el modelo.



Puntos clave del algoritmo

- La regresión lineal parte de la suposición de que existe una relación lineal entre las variables independientes y la variable dependiente
- Utiliza los residuos (diferencias entre valores reales y predichos) para ajustar el modelo, buscando minimizar su suma al cuadrado
- Es muy eficiente con datos numéricos continuos y escalados, y funciona mejor cuando las variables no están muy correlacionadas entre sí
- Permite interpretar con facilidad el impacto de cada variable independiente sobre la predicción, gracias a los coeficientes del modelo
- Es sensible a valores atípicos, ya que estos pueden desviar la recta de ajuste y empeorar el rendimiento global
- Supone ciertas condiciones como que la relación entre variables sea lineal, que los errores (residuos) sigan una distribución normal, que su variación sea constante en todos los niveles (homoscedasticidad) y que no haya patrones entre los errores (ausencia de autocorrelación).

Cuándo funciona bien y cuándo no

Funciona bien cuando la relación entre las variables es realmente lineal, no hay valores atípicos extremos y se cumplen las condiciones estadísticas básicas como normalidad de los residuos, homoscedasticidad y ausencia de autocorrelación. La linealidad se tiene que dar entre cada variable independiente y la variable dependiente, no entre las variables independientes entre sí. Es especialmente útil cuando se busca una interpretación clara del impacto de cada variable sobre el resultado.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



No funciona bien cuando hay relaciones no lineales, muchas variables irrelevantes o correlacionadas entre sí (multicolinealidad), o cuando hay ruido excesivo en los datos. También puede fallar si los residuos muestran patrones o si su variación cambia a lo largo de los valores predichos.

Particularidades del algoritmo

Una característica propia de la regresión lineal es el uso del método de los mínimos cuadrados. Esta técnica ajusta la recta o el hiperplano buscando los coeficientes que minimizan la suma de las diferencias al cuadrado entre los valores reales y los predichos. Gracias a este criterio, se obtiene la mejor aproximación global a los datos de entrenamiento. Por ejemplo, en un modelo que predice la temperatura en función del número de horas de sol, la recta se ajusta intentando minimizar los errores entre las temperaturas reales y las estimadas por el modelo.

Además, la regresión lineal parte de una serie de condiciones estadísticas que deben cumplirse para que el modelo sea válido. Una de ellas es la linealidad. Debe existir una relación lineal entre cada variable independiente y la variable dependiente. Esta relación debe mantenerse entre todas las variables independientes respecto a la variable a predecir, no solo entre algunas. En un caso como predecir el precio de una vivienda a partir de su tamaño, antigüedad y número de habitaciones, cada una de estas variables debería tener un comportamiento lineal con respecto al precio para que el modelo funcione correctamente.

Otra suposición clave es la normalidad de los residuos. Esto significa que las diferencias entre los valores reales y los predichos deben seguir una distribución normal. Cumplir este requisito permite interpretar mejor los resultados del modelo y aplicar ciertas técnicas estadísticas con más garantías.

También es importante que exista homoscedasticidad. Esto quiere decir que la varianza de los residuos se mantenga constante para todas las predicciones. Si la dispersión de los errores cambia según el valor predicho, el modelo puede estar cometiendo errores más grandes en ciertos rangos, lo que se conoce como heteroscedasticidad. Por ejemplo, si al predecir ingresos según nivel educativo, los errores se disparan en los niveles más altos, esto sería un caso de heteroscedasticidad.

La ausencia de autocorrelación en los residuos es otra condición necesaria. Los errores cometidos por el modelo no deberían seguir ningún patrón ni estar relacionados entre sí, especialmente si los datos están ordenados temporalmente. Si los residuos presentan autocorrelación, como podría ocurrir al predecir el número de visitas diarias a una web, puede significar que hay comportamientos repetitivos no captados por el modelo.

En la regresión múltiple hay una particularidad adicional. Es fundamental evitar la multicolinealidad, que ocurre cuando dos o más variables independientes están muy correlacionadas entre ellas. Esto dificulta saber qué variable está influyendo realmente en la predicción y puede hacer que los coeficientes del modelo cambien bruscamente con pequeñas variaciones en los datos. Por ejemplo, en un modelo que predice el consumo energético a partir del número de electrodomésticos y el tamaño del hogar, estas dos variables podrían estar tan relacionadas que una de ellas no aporte información nueva.

Por último, en los modelos con muchas variables independientes, es clave seleccionar bien cuáles se van a incluir. Deben escogerse las más relacionadas con la variable dependiente y, al mismo tiempo, que no estén demasiado correlacionadas entre sí. Para ello pueden usarse técnicas como la matriz

de correlación, métodos de selección automática o reducción de dimensionalidad como el análisis de componentes principales (PCA).

Support Vector Regression, margen ϵ y kernels


VR es una técnica para hacer predicciones numéricas basada en la misma idea que las máquinas de soporte vectorial usadas en clasificación. Pero en lugar de separar clases, SVR busca ajustar una línea o curva que pase lo más cerca posible de los datos sin preocuparse por errores pequeños.

Para eso se define un margen de tolerancia llamado **epsilon (ϵ)**. Si la predicción cae dentro de ese margen con respecto al valor real, no se considera un error importante. Solo se tienen en cuenta los casos que se desvían mucho, y son esos los que influyen en la construcción del modelo. Esto hace que el modelo sea menos sensible a pequeñas fluctuaciones y más robusto frente al ruido.

En la siguiente imagen, a la izquierda, con un epsilon de 0.5, el modelo ajusta una línea más precisa. El margen es estrecho, por lo que muchos puntos quedan fuera y se consideran errores importantes que el modelo intenta corregir. Esto puede hacer que se adapte más a los datos, pero también corre más riesgo de sobreajuste.

A la derecha, con un epsilon más amplio (1.2), el modelo permite mayor desviación sin penalizarla. El margen abarca más puntos, que se consideran aceptables aunque no estén exactamente en la línea. Esto da lugar a una predicción más simple y robusta frente al ruido.

Esta visualización ayuda a entender cómo epsilon actúa como un "colchón" de tolerancia en SVR, decidiendo qué errores se ignoran y cuáles afectan directamente al modelo.



El comportamiento del modelo depende de varios hiperparámetros. Epsilon marca cuánta desviación se tolera sin penalizar. C indica cuánto se penalizan los errores grandes: valores bajos dan lugar a modelos más simples y valores altos fuerzan un mayor ajuste. Kernel transforma los datos si la relación no es lineal. El kernel más usado en regresión es el radial o RBF, pero también se puede usar el lineal o el polinómico. Si el kernel es no lineal, se añade el parámetro gamma, que controla la influencia de cada punto sobre la predicción.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



SVR tiene otras particularidades importantes. Es sensible a la escala de los datos, por lo que es imprescindible aplicar un escalado previo a las variables antes de entrenar. También hay que tener en cuenta que, aunque puede manejar relaciones complejas, no escala bien con conjuntos de datos muy grandes. Cuantos más vectores soporte necesite, más costoso será el entrenamiento.

Por último, hay que destacar que no es un modelo interpretable. Si se usa un kernel no lineal, es difícil entender cómo influyen las variables en la predicción final. Por eso, SVR es recomendable cuando lo que se busca es precisión más que explicación.

Árboles de decisión para regresión, partición de varianza

Un árbol de decisión para regresión divide el espacio de datos en regiones más pequeñas aplicando reglas sucesivas basadas en los valores de las variables independientes. A diferencia de la clasificación, donde el objetivo es asignar clases, en regresión cada hoja del árbol devuelve un valor numérico, normalmente la media de los valores reales que han llegado hasta ella.


El criterio de división más habitual es la reducción de varianza. En cada nodo, el algoritmo elige la variable y el punto de corte que generan dos subconjuntos con menor varianza interna, es decir, grupos donde los valores de salida son más parecidos entre sí. Esto indica que la división ha separado correctamente los datos según el valor a predecir, y mejora la precisión del modelo en cada hoja.

Este tipo de modelo no requiere que exista una relación lineal entre las variables ni que los datos sigan una distribución concreta. Puede capturar relaciones no lineales, efectos de umbral y comportamientos abruptos que otros modelos, como la regresión lineal o una SVR con kernel lineal, no detectan fácilmente.

Sin embargo, los árboles de regresión tienden a sobreajustar si no se aplican restricciones. Para evitarlo, se recomienda limitar la profundidad máxima del árbol (`max_depth`) o fijar un número mínimo de muestras por hoja (`min_samples_leaf`). Por ejemplo, valores entre 3 y 7 para la profundidad y entre 5 y 20 muestras por hoja suelen ser eficaces en conjuntos pequeños o medianos.

Una diferencia importante respecto a clasificación es que aquí se utilizan métricas continuas como el error cuadrático medio (MSE) para evaluar el rendimiento, y no precisión o matrices de confusión. Si el modelo está bien ajustado, las predicciones siguen el patrón real de forma escalonada, según las regiones que ha generado.

En la siguiente imagen se muestra cómo el modelo construye divisiones sobre la variable independiente (eje horizontal) y asigna una predicción constante a cada segmento. Cada valor predicho corresponde a la media de los datos reales en esa región. Esta representación visual permite entender cómo un árbol de regresión aproxima funciones no lineales mediante bloques con valores constantes.



Random Forest para regresión, ensamble y reducción de varianza

Random Forest es un modelo de ensamble que combina múltiples árboles de decisión para obtener predicciones más robustas y precisas. Cada árbol se entrena con una muestra aleatoria del conjunto de entrenamiento (con reemplazo) y, en el caso de regresión, la predicción final se calcula haciendo la media de las predicciones individuales de todos los árboles.

Este enfoque reduce la varianza del modelo sin aumentar demasiado el sesgo. Aunque un solo árbol puede sobreajustarse fácilmente a los datos, la media de muchos árboles independientes compensa estas desviaciones y mejora la capacidad de generalización. Esta estrategia hace que Random Forest funcione bien incluso en presencia de ruido o datos no lineales.

En regresión, Random Forest no necesita que las variables independientes tengan una relación lineal con la variable objetivo ni que los datos sigan una distribución concreta. Funciona bien con conjuntos de datos complejos, con muchas variables o con interacciones entre ellas, y no requiere escalar las características.


A diferencia de un árbol individual, donde se puede seguir una única ruta de decisión, aquí no hay una interpretación directa del modelo completo. Aun así, se pueden calcular importancias de las variables para saber cuáles influyen más en la predicción. También permite ajustar hiperparámetros específicos como el número de árboles (`n_estimators`), la profundidad máxima de cada árbol (`max_depth`) o el número de variables consideradas en cada división (`max_features`). Por ejemplo, `max_features='sqrt'` suele ser una opción adecuada.

En la siguiente imagen se representa el funcionamiento interno de Random Forest en un problema de regresión. Cada árbol genera una predicción distinta a partir de sus propias reglas y subconjuntos de datos. La predicción final del modelo se obtiene calculando la media de todas esas salidas

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



individuales. Este proceso reduce el sobreajuste de los árboles por separado y proporciona una estimación más estable y precisa.



Adaboost para regresión, errores ponderados continuos

AdaBoost también puede aplicarse a problemas de regresión, donde el objetivo no es clasificar, sino predecir valores numéricos continuos. En este caso, el algoritmo entrena una serie de modelos simples, normalmente árboles de regresión poco profundos, de forma secuencial. Cada modelo intenta corregir los errores cometidos por el anterior, dando más importancia a los puntos donde las predicciones han fallado más.

El proceso comienza asignando el mismo peso a todas las observaciones. Después de entrenar el primer modelo, se calculan los errores y se ajustan los pesos: los puntos con errores más grandes reciben mayor peso en el siguiente modelo. Así, cada nuevo estimador se centra más en las observaciones difíciles de predecir.

Este ajuste progresivo permite que el conjunto de modelos se adapte a zonas complejas del dataset sin necesidad de recurrir a modelos muy complejos desde el inicio. Es una estrategia eficaz para mejorar la precisión en regiones con ruido, valores atípicos o patrones irregulares, siempre que se controle adecuadamente el número de iteraciones y la complejidad del modelo base.


La predicción final se obtiene combinando los resultados de todos los modelos, ponderando su contribución según su rendimiento. En lugar de una votación como en clasificación, se calcula una media ponderada de los valores estimados.

Entre los hiperparámetros principales destacan el número de estimadores (`n_estimators`, por ejemplo entre 50 y 200), la tasa de aprendizaje (`learning_rate`, normalmente entre 0.01 y 1) y la función de pérdida (`loss`), que puede ser lineal, cuadrática o exponencial, en función de cómo se

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



quieran penalizar los errores. El modelo base (`base_estimator`) suele tener profundidad limitada para evitar que cada árbol sobreajuste por separado.



Comparación general de algoritmos

Algoritmo	Objetivo general	Ventajas	Limitaciones	Hiperparámetros más importantes	Puntos clave a tener en cuenta
Regresión lineal (simple y múltiple)	Ajustar una recta o hiperplano que minimice la diferencia entre los valores	Interpretación sencilla, rápido de entrenar, útil como punto de partida. Eficaz con relaciones lineales	No capta relaciones no lineales, afectada por multicolinealidad, sensible a outliers	<code>fit_intercept</code> , <code>normalize</code> (según la implementación)	Requiere relación lineal entre todas las variables independientes y la dependiente. Requiere

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



	reales y los predichos				residuos normales, homocedasticidad y sin autocorrelación
SVR (Support Vector Regression)	Ajustar una función que minimiza errores dentro de un margen ϵ , maximizando el margen y usando kernels si es necesario	Flexible con kernels, tolera relaciones no lineales. Control sobre errores mediante ϵ	Costosa computacionalmente, difícil de ajustar. Sensible a selección de hiperparámetros	C (penalización), epsilon (margen), kernel, gamma	El valor de ϵ define el margen sin penalización. Útil en datos ruidosos si se ajusta bien. Requiere escalado
Árboles de decisión	Dividir los datos en regiones homogéneas mediante reglas basadas en la variable dependiente	Captura relaciones no lineales, fácil de visualizar, no necesita normalización	Tendencia a sobreajuste sin regularización, predicción por tramos constantes	max_depth, min_samples_split, min_samples_leaf, criterion	No necesita normalización. Acepta variables mixtas. Ideal si hay umbrales o patrones no lineales evidentes
Random Forest	Promediar múltiples árboles de decisión entrenados sobre subconjuntos aleatorios para mejorar estabilidad y precisión	Reduce el sobreajuste, robusto a outliers, buen rendimiento sin mucho ajuste	Menos interpretable, más costoso. No siempre mejora tras cierto número de árboles	n_estimators, max_features, max_depth, n_jobs	Evalúa la importancia de variables. No requiere normalización. Entrenamiento más largo, pero paralelo

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



AdaBoost	Combinar modelos simples corrigiendo iterativamente los errores de predicción con más peso en los más grandes	Mejora modelos simples, adapta bien en zonas difíciles, precisa con pocos hiperparámetros	Muy sensible a outliers, entrenamiento secuencial, no paralelizable	n_estimators, learning_rate, loss, base_estimator	Funciona bien si se ajustan iteraciones y modelo base. Penaliza más los errores altos si se ajusta la función de pérdida
----------	---	---	---	---	--