

Autora, traducción y adaptación: Mireia Consarnau Pallarés.  
Material original elaborado para el IOC.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



|                                                                                                                        |           |
|------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>Aprendizaje no supervisado: modelos de agrupación y análisis de patrones.....</b>                                   | <b>1</b>  |
| <b>Introducción.....</b>                                                                                               | <b>1</b>  |
| <b>Lección 1. ¿Qué es el aprendizaje no supervisado? Conceptos y proceso general.....</b>                              | <b>2</b>  |
| ¿Qué es el aprendizaje no supervisado?.....                                                                            | 2         |
| Proceso general.....                                                                                                   | 3         |
| ¿Para qué sirve? Aplicaciones concretas.....                                                                           | 3         |
| Principales tareas del aprendizaje no supervisado.....                                                                 | 4         |
| Conceptos clave del clustering.....                                                                                    | 5         |
| ¿Qué es un clúster?.....                                                                                               | 5         |
| ¿Cómo se mide la similitud?.....                                                                                       | 6         |
| Métricas de distancia habituales.....                                                                                  | 6         |
| Modelos para formar clústeres.....                                                                                     | 7         |
| Reducción de dimensiones con PCA.....                                                                                  | 9         |
| ¿Qué es el PCA?.....                                                                                                   | 9         |
| ¿Por qué reducir dimensiones?.....                                                                                     | 10        |
| ¿Cómo funciona?.....                                                                                                   | 10        |
| Decidir cuántos componentes conservar.....                                                                             | 11        |
| Evaluación de la calidad del modelo.....                                                                               | 12        |
| ¿Cómo evaluar un modelo con etiquetas? Métricas externas.....                                                          | 12        |
| ¿Cómo evaluar un modelo sin etiquetas? Métricas internas.....                                                          | 12        |
| Caso práctico simulado.....                                                                                            | 13        |
| ¿Se puede mejorar un modelo sin saber la respuesta?.....                                                               | 14        |
| <b>Lección 2. Agrupación con k-medias y métodos jerárquicos: funcionamiento y aplicación.....</b>                      | <b>15</b> |
| ¿Qué es el agrupamiento con K-means y cómo funciona?.....                                                              | 15        |
| Puntos fuertes y limitaciones del algoritmo K-means.....                                                               | 16        |
| Fases del algoritmo.....                                                                                               | 16        |
| ¿Cómo decidir cuántos grupos formar? Desarrollo de la fase 1: Determinación del número de clústeres (K).....           | 18        |
| ¿Cómo se eligen los centroides iniciales? Desarrollo de la fase 2: Inicialización estratégica de los centroides.....   | 19        |
| ¿Cómo se asignan los puntos a los clústeres? Desarrollo de la fase 3: Asignación de observaciones a los clústeres..... | 20        |
| ¿Cómo se actualizan los centroides? Desarrollo de la fase 4: Actualización de los centroides mediante promedios.....   | 21        |
| ¿Cuándo termina el algoritmo? Desarrollo de la fase 5: Iteración hasta la convergencia del modelo.....                 | 21        |
| Hiperparámetros del algoritmo K-means.....                                                                             | 22        |
| ¿Qué es el agrupamiento jerárquico y cómo funciona?.....                                                               | 22        |
| Tipos de enfoque: aglomerativo y divisivo.....                                                                         | 23        |
| Características principales del agrupamiento jerárquico.....                                                           | 24        |
| Método aglomerativo (Bottom-up).....                                                                                   | 25        |
| Criterio de similitud entre clústeres.....                                                                             | 25        |
| Métodos de enlace (linkage).....                                                                                       | 26        |
| Combinación entre restricciones de conectividad y métodos de enlace.....                                               | 28        |
| El dendrograma como representación visual del agrupamiento.....                                                        | 29        |
| Decisión del número de clústeres finales.....                                                                          | 30        |
| Hiperparámetros del algoritmo Aglomerativo.....                                                                        | 30        |

### **Lección 3. Agrupación basada en densidad: detección de formas y estructuras complejas.....32**

|                                                                     |    |
|---------------------------------------------------------------------|----|
| ¿Qué es el agrupamiento por densidad y cómo funciona?.....          | 32 |
| Tipos de puntos del algoritmo DBSCAN.....                           | 32 |
| Funcionamiento del algoritmo DBSCAN.....                            | 33 |
| Puntos fuertes y limitaciones del algoritmo DBSCAN.....             | 33 |
| DBSCAN frente a clústeres con densidades variables.....             | 34 |
| Comparativa con K-means y agrupamiento jerárquico.....              | 35 |
| Elección de los hiperparámetros eps y min_samples.....              | 35 |
| Cómo ajustar eps y min_samples con el análisis de k-distancias..... | 36 |



# Aprendizaje no supervisado: modelos de agrupación y análisis de patrones

## Introducción

El aprendizaje no supervisado es una técnica que permite descubrir patrones en los datos sin requerir respuestas previas. En esta unidad, nos centraremos en cómo aplicar algunas de las metodologías más comunes para abordar distintos problemas prácticos, como la segmentación de clientes o la reducción de dimensiones.

Nos centraremos especialmente en dos métodos clave: la agrupación de datos y la reducción de dimensiones mediante PCA. Ambas técnicas ayudan a simplificar grandes volúmenes de información, incluso cuando no disponemos de etiquetas previas.

La agrupación consiste en detectar similitudes entre elementos y reunirlos en grupos con características comunes. Esta estrategia resulta útil para explorar la estructura interna de los datos y revelar relaciones no evidentes a simple vista.

En el caso de conjuntos con muchas variables, el Análisis de Componentes Principales (PCA) permite reducir la cantidad de dimensiones sin perder demasiada información, facilitando así tanto la visualización como el análisis.

A lo largo del tema, el alumnado aprenderá cómo funcionan estos algoritmos, en qué situaciones conviene aplicarlos y qué limitaciones presentan. Además, pondrá en práctica su implementación y evaluación con Python y herramientas como scikit-learn.

# Lección 1. ¿Qué es el aprendizaje no supervisado? Conceptos y proceso general

## ¿Qué es el aprendizaje no supervisado?


Cuando trabajamos con datos reales, a menudo no contamos con etiquetas que indiquen a qué categoría pertenece cada elemento. En estos casos, el aprendizaje no supervisado ofrece herramientas para explorar los datos y descubrir posibles agrupaciones o estructuras escondidas, basándose únicamente en sus características.

Este tipo de algoritmos no necesita respuestas conocidas para aprender, ya que no busca ajustar un modelo a unos resultados esperados. En lugar de eso, detecta regularidades dentro del conjunto analizando relaciones como la forma, la densidad o la proximidad entre elementos.

El aprendizaje no supervisado engloba una serie de técnicas diseñadas para trabajar con información no clasificada. Su objetivo principal es identificar patrones, segmentaciones o estructuras internas, a menudo usando criterios estadísticos o espaciales.

A diferencia del aprendizaje supervisado, aquí no se puede medir directamente si una solución es correcta o incorrecta. No hay error ni retroalimentación directa: el sistema debe organizar la información por sí mismo a partir de las relaciones que detecta entre los datos.

Una forma sencilla de visualizar esta diferencia es con una comparación gráfica entre ambos enfoques, donde se observa cómo uno aprende con ejemplos etiquetados y el otro sin referencias previas.




Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



## Proceso general

A la hora de aplicar técnicas de aprendizaje no supervisado, es importante seguir una secuencia lógica que permita obtener buenos resultados. Estas son las etapas clave:

- A. **Preparar los datos.** Antes de aplicar cualquier técnica, es fundamental limpiar el conjunto: corregir errores, eliminar duplicados, tratar valores ausentes o atípicos que puedan afectar al análisis. También es recomendable escalar o normalizar las variables para que todas contribuyan de forma equilibrada.
- B. **Escoger la técnica adecuada.** La elección del método dependerá del objetivo: agrupar elementos similares, reducir dimensiones, detectar valores atípicos, etc. Es buena práctica comparar distintas opciones y ver cuál ofrece mejores resultados con los datos disponibles.
- C. **Ejecutar el modelo.** Una vez seleccionada la técnica, se aplica sobre el conjunto de datos sin supervisión. El modelo analiza las relaciones internas y organiza la información en función de los patrones que detecta.
- D. **Analizar los resultados.** Tras la ejecución, llega el momento de valorar si los resultados tienen sentido. Según la tarea, se aplican criterios distintos: en agrupamiento se estudia la cohesión y separación de los grupos; en reducción de dimensiones, la proporción de información conservada.
- E. **Interpretar y aplicar.** Finalmente, se interpretan los hallazgos con el objetivo de extraer conclusiones prácticas. Esta fase puede dar lugar a segmentaciones útiles, mejoras en procesos o decisiones estratégicas basadas en patrones detectados.



Esquematzació del procés de aprenentatge no supervisat

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



## ¿Para qué sirve? Aplicaciones concretas

El aprendizaje no supervisado se aplica en muchos contextos donde no se dispone de etiquetas, pero sí se quiere entender mejor la estructura de los datos. Algunos ejemplos reales:

- **En marketing y negocio**
  - Segmentación de clientes según sus hábitos, preferencias o comportamientos de compra
  - Detección de patrones de consumo y predicción de tendencias del mercado
- **En análisis de datos y documentación**
  - Organización automática de documentos por temas sin necesidad de clasificación previa
  - Identificación de duplicados o registros muy similares en bases de datos
- **En redes sociales y comportamiento humano**
  - Agrupación de usuarios con ideologías u opiniones similares
  - Análisis de estructuras de relación y comunidades dentro de redes sociales
- **En ciencia y tecnología**
  - Clasificación de genes con funciones parecidas
  - Apoyo en la investigación de nuevos medicamentos a partir de patrones en datos biomédicos
  - Exploración y organización de grandes volúmenes de datos astronómicos
- **En procesamiento de datos complejos**
  - Reducción del número de variables en conjuntos muy amplios para facilitar la interpretación sin perder información relevante

## Principales tareas del aprendizaje no supervisado

En el aprendizaje no supervisado no se dispone de etiquetas que indiquen la clase de cada ejemplo. En lugar de seguir modelos con respuestas ya definidas, este enfoque examina las características de los datos para descubrir estructuras internas que no son evidentes a simple vista.

Cada elemento se representa como un vector de atributos, y a partir de esa información, los algoritmos intentan encontrar patrones comunes, agrupar casos similares o reducir la complejidad del conjunto.

- Agrupación de datos (clustering).** Esta tarea busca estructurar el conjunto dividiéndolo en grupos formados por elementos internamente similares y externamente diferenciados. El objetivo es que cada grupo contenga elementos con características próximas entre sí, maximizando la cohesión interna y la separación entre grupos.
- Detección de anomalías.** Consiste en identificar elementos que se alejan significativamente del patrón general de los datos. Estos casos no encajan en los agrupamientos formados y se consideran desviaciones respecto al comportamiento común del conjunto.
- Reducción de variables (dimensionalidad).** Se basa en disminuir el número de atributos conservando la mayor parte posible de la información. Para ello, se agrupan características

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)





que expresan relaciones similares, lo que permite representar el conjunto de forma más compacta sin alterar sustancialmente su estructura interna.

**d. Otras tareas útiles**

- **Descubrimiento de relaciones entre variables.** Consiste en identificar patrones de asociación frecuentes entre diferentes características de un conjunto de datos. Este tipo de análisis permite detectar correlaciones o dependencias que no son evidentes inicialmente y que pueden aportar conocimiento estructural sobre el conjunto.
- **Extracción de temas en conjuntos de texto.** En contextos textuales, el aprendizaje no supervisado se puede aplicar para identificar automáticamente grupos de palabras o conceptos que tienden a aparecer conjuntamente. Esta tarea permite representar colecciones de documentos en función de los temas predominantes sin necesidad de clasificaciones previas.

El análisis de clústeres es una técnica fundamental para segmentar conjuntos de datos en agrupaciones coherentes. Su utilidad no se limita únicamente a la formación de grupos, sino que se extiende a otras tareas del análisis no supervisado con las que mantiene una relación directa.

En particular, las tres tareas principales del aprendizaje no supervisado —agrupación, detección de anomalías y reducción de dimensionalidad— comparten un enfoque común basado en la exploración de estructuras internas dentro de los datos.

La detección de anomalías puede entenderse como una extensión del análisis de clústeres, en la que se identifican elementos que presentan un comportamiento significativamente diferente al de los grupos formados. Esta identificación se basa en la comparación entre las características del elemento y los perfiles definidos por los clústeres habituales.

Por su parte, la reducción de dimensionalidad puede interpretarse como un agrupamiento aplicado a las variables en lugar de a los individuos. Agrupar atributos con comportamientos similares permite representar el conjunto de datos de forma más compacta, sin una pérdida excesiva de información. Aunque se trate como una técnica independiente, conceptualmente sigue una lógica muy próxima a la del clustering.

## Conceptos clave del clustering

Antes de aplicar algoritmos de agrupación, es importante comprender una serie de conceptos fundamentales que definen cómo funciona el clustering y qué se espera obtener con este tipo de análisis. Estos conceptos permiten interpretar mejor los resultados y tomar decisiones informadas durante el proceso.

A continuación, se presentan las ideas centrales que forman la base teórica de los métodos de clustering: qué es un clúster, cómo se mide la similitud entre elementos y qué papel juega la distancia en la formación de grupos.

### ¿Qué es un clúster?

En el contexto del aprendizaje no supervisado, un clúster es un conjunto de elementos que presentan similitudes entre sí en función de sus características. Estos elementos se representan como vectores

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



dentro de un espacio multidimensional, y su agrupación se basa en la proximidad o semejanza entre esos vectores.

El propósito principal de este tipo de análisis es organizar los datos en subconjuntos bien diferenciados, sin necesidad de etiquetas previas. Se busca que cada grupo esté formado por elementos internamente similares (alta cohesión) y que al mismo tiempo exista una clara separación respecto a los demás grupos (alta separación). Esta dualidad entre homogeneidad interna y heterogeneidad externa es clave en muchas técnicas de segmentación.

Este enfoque permite detectar estructuras internas en los datos que, de otro modo, pasarían desapercibidas. La validez de las agrupaciones obtenidas dependerá del contexto y de los criterios utilizados, por lo que también requiere juicio analítico.

Uno de los grandes desafíos del clustering consiste en identificar segmentaciones que sean coherentes y significativas, sin contar con información de referencia. El valor del proceso radica precisamente en su capacidad para revelar patrones latentes y facilitar una interpretación más profunda del conjunto analizado.

## ¿Cómo se mide la similitud?

En los métodos de agrupación, evaluar la similitud entre elementos es fundamental para determinar cómo se organizan los datos. Aunque este concepto puede parecer abstracto, en la práctica se representa habitualmente mediante una medida de distancia: cuanto más cerca se encuentran dos puntos en el espacio de características, más similares se consideran.

La forma en que se calcula esta distancia tiene un impacto directo en el resultado del análisis. Es precisamente esta medida la que guía al algoritmo a decidir qué elementos deben agruparse, por lo que influye en la composición final de los clústeres.

Existen distintas formas de calcular esa distancia —como la euclidiana, la Manhattan o la basada en el coseno— y cada una interpreta las relaciones entre los datos de manera distinta. Por eso, adaptar la métrica al tipo de variables y al objetivo concreto del análisis es un paso clave para obtener agrupaciones consistentes y significativas.

## Métricas de distancia habituales

En los algoritmos de clustering, la forma en que se cuantifica la distancia entre elementos determina cómo se agrupan los datos. A continuación se presentan algunas de las métricas más comunes utilizadas para evaluar similitud:

- **Distancia euclidiana.** Calcula la separación directa entre dos puntos en un espacio multidimensional. Refleja la distancia “geométrica” tradicional y es especialmente útil cuando las variables han sido normalizadas.
- **Distancia de Manhattan.** Suma las diferencias absolutas entre las coordenadas de cada dimensión. Representa trayectos en los que solo se puede avanzar en líneas rectas horizontales y verticales, lo que modifica la sensibilidad del agrupamiento respecto a la euclidiana.

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- **Distancia de Minkowski.** Generaliza las dos anteriores mediante un parámetro ajustable que controla la influencia relativa de las dimensiones. Permite adaptar el cálculo de la distancia según el tipo de dispersión que se quiera priorizar.
- **Distancia de Hamming.** Cuenta el número de posiciones en las que difieren dos vectores, y se emplea principalmente con datos categóricos o binarios. Es adecuada cuando lo relevante no es la magnitud de la diferencia, sino el número de discrepancias.
- **Distancia de Mahalanobis.** mide la separación entre un punto y un grupo considerando tanto la media como la covarianza de las variables. Tiene en cuenta la correlación entre dimensiones y es apropiada en contextos con variables relacionadas o redundantes.

La forma en que se define la distancia entre elementos influye directamente en el comportamiento de cualquier algoritmo de agrupación. Esta métrica determina cómo se comparan los puntos dentro del espacio de características y, en consecuencia, condiciona la formación y distribución de los grupos resultantes.

No existe una métrica única que funcione de manera óptima en todos los contextos. Su idoneidad depende de múltiples factores, como la naturaleza de los datos, la escala de las variables, su distribución o la presencia de correlaciones entre ellas.

Algunas métricas ofrecen buenos resultados cuando las variables están correctamente normalizadas y no presentan valores extremos, mientras que otras son más robustas frente a escalas distintas o relaciones entre dimensiones. La elección de una métrica adecuada debe considerar tanto las propiedades del conjunto de datos como los objetivos analíticos.


Además, ciertos algoritmos están diseñados para trabajar con una métrica específica, mientras que otros permiten ajustar este parámetro según las necesidades del análisis. Por todo ello, seleccionar la distancia apropiada no es solo un paso técnico, sino una decisión estratégica que afecta a la interpretación de los resultados y a la validez de las agrupaciones obtenidas.

## Modelos para formar clústeres

Los algoritmos de agrupación se pueden clasificar en función de cómo gestionan la pertenencia de los elementos a los distintos grupos. Cada enfoque parte de una concepción distinta sobre qué constituye un clúster, cómo se identifican las similitudes y qué tipo de estructuras se pueden extraer del conjunto de datos.

Algunas técnicas asignan cada elemento a un único grupo de forma exclusiva, mientras que otras permiten una pertenencia parcial o probabilística. Existen también métodos que construyen agrupaciones de forma jerárquica, así como enfoques basados en la densidad local del conjunto.

Esta variedad de estrategias permite adaptar el análisis a diferentes tipos de datos y objetivos, ofreciendo flexibilidad para trabajar con estructuras complejas o distribuciones no lineales.



Diferencias en la manera de agrupar según el algoritmo utilizado  
 Adaptación de: Patrik D'haeseleer: "How does gene expression clustering work?", Nature Biotechnology 23, 1499 - 1501 (2005).

A) El conjunto de datos contiene cuatro clústeres de diferentes tamaños, formas y puntos de datos. Se utilizó la distancia euclidiana, que corresponde a la distancia en línea recta entre puntos en este gráfico, para el agrupamiento.

B) El agrupamiento jerárquico encuentra toda una jerarquía de clústeres. El árbol se cortó al nivel indicado para obtener cuatro clústeres. Se pueden apreciar algunos de los superclústeres y subclústeres.

C) El K-means (con  $K = 4$ ) divide el espacio en cuatro subespacios, dependiendo de cuál de los cuatro centroides del clúster (estrellas) es el más cercano.

D) SOM encuentra clústeres, que se organizan en una estructura de cuadrícula (en este caso, una cuadrícula simple de 2 por 2).

- **Algoritmos de partición.** Los métodos de partición inician con una distribución preliminar —habitualmente aleatoria— de los datos en varios grupos. A través de un proceso iterativo, esa asignación se va ajustando con el objetivo de mejorar la coherencia interna de cada agrupación. Estos algoritmos requieren especificar de antemano cuántos grupos se desean obtener.

Existen dos variantes principales dentro de esta familia:

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Partición rígida.** Cada elemento se asigna exclusivamente a un único grupo. Algoritmos como K-means siguen este enfoque, en el que no hay solapamientos ni ambigüedad en la pertenencia.
- **Partición suave o probabilística.** Los métodos basados en modelos de mezclas, como las mezclas gaussianas (GMM), estiman una probabilidad de pertenencia para cada dato respecto a cada grupo. Esto permite reflejar incertidumbre y manejar mejor situaciones donde los límites entre agrupaciones no son claramente definidos.
- **Algoritmos jerárquicos.** Los métodos jerárquicos construyen agrupaciones anidadas, organizando los datos en distintos niveles de detalle. Esta estructura se forma mediante una sucesión de combinaciones o divisiones, y permite observar cómo evolucionan las relaciones entre los elementos a diferentes escalas.

Existen dos enfoques principales:

- **Jerarquía aglomerativa (ascendente).** Se parte de una situación en la que cada elemento constituye su propio grupo. En cada iteración, se fusionan los dos conjuntos más próximos hasta que se alcanza una única agrupación que contiene todos los datos.
- **Jerarquía divisiva (descendente).** Comienza con un único grupo que incluye todo el conjunto, y se va separando de forma progresiva en subconjuntos, eligiendo en cada etapa la partición más significativa.

El resultado se representa habitualmente mediante un dendrograma: un árbol que refleja visualmente cómo se agrupan o se separan los elementos. Las hojas corresponden a instancias individuales y la raíz al conjunto completo. Seleccionar un nivel de corte en el árbol permite obtener una partición concreta según el nivel de granularidad deseado. Estos métodos resultan especialmente útiles cuando se busca interpretar con claridad las relaciones jerárquicas dentro de los datos.

- **Algoritmos basados en densidad.** Este enfoque detecta agrupaciones localizando regiones del espacio donde los datos se concentran de forma significativa. Los elementos situados en zonas densas se consideran parte de un mismo grupo, mientras que aquellos más aislados se tratan como ruido o casos atípicos.

A diferencia de los métodos clásicos, estos algoritmos no requieren especificar el número de clústeres previamente. En su lugar, emplean parámetros como la distancia máxima entre puntos vecinos o el número mínimo de elementos en una región para definir qué constituye una agrupación válida.

Modelos como DBSCAN utilizan este criterio para construir agrupaciones con formas irregulares, detectar automáticamente el número de grupos y manejar con eficacia la presencia de valores atípicos. Este enfoque resulta útil en conjuntos complejos donde la estructura no es evidente a simple vista.

- Otros algoritmos
  - **Algoritmos basados en descomposición espectral.** Utilizan técnicas algebraicas, como la descomposición en valores propios, para analizar matrices de similitud entre

elementos. Esta aproximación permite detectar estructuras complejas o conexiones no evidentes en el espacio original. Se utiliza, por ejemplo, en el clustering espectral.

- **Algoritmos que dividen el espacio en celdas.** Separan el conjunto de datos en regiones pequeñas y regulares, evaluando la densidad local dentro de cada celda. A partir de esta información, se identifican posibles agrupaciones. Este tipo de estrategias es eficiente con grandes volúmenes de datos y se aplica en métodos como los basados en grid.
- **Algoritmos de agrupación difusa.** Permiten que cada elemento tenga diferentes grados de pertenencia a múltiples grupos. A diferencia de los métodos estrictos, no asignan un único clúster por elemento, sino que expresan la afinidad relativa con cada grupo. Este enfoque corresponde a técnicas de clustering fuzzy.
- **Algoritmos fundamentados en lógica difusa.** Incorporan formalmente la teoría de conjuntos difusos para definir la pertenencia de los elementos de manera gradual. En lugar de clasificaciones binarias, ofrecen representaciones continuas, más adecuadas cuando las fronteras entre categorías no están claramente definidas.

## Reducción de dimensiones con PCA

En muchos análisis, especialmente cuando se trabaja con conjuntos que contienen un elevado número de variables, resulta necesario simplificar la información para poder interpretarla y procesarla con mayor eficacia. La reducción de dimensiones permite representar los datos en un espacio más compacto, sin perder su estructura esencial.

Entre las técnicas más utilizadas para este fin se encuentra el Análisis de Componentes Principales (PCA), un método que transforma el conjunto original en un nuevo sistema de variables, con el objetivo de conservar la mayor parte de la información relevante en un número reducido de dimensiones.

### ¿Qué es el PCA?

El PCA es una técnica fundamental en el análisis de datos que reduce la complejidad de grandes conjuntos de variables. Esta metodología convierte las variables originales en un conjunto de nuevas variables, conocidas como componentes principales, que son independientes entre sí y facilitan la interpretación.

Algunas de sus propiedades más destacadas son:

- **Reducción sin pérdida significativa de información.** El PCA permite disminuir el número de variables conservando la estructura principal del conjunto, lo que resulta especialmente útil cuando se trabaja con datos de alta dimensionalidad.
- **Transformación basada en la variabilidad.** El método identifica las direcciones en las que los datos presentan mayor dispersión y define esos ejes como los componentes principales. Cuanto mayor sea la varianza explicada por un componente, más información contiene.
- **Independencia entre componentes.** Los componentes obtenidos están contruidos de forma que no guardan correlación entre ellos. Esto facilita su interpretación y evita redundancias, mejorando también el rendimiento en ciertos modelos predictivos.

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Conservación de la varianza.** Aunque se reduce el número de dimensiones, el método prioriza conservar la máxima cantidad de variabilidad posible. Los primeros componentes concentran la mayor parte de la información, mientras que los últimos suelen contener detalles menos relevantes o ruido.
- **Aplicaciones diversas.** Además de su uso para simplificar conjuntos complejos, el PCA también se emplea para visualizar datos en dos o tres dimensiones, eliminar redundancias, comprimir información o mejorar la eficiencia computacional en modelos de aprendizaje automático.
- **Importancia de la escala.** Dado que el PCA se basa en la variabilidad de los datos, es imprescindible normalizar las variables antes de aplicarlo. De lo contrario, las que tienen escalas mayores pueden dominar la transformación y alterar los resultados.

## ¿Por qué reducir dimensiones?

La reducción de dimensiones es crucial cuando se trabajan con datos con muchas variables, ya que un exceso de información puede complicar el análisis y ralentizar los procesos. Al reducir el número de dimensiones, conseguimos simplificar el modelo sin perder la esencia de los datos.

Al disminuir el número de variables, se simplifica el espacio de características, lo que permite:

- Mejorar la eficiencia de los algoritmos al reducir la carga de procesamiento
- Facilitar la visualización e interpretación de los datos
- Evitar redundancias entre variables que aportan información similar
- Eliminar ruido o detalles poco relevantes que dificultan la extracción de patrones útiles

La reducción de dimensiones ayuda a centrarse en la información más significativa sin perder la estructura esencial del conjunto de datos.

## ¿Cómo funciona?

Para aplicar el PCA, se sigue una serie de pasos que permiten transformar los datos en una forma más simplificada pero manteniendo las relaciones clave entre las variables. Este proceso no solo facilita el análisis, sino que también mejora la eficiencia del procesamiento de datos.

Los pasos habituales son los siguientes:

1. **Preparar los datos.** Antes de empezar, es necesario normalizar las variables para que todas tengan la misma escala. Esto implica ajustar sus valores para que tengan media cero y desviación estándar uno. Si no se estandarizan, las variables con valores mayores influirán de forma desproporcionada en el resultado final.
2. **Analizar la relación entre las variables.** A continuación, se calcula una matriz que recoge la relación entre las diferentes variables. Dependiendo del caso, puede ser una matriz de covarianza (si las variables tienen escalas distintas) o de correlación (si ya han sido normalizadas o están en la misma escala).
3. **Extraer los componentes principales.** Mediante una descomposición matemática de la matriz anterior, se obtienen los vectores propios (direcciones principales de variación) y los valores propios (medida de la varianza que explica cada dirección).

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)





4. **Seleccionar los componentes relevantes.** Una vez calculados, los componentes se ordenan en función de la cantidad de varianza que explican. Se eligen los primeros que acumulan un porcentaje elevado de la información total, lo que permite reducir dimensiones sin perder contenido esencial.
5. **Transformar los datos.** Finalmente, el conjunto original se proyecta sobre los ejes definidos por los componentes seleccionados. Esto genera una nueva versión del conjunto de datos, con menos dimensiones, más simple de interpretar y con menor redundancia.

## Decidir cuántos componentes conservar

Una de las decisiones clave al aplicar el PCA es seleccionar cuántos componentes mantener en el modelo. Esta elección determina el balance entre la complejidad y la capacidad de representar la variabilidad original de los datos, buscando siempre la mayor eficiencia.

A mayor número de componentes, se preserva más variabilidad de los datos, pero también se incrementa el volumen de información a procesar. En cambio, reducir excesivamente el número de componentes puede simplificar el análisis, pero con el riesgo de perder patrones importantes. Por eso, es fundamental encontrar un equilibrio adecuado entre precisión y simplicidad.

A continuación, se presentan algunas estrategias útiles para tomar esta decisión:

- **Observar la varianza explicada acumulada.** Una opción común es seleccionar los primeros componentes que, en conjunto, explican un porcentaje elevado de la variabilidad total, como el 95 % o el 99 %. También puede optarse por un número fijo si tiene sentido en el contexto del problema o facilita la interpretación.
- **Ajustar según el nivel de detalle necesario.** Reducir mucho el número de componentes simplifica el conjunto resultante, pero puede hacer que se pierda información relevante. En cambio, conservar demasiados componentes puede mantener datos redundantes o ruido. El objetivo es ajustar el número para conservar lo esencial sin sobrecargar el análisis.
- **Comparar diferentes configuraciones.** Probar varias opciones y observar cómo afectan al rendimiento es una estrategia eficaz. Esto se puede hacer midiendo la precisión de un modelo posterior, la claridad en la visualización o la eficiencia del procesamiento. La validación cruzada o el uso de un conjunto de prueba pueden ayudar a valorar las alternativas.
- **Mejorar la eficiencia computacional.** Reducir la dimensionalidad también implica trabajar con menos variables, lo que agiliza los cálculos y mejora la velocidad de procesamiento, especialmente en conjuntos de datos muy grandes. Esto convierte al PCA no solo en una herramienta de análisis, sino también en una forma de optimizar recursos.



## Evaluación de la calidad del modelo

Tras aplicar un algoritmo de clustering, es esencial analizar si los grupos formados representan correctamente la estructura subyacente de los datos. Para ello, se utilizan diferentes métricas que permiten evaluar la cohesión y separación de los clústeres generados.

El tipo de métrica a utilizar dependerá de si se dispone de información previa sobre las clases reales. Si existe una referencia externa, se pueden usar medidas comparativas. En cambio, si los datos no tienen etiquetas, habrá que evaluar la calidad interna del agrupamiento en función de su cohesión y separación.

### ¿Cómo evaluar un modelo con etiquetas? Métricas externas

Cuando se dispone de las clases reales de los datos, es posible comparar directamente las agrupaciones obtenidas con la estructura esperada. Para ello se utilizan métricas externas, que miden el grado de coincidencia entre los clústeres generados y las categorías conocidas:

- **Adjusted Rand Score (ARI).** Evalúa la similitud entre dos asignaciones de clústeres, ajustando por coincidencias aleatorias. Sus valores oscilan entre -1 y 1, donde 1 representa una correspondencia perfecta entre las agrupaciones y las clases reales.
- **Homogeneity.** Mide si cada clúster contiene únicamente elementos de una misma clase. Un valor de 1 indica que todos los puntos dentro de un grupo pertenecen a la misma categoría.
- **Completeness.** Verifica si todos los elementos de una clase concreta están contenidos en un solo clúster. Un valor de 1 indica que cada clase está completamente recogida dentro de un único grupo.
- **V-Measure.** Es la media armónica entre homogeneidad y completitud. Proporciona una visión global que combina la pureza interna de los grupos y la cobertura de las clases.
- **Visualización.** Representar los datos de forma gráfica, por ejemplo con diagramas de dispersión, permite observar de manera intuitiva la distribución de los clústeres y detectar solapamientos o agrupaciones mal definidas.

### ¿Cómo evaluar un modelo sin etiquetas? Métricas internas

En ausencia de etiquetas externas, se utilizan métricas internas que miden la calidad de los clústeres a partir de sus propias características. Estas métricas evalúan la homogeneidad de los grupos y su separación, ayudando a determinar si el modelo ha encontrado patrones significativos:

- **Índice de silueta (Silhouette Score).** Mide la calidad de la asignación de cada punto a su clúster, comparando la cohesión interna con la separación respecto a otros clústeres. Su valor va de -1 a 1, siendo 1 el mejor valor, que indica que los puntos están bien agrupados y alejados de otros clústeres.
- **Índice de Davies-Bouldin (DBI).** Calcula la relación entre la densidad interna de los clústeres y la distancia entre ellos. Valores más bajos indican una mejor partición, ya que reflejan una mayor separación entre los clústeres y una mayor cohesión dentro de cada uno.

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Coeficiente de Calinski-Harabasz.** Evalúa la separación entre los clústeres y su compactación interna. Cuanto más alto sea el valor, mejor será la estructura de los clústeres, ya que indica mayor distancia entre los centros y menor dispersión dentro de los mismos.
- **Índice de Dunn.** Mide la relación entre la distancia mínima entre clústeres y la dispersión dentro de ellos. Valores más altos sugieren una mejor separación entre clústeres y una mayor cohesión interna.
- **Inercia (Inertia).** Calcula la suma de las distancias cuadradas de cada punto a su centroide correspondiente. Un valor bajo de inercia indica que los puntos están más agrupados alrededor del centro de su clúster, lo que es deseable en muchos casos.

## Caso práctico simulado

Imaginemos que hemos aplicado un algoritmo de clustering para dividir un conjunto de datos en X grupos. En este caso, hemos utilizado un tipo de agrupamiento exclusivo, donde cada punto pertenece exclusivamente a un solo clúster, sin posibilidad de pertenencia compartida. Aunque existen técnicas que permiten pertenencias múltiples, no se tratan en esta unidad.

Tras aplicar el modelo, los resultados obtenidos son los siguientes:

- **Inercia:** 438.75
- **Adjusted Rand Score:** 0.86
- **Homogeneidad:** 0.81
- **Complejidad:** 0.84
- **V-Measure:** 0.82
- **Silhouette:** 0.53
- **Davies-Bouldin:** 0.68
- **Calinski-Harabasz:** 318.40

Estos resultados reflejan un comportamiento bastante satisfactorio del modelo. A pesar de que siempre es posible mejorar, las métricas indican que los clústeres generados son coherentes y que los grupos identificados capturan de forma precisa la estructura de los datos.

- **Inercia.** El valor obtenido, 438.75, indica que los puntos dentro de cada clúster están razonablemente cercanos entre sí, lo que sugiere que los clústeres son compactos. Aunque la inercia baja generalmente está asociada con agrupaciones más coherentes, se puede seguir ajustando para mejorar la cohesión.
- **Adjusted Rand Score.** Con un valor de 0.86, el *Adjusted Rand Score* muestra una alta similitud entre las agrupaciones obtenidas y las clases reales (si están disponibles). Este buen resultado demuestra que el modelo ha logrado identificar correctamente la estructura de los datos.
- **Homogeneidad, Complejidad y V-Measure.** Las métricas de homogeneidad (0.81), completitud (0.84) y V-Measure (0.82) sugieren que los clústeres están bien definidos: cada grupo contiene puntos que pertenecen mayormente a una misma clase y las clases están correctamente distribuidas en los grupos. La V-Measure, que equilibra ambas métricas, refuerza esta interpretación.
- **Silhouette.** Con un valor de 0.53, el índice de silueta indica que los puntos están más cerca de su propio clúster que de otros, lo que demuestra una separación aceptable. Aunque no

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



perfecta, la separación es lo suficientemente buena como para indicar que el modelo es funcional.

- **Davies-Bouldin.** El valor de 0.68 en el índice de Davies-Bouldin señala que los clústeres están bien separados y que la densidad interna de los mismos es adecuada. Cuanto menor sea este valor, mejor será la calidad del agrupamiento.
- **Calinski-Harabasz.** El alto valor de 318.40 indica una buena separación entre los clústeres y una compactación interna satisfactoria. Esto refuerza la idea de que el modelo ha logrado una segmentación clara y bien definida de los datos.

Los indicadores sugieren que el modelo de clustering ha funcionado correctamente. Aunque se podrían hacer ajustes adicionales, los resultados son lo suficientemente sólidos como para considerar que la segmentación es adecuada. Las métricas permiten asegurar que los clústeres reflejan de manera efectiva la estructura de los datos.

## ¿Se puede mejorar un modelo sin saber la respuesta?

Mejorar un modelo en un entorno no supervisado no implica compararlo con respuestas conocidas, ya que estas no existen. En lugar de eso, se trata de ajustar el modelo para obtener clústeres coherentes que representen adecuadamente los datos de forma eficiente.

A continuación se presentan algunas estrategias clave para optimizar el modelo:

- **Probar diferentes configuraciones.** En algunos algoritmos, como K-means, las decisiones iniciales influyen significativamente en el resultado final. Por ejemplo, la elección del número de clústeres es un parámetro crítico. Ajustar estos hiperparámetros requiere probar diferentes configuraciones y evaluar cuál da los mejores resultados.
- **Simplificar el espacio de trabajo.** No siempre es necesario utilizar todas las variables disponibles. Técnicas como el PCA permiten reducir el número de dimensiones sin perder la información más relevante. Esto no solo facilita la interpretación, sino que también mejora la eficiencia del procesamiento al reducir la carga computacional.
- **Optimizar el rendimiento.** El objetivo no es solo que el modelo funcione, sino que lo haga de manera eficiente. Reducir el número de variables, elegir algoritmos más ligeros o ajustar los parámetros adecuados puede acelerar significativamente el tiempo de cálculo, lo que es esencial cuando se trabaja con grandes volúmenes de datos.
- **Valorar la calidad sin etiquetas.** Aunque no tengamos etiquetas reales para comparar, se pueden emplear métricas internas, como Silhouette, Davies-Bouldin o Calinski-Harabasz, para evaluar la calidad del clustering. También es útil realizar una inspección visual de los clústeres, observando si las agrupaciones tienen sentido y si los grupos están bien diferenciados o se solapan.

Mejorar un modelo sin supervisión requiere ensayo, análisis y ajustes continuos. Aunque no hay una solución única, ajustar los parámetros, reducir dimensiones y evaluar los resultados desde diferentes perspectivas ayuda a conseguir modelos más robustos y eficientes.

---

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)

