

Lección 2. Agrupación con k-medias y métodos jerárquicos: funcionamiento y aplicación

En esta lección exploraremos dos de los enfoques más utilizados para realizar agrupamientos sobre datos no etiquetados: el método de K-means y los métodos jerárquicos. Ambos permiten descubrir patrones y estructuras en los datos, pero lo hacen de forma distinta y con características particulares que conviene conocer.

K-means es un algoritmo eficiente que parte de un número de grupos predefinido y busca asignar cada elemento al grupo más cercano. En cambio, los métodos jerárquicos construyen agrupamientos de forma progresiva, sin necesidad de fijar de antemano el número de clústeres, lo que los hace especialmente útiles para explorar diferentes niveles de agrupación.


A lo largo de la unidad veremos cómo funcionan estos métodos, qué decisiones hay que tomar para aplicarlos correctamente y en qué contextos resulta más adecuado utilizar uno u otro.

¿Qué es el agrupamiento con K-means y cómo funciona?

El algoritmo K-means es una técnica muy utilizada para agrupar datos no etiquetados. Su objetivo es dividir el conjunto de datos en grupos bien definidos o clústeres, de forma que los elementos de cada grupo sean lo más parecidos posible entre sí y diferentes de los elementos de los demás grupos.

Este método funciona de manera iterativa y parte de una idea clave: el número de clústeres deseado (K) debe conocerse o estimarse antes de aplicar el algoritmo. A partir de ahí, el proceso se basa en la cercanía entre los datos y ciertos puntos centrales llamados centroides, que representan el "centro" de cada grupo.

Aunque es un algoritmo sencillo en su planteamiento, su comportamiento depende de varias decisiones que veremos a continuación, como la elección del número de grupos, el modo de iniciar el proceso o el criterio para determinar cuándo ha finalizado.



Clústeres identificados por K-means

Puntos fuertes y limitaciones del algoritmo K-means

K-means destaca por su eficiencia, ya que permite trabajar con conjuntos de datos grandes sin requerir demasiados recursos computacionales. Su simplicidad y facilidad de uso lo hacen accesible incluso para quienes están empezando con técnicas de agrupamiento. Además, ofrece una gran flexibilidad, ya que puede aplicarse a distintos tipos de datos numéricos, así como a representaciones vectoriales de textos o imágenes. Sus resultados son fáciles de interpretar, ya que cada dato queda asociado a un grupo con un centroide representativo, lo que facilita el análisis visual y la comprensión de las agrupaciones obtenidas.

A pesar de sus ventajas, también tiene limitaciones importantes. Es sensible a la inicialización de los centroides, lo que puede llevar a resultados distintos si se parte de posiciones diferentes, y a menudo se queda atrapado en óptimos locales. Requiere decidir de antemano el número de grupos, algo que no siempre es evidente. Funciona bien cuando los clústeres son esféricos, de tamaño y densidad similares, pero pierde precisión cuando los grupos tienen formas irregulares o no están claramente separados. Tampoco es adecuado para conjuntos de datos que no pueden dividirse linealmente, ya que tiende a forzar particiones poco realistas en estos casos.


Fases del algoritmo

1. **Determinación del número de clústeres (K).** El primer paso consiste en definir cuántos grupos se desean formar. Este valor, conocido como K, es fundamental porque condiciona la estructura del agrupamiento y debe establecerse antes de ejecutar el algoritmo. Determinar K requiere criterios adecuados, ya que una mala elección puede producir agrupamientos poco representativos. Más adelante exploraremos métodos como el codo, la silueta o los criterios de información para estimar el valor óptimo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)




2. **Inicialización estratégica de los centroides.** Una vez fijado el número de clústeres, se seleccionan los centroides iniciales, que actuarán como puntos de referencia para formar los grupos. Esta inicialización no es trivial, ya que puede afectar tanto a la velocidad de convergencia como a la calidad final del agrupamiento. Existen varios métodos para este paso, desde la selección aleatoria hasta enfoques más elaborados como K-means++, que mejora la distribución inicial de los centroides para evitar soluciones subóptimas.
3. **Asignación de observaciones a los clústeres.** En esta fase, cada observación del conjunto de datos se asigna al clúster cuyo centroide esté más próximo, normalmente utilizando la distancia euclidiana como métrica. Esta etapa define la estructura provisional de los grupos y es clave para evaluar la coherencia interna del agrupamiento.
4. **Actualización de los centroides mediante promedios.** Una vez asignados los puntos, se actualiza la posición de cada centroide. Esto se hace calculando la media de todos los puntos asignados a cada grupo. En algunos casos, si el modelo no mejora, se puede realizar una nueva inicialización de los centroides para evitar quedar atrapados en una solución subóptima.
5. **Iteración hasta la convergencia del modelo.** Los pasos de asignación y actualización se repiten sucesivamente hasta que el modelo alcanza la convergencia. Esto sucede cuando las asignaciones ya no cambian significativamente entre iteraciones o cuando se minimiza una métrica interna como la inercia. El proceso se detiene si se alcanza una configuración estable o si se llega al número máximo de iteraciones establecido.



Fases del algoritmo K-means


¿Cómo decidir cuántos grupos formar? Desarrollo de la fase 1: Determinación del número de clústeres (K)

El número de clústeres, representado por la letra K, es una de las decisiones más importantes a la hora de aplicar el algoritmo K-means. Este valor determina cuántos grupos se formarán en los datos y afecta directamente a la estructura del resultado. Una K mal elegida puede generar agrupamientos poco representativos: si es demasiado baja, puede unir datos distintos en un mismo grupo; si es demasiado alta, puede dividir excesivamente patrones que en realidad forman una sola categoría.




Elección del valor K que determina el número de clústeres

- Existen varias estrategias para estimar un valor adecuado de K, y en la práctica es habitual combinarlas para tomar una decisión informada. Una de las más conocidas es el método del codo (*elbow method*). Consiste en aplicar K-means con distintos valores de K y representar gráficamente la inercia —es decir, la suma de las distancias cuadradas entre cada punto y su centroide—. A medida que K aumenta, la inercia disminuye, pero llega un momento en que la mejora se vuelve marginal. Ese punto de inflexión se interpreta como el valor óptimo de K.



Ejemplo de estimación del valor óptimo de K mediante el método del codo

- Otra técnica es el método de la silueta, que evalúa la calidad de los clústeres comparando la distancia media entre puntos de un mismo clúster (cohesión) y la distancia a puntos de otros clústeres (separación). El resultado es un valor entre -1 y 1, y cuanto más alto, mejor está definido el agrupamiento. El valor de K que maximiza la silueta media suele ser una buena elección.



Ejemplo de estimación del número óptimo de clústeres mediante el método Silhouette

- También se pueden aplicar criterios de información, como el AIC (Akaike Information Criterion) o el BIC (Bayesian Information Criterion), que permiten comparar modelos penalizando la complejidad excesiva. Estos métodos son útiles cuando se busca el equilibrio entre ajuste y simplicidad.
- En algunos casos se utiliza la validación interna o externa. Si se dispone de etiquetas reales, se puede evaluar el agrupamiento comparándolo con esa información (validación externa). Si no hay etiquetas, se utilizan métricas estadísticas internas como la cohesión o la silueta.
- Finalmente, el análisis exploratorio de los datos o el conocimiento del dominio también pueden dar pistas. Visualizar los datos en dos dimensiones o conocer los patrones esperables en el contexto puede ayudar a acotar el número de clústeres razonable.

No hay una fórmula exacta para decidir K. La clave es combinar diferentes métodos, evaluar los resultados y, si es necesario, probar varios valores para ver cuál ofrece un agrupamiento más coherente y útil para el análisis.

¿Cómo se eligen los centroides iniciales? Desarrollo de la fase 2: Inicialización estratégica de los centroides

En el algoritmo K-means, los centroides iniciales se seleccionan antes de empezar las iteraciones. Esta elección es fundamental, ya que puede influir en el número de pasos necesarios para llegar a una solución y en la calidad final del agrupamiento. A continuación, se presentan algunas de las estrategias más utilizadas para iniciar el proceso:

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Selección aleatoria.** Es la forma más simple de inicialización. Consiste en elegir K puntos del conjunto de datos al azar. Aunque es fácil de aplicar, puede provocar resultados poco consistentes si los puntos elegidos están mal distribuidos o demasiado próximos entre sí.
- **K-means++.** Este método mejora la selección inicial. Empieza eligiendo un punto aleatorio y después selecciona los siguientes dando más probabilidad a los que están más alejados de los ya elegidos. Así se asegura que los centroides iniciales estén bien repartidos por el espacio de datos, lo que mejora la calidad del agrupamiento y acelera la convergencia.
- **Inicialización basada en clústeres jerárquicos.** Consiste en aplicar un método jerárquico para dividir los datos en grupos y usar los centroides de esos grupos como punto de partida para K-means. Es útil cuando es útil combinar diferentes técnicas de agrupamiento.
- **Inicialización basada en densidad.** Se usan algoritmos como DBSCAN para detectar regiones densas en el conjunto de datos. A partir de ahí, se seleccionan centroides en esas zonas con alta concentración, pensando que son buenos puntos representativos.
- **Selección manual o basada en conocimiento experto.** Cuando se conoce bien el dominio de los datos, puede ser útil fijar manualmente los puntos iniciales. Por ejemplo, si ya se sabe que ciertos valores representan casos típicos o centros esperables, se pueden usar como centroides desde el principio.
- **Inicialización basada en información previa.** En algunos casos, se dispone de información histórica o resultados anteriores. Si se han usado centroides con buenos resultados en otros agrupamientos similares, se pueden reutilizar directamente.

Escoger bien los centroides al principio puede evitar problemas posteriores y hacer que el modelo trabaje de forma más eficiente y precisa.

¿Cómo se asignan los puntos a los clústeres? Desarrollo de la fase 3: Asignación de observaciones a los clústeres

Una vez establecidos los centroides iniciales, el siguiente paso consiste en asignar cada punto del conjunto de datos al clúster que tenga el centroide más cercano. Esta etapa es clave, ya que define la estructura inicial de los grupos sobre los que después se recalcularán los centroides.

La asignación se basa en una métrica de distancia, siendo la más común la **distancia euclidiana**. Esta medida calcula la distancia recta entre dos puntos en el espacio. Cuanto más cerca esté un punto de un centroide, más probable será que pertenezca a ese clúster.

El procedimiento es sencillo:

1. Para cada punto, se calcula su distancia a cada uno de los centroides.
2. Se asigna el punto al clúster del centroide más cercano.
3. Esta asignación se repite para todos los puntos del conjunto de datos.

Este proceso se realiza en cada iteración del algoritmo, ya que los centroides se irán actualizando y, por tanto, las asignaciones también pueden cambiar. El objetivo es que, a medida que los centroides se reubican, las observaciones se agrupen junto con los puntos que presenten mayor similitud dentro del conjunto.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Aunque parezca una operación sencilla, su repetición constante en grandes volúmenes de datos requiere una buena optimización para mantener la eficiencia del modelo.

¿Cómo se actualizan los centroides? Desarrollo de la fase 4: Actualización de los centroides mediante promedios

Después de asignar cada punto al centroide más cercano, el siguiente paso consiste en recalculer la posición de cada centroide. Esta actualización se basa en la media de los puntos que pertenecen a su clúster. Es decir, el nuevo centroide se coloca en el centro geométrico de todas las observaciones asignadas a ese grupo.

El procedimiento es el siguiente:

1. Para cada clúster, se identifican todos los puntos que han sido asignados a él en la iteración actual.
2. Se calcula la media de las coordenadas de esos puntos.
3. Esa media define la nueva posición del centroide.

Este proceso garantiza que cada centroide se desplace hacia el centro real del grupo de datos que representa, ajustando su ubicación para reflejar mejor la distribución interna del clúster. A medida que los centroides se reubican, también cambian las asignaciones, por lo que esta operación se repite en varias iteraciones.

La actualización por media es especialmente adecuada cuando los datos son numéricos y los clústeres tienen forma aproximadamente esférica. Si los grupos son muy irregulares o los datos no son numéricos, este cálculo puede no reflejar bien la estructura real del conjunto.

Este paso se repite junto con la asignación de puntos hasta que el modelo se estabiliza, es decir, hasta que los centroides dejan de moverse significativamente.

¿Cuándo termina el algoritmo? Desarrollo de la fase 5: Iteración hasta la convergencia del modelo

El algoritmo K-means se basa en un proceso iterativo en el que, en cada paso, se asignan los puntos a los centroides más cercanos y luego se recalculan esos centroides según los puntos asignados. Este ciclo de asignación (fase 3) y actualización (fase 4) se repite con el objetivo de ajustar progresivamente la posición de los centroides para que representen lo mejor posible a cada grupo de datos.

Este proceso continúa hasta alcanzar una situación estable en la que las asignaciones ya no cambian de forma significativa. A este estado se le llama **convergencia del modelo**, y significa que el algoritmo ha encontrado una estructura coherente de agrupamiento: los centroides se mantienen prácticamente en la misma posición y los puntos asignados a cada grupo ya no varían.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Durante todo el proceso, una métrica clave para evaluar la calidad del modelo es la **inercia**, que mide lo compactos que están los puntos dentro de cada clúster. Cuanto menor sea esta medida, más cerca estarán los puntos de su centroide y, por tanto, mejor definido estará el agrupamiento. K-means busca precisamente minimizar esta inercia a lo largo de las iteraciones. Cuando los cambios en la inercia dejan de ser significativos o se alcanza el número máximo de iteraciones definido, el algoritmo se detiene y se considera que ha finalizado correctamente.

Hiperparámetros del algoritmo K-means

En Python, el algoritmo K-means incluye varios **hiperparámetros** que permiten ajustar su comportamiento para mejorar la calidad del agrupamiento y la estabilidad de los resultados. Estos parámetros pueden configurarse fácilmente al utilizar la implementación de [scikit-learn](#).


A continuación se detallan los más relevantes:

- **n_clusters:** Es el número de clústeres que se desea encontrar. Representa el valor de K en el algoritmo.
- **init:** Define el método de inicialización de los centroides. Las opciones más comunes son `'k-means++'`, que mejora la distribución inicial, `'random'`, que selecciona centroides al azar, y `'lloyd'`, que es una implementación más reciente y optimizada. También se puede proporcionar manualmente un conjunto de centroides iniciales.
- **n_init:** Indica cuántas veces se ejecutará el algoritmo con diferentes inicializaciones. De todas las ejecuciones, se selecciona la que tenga la menor inercia. Cuanto mayor sea este valor, más probabilidades habrá de obtener un buen resultado.
- **max_iter:** Es el número máximo de iteraciones permitidas en cada ejecución del algoritmo. Sirve para evitar bucles largos si el modelo tarda en converger.
- **tol:** Es el valor de tolerancia utilizado como criterio de parada. Si el cambio en la posición de los centroides entre iteraciones es menor que este umbral, el algoritmo se considera convergente y se detiene.

¿Qué es el agrupamiento jerárquico y cómo funciona?

El agrupamiento jerárquico (*Hierarchical Clustering*) es una técnica que permite clasificar los datos en grupos o clústeres en función de su similitud. Organiza las observaciones en una estructura con forma de árbol, donde cada nivel representa una posible agrupación. Este tipo de representación facilita entender las relaciones entre los elementos del conjunto de datos y explorar diferentes niveles de agrupación según el detalle que se necesite.


Los puntos individuales se agrupan paso a paso en función de su proximidad. La estructura que se forma, conocida como **dendrograma**, representa gráficamente cómo se van uniendo los elementos y permite decidir fácilmente cuántos grupos formar, simplemente cortando el árbol a la altura deseada.



Funcionamiento del agrupamiento jerárquico

Una de las ventajas principales de este tipo de agrupamiento es que permite analizar los datos a distintos niveles de granularidad. Es posible observar tanto una visión general como detalles más específicos, lo que facilita la identificación de patrones, la comprensión de la estructura interna de los datos y la detección de relaciones ocultas.

Además, este tipo de análisis permite detectar **valores atípicos** o puntos que no encajan claramente en ningún grupo. Estos elementos suelen quedar aislados o separados en ramas concretas del dendrograma, lo que facilita su identificación como posibles outliers.



Detección de valores atípicos


Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Tipos de enfoque: aglomerativo y divisivo

El agrupamiento jerárquico se puede aplicar de dos maneras distintas, según el enfoque que se utilice: aglomerativo o divisivo. Ambos construyen la estructura jerárquica, pero lo hacen en direcciones opuestas.

- El **enfoque aglomerativo** (también conocido como *bottom-up*) es el más común. Parte de la idea de que cada observación comienza formando su propio clúster. A partir de ahí, se van uniendo los grupos más similares en cada paso, hasta que todos los elementos quedan unidos en una única agrupación. Este proceso va construyendo la jerarquía desde abajo hacia arriba y se puede visualizar fácilmente en un dendrograma. El algoritmo AGNES (Agglomerative Nesting) es un ejemplo típico de este enfoque.
- Por otro lado, el **enfoque divisivo** (*top-down*) comienza con un único grupo que contiene todos los datos. En cada paso, este gran clúster se va dividiendo en grupos más pequeños, hasta que cada observación queda aislada o se alcanza un número determinado de clústeres. Este método sigue el proceso contrario al aglomerativo y es menos habitual, pero útil en ciertos contextos. El algoritmo DIANA (Divisive Analysis) es un ejemplo representativo de este enfoque.



Diferencia entre el método aglomerativo y el divisivo

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Ambos métodos permiten construir la misma estructura jerárquica, pero con estrategias distintas. La elección entre uno u otro dependerá del tipo de problema, del tamaño del conjunto de datos y de las necesidades específicas del análisis.

Características principales del agrupamiento jerárquico

El agrupamiento jerárquico tiene un conjunto de propiedades que lo hacen especialmente útil en tareas exploratorias. Algunas de estas características aportan ventajas claras respecto a otros métodos, mientras que otras suponen limitaciones que deben tenerse en cuenta según el tipo de datos o el objetivo del análisis.

- **No necesita definir el número de clústeres al inicio.** A diferencia de otros algoritmos como K-means, permite construir toda la estructura jerárquica sin especificar previamente cuántos grupos se desean. Esto permite decidir el número de clústeres más adelante, una vez se ha visualizado la distribución real de los datos.
- **Permite distintos niveles de análisis.** Gracias al formato jerárquico, se puede observar el agrupamiento a diferentes profundidades. Es posible hacer un análisis general o explorar detalles más finos ajustando el nivel de corte del dendrograma.
- **Facilita la detección de dependencias internas.** El modelo permite identificar relaciones entre grupos y subgrupos, cosa que ayuda a entender mejor la organización natural de los datos y a detectar estructuras anidadas.
- **Ofrece visualización clara mediante el dendrograma.** La estructura que se genera es fácil de interpretar gráficamente, especialmente en conjuntos pequeños o medianos. El dendrograma permite identificar grupos compactos, posibles errores o valores atípicos que quedan separados.
- **Tiene limitaciones con conjuntos de datos grandes.** El coste computacional crece rápidamente, ya que es necesario calcular y almacenar todas las distancias entre pares de datos. Esto lo hace menos práctico con volúmenes muy altos.
- **No se puede actualizar de forma incremental.** Una vez construido, el modelo no admite incorporar nuevos datos sin repetir todo el proceso. No es apto para contextos donde los datos se actualizan de forma continua.
- **Las decisiones tempranas no se corrigen.** Cada fusión o división que se produce es irreversible. Si se toman malas decisiones en los primeros pasos, estas afectarán directamente al resultado final.
- **Es sensible a la distancia y al método de enlace usados.** Diferentes configuraciones pueden generar dendrogramas muy distintos. Es recomendable probar varias combinaciones y validar con métricas de calidad para asegurar un buen agrupamiento.

Método aglomerativo (Bottom-up)

El agrupamiento aglomerativo, también llamado *bottom-up*, es el enfoque jerárquico más utilizado. Este método parte de que cada observación constituye inicialmente su propio clúster. A medida que avanza el algoritmo, los clústeres más cercanos se van fusionando sucesivamente, hasta que se forma una única agrupación que contiene todos los datos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Una ventaja de este método es que permite trabajar con grandes volúmenes de datos, especialmente si se usa junto con una **matriz de conectividad**. Esta matriz define qué puntos son vecinos según una estructura previa, y actúa como restricción: solo pueden fusionarse entre sí los clústeres que estén conectados. Si no se imponen estas restricciones, el algoritmo debe considerar todas las combinaciones posibles en cada paso, lo cual puede resultar muy costoso a nivel computacional.

El uso de restricciones de conectividad es especialmente útil cuando se trabaja con datos estructurados espacial o secuencialmente. Por ejemplo, se pueden limitar las fusiones a observaciones adyacentes en una rejilla, en una imagen o en una serie temporal, mejorando la coherencia de los agrupamientos.

Criterio de similitud entre clústeres

En el agrupamiento jerárquico aglomerativo, la forma en que se decide qué clústeres deben unirse en cada paso depende de cómo se mida la similitud entre ellos. Esta similitud se calcula a partir de la distancia entre los elementos de cada grupo, pero el modo concreto de hacerlo puede variar según el método que se elija.

A esta forma de calcular la distancia entre clústeres se le conoce como criterio de enlace o método de vinculación. La elección de este criterio es importante, ya que determina cómo evoluciona el agrupamiento y qué estructura final tendrá el dendrograma. Según el criterio usado, se priorizarán uniones más compactas, más dispersas o con menor variación interna.

Métodos de enlace (linkage)

Durante el agrupamiento jerárquico, el algoritmo necesita decidir en cada paso qué clústeres se deben unir. Para tomar esta decisión, utiliza lo que se conoce como método de enlace, que es una forma de calcular la distancia o la similitud entre dos clústeres.

Cada método de enlace tiene su propia lógica, y según el que se utilice, se formarán agrupaciones con formas y tamaños distintos.

- **Enlace completo.** La distancia entre dos clústeres se define como la mayor distancia entre cualquier par de puntos, uno de cada clúster. Esto provoca que los grupos resultantes sean más compactos y estén bien separados entre sí. Es útil cuando se quiere evitar que dos clústeres se unan por un único punto cercano.
- **Enlace simple.** La distancia se calcula como la menor distancia entre dos puntos, uno de cada clúster. Es decir, si hay al menos un punto cercano entre los dos grupos, se pueden unir. Este método puede generar clústeres alargados o en forma de cadena, ya que solo necesita un punto de conexión.
- **Enlace medio.** Calcula la distancia media entre todos los puntos de un clúster y los del otro. Tiene un comportamiento intermedio entre el enlace simple y el completo, y suele producir agrupaciones más equilibradas.
- **Método de Ward.** En lugar de mirar distancias entre puntos, este método se basa en minimizar el aumento de la variación interna cuando se unen dos clústeres. Busca que cada fusión provoque el menor cambio posible dentro del nuevo grupo, lo que da como resultado clústeres de tamaño y forma parecidos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Es importante tener en cuenta cómo influye el método de enlace en el tamaño y forma de los clústeres. Algunos algoritmos presentan un comportamiento conocido como *rich get richer*, en el que los clústeres grandes tienden a seguir creciendo más que los pequeños. Esto puede dar lugar a agrupaciones muy desequilibradas.

El enlace completo tiende a favorecer este efecto, permitiendo que los clústeres grandes absorban a los pequeños. El resultado son grupos alargados o de tamaño muy desigual, lo que puede dificultar la interpretación.

Por el contrario, el método de Ward genera agrupaciones más regulares. Al minimizar la variación interna en cada fusión, los clústeres tienden a tener tamaños más parecidos y formas más homogéneas. Esto hace que sea una opción recomendable en muchos casos.

Sin embargo, Ward tiene una limitación importante: no es adecuado cuando se trabaja en espacios no euclídeos o con métricas distintas a la distancia euclidiana. En estas situaciones, el enlace medio es una alternativa útil, ya que funciona mejor con otros tipos de distancias.

Restricciones de conectividad

En el agrupamiento jerárquico aglomerativo, es posible añadir restricciones que limitan qué clústeres pueden fusionarse. Estas restricciones de conectividad ayudan a conservar cierta estructura o coherencia entre los datos, ya que solo permiten unir elementos que cumplan condiciones específicas, como proximidad espacial, relación temporal o vínculos conocidos.

Aplicar restricciones puede ser útil cuando se quiere que los grupos resultantes tengan un significado concreto o cuando se trabaja con datos estructurados, como mapas, series temporales o redes. Por ejemplo, si se agrupan personas en una red social, se podría establecer que solo se unan si son amigas y comparten intereses similares. Esto impide fusiones poco coherentes desde el punto de vista del contexto.

Existen diferentes formas de aplicar estas restricciones:

- **Restricciones espaciales.** Se utilizan para evitar que se fusionen clústeres que no están próximos en el espacio. Son útiles en análisis geográficos o en imágenes, donde solo deberían unirse zonas contiguas.
- **Restricciones temporales.** Limitan la fusión de clústeres a los que ocurren en un mismo intervalo de tiempo o en una secuencia determinada. Son habituales en análisis de series temporales.
- **Restricciones basadas en redes.** Se aplican en contextos donde los datos están conectados entre sí, como en grafos o xarxes socials. Solo se permite la fusión si existe alguna relación directa entre los elementos de los clústeres.
- **Restricciones de contigüidad.** Exigen que los elementos agrupados mantengan continuidad estructural. Es decir, que los clústeres no queden divididos o desconectats de forma artificial. Això és especialment rellevant en mapes o en dades físiques amb una estructura lògica.
- **Restricciones personalizadas.** Se pueden definir reglas específicas según el objetivo del análisis. Por ejemplo, limitar la unión de clústeres basándose en características concretas del conjunt de dades o en coneixement previ del domini.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Aplicar este tipo de restricciones no solo permite obtener clústeres más coherentes, sino que también mejora la eficiencia del algoritmo. Al limitar las posibles fusiones, el proceso de agrupamiento se vuelve más rápido, especialmente cuando se trabaja con grandes volúmenes de datos.


Estas restricciones se gestionan mediante una matriz de conectividad, que indica qué puntos pueden conectarse. Esta matriz suele ser muy dispersa, es decir, tiene la mayoría de valores en cero, ya que solo se indican las conexiones relevantes. Por eso, se almacena de forma optimizada, guardando únicamente las posiciones donde hay conexiones reales.

En las figuras comparativas puede observarse que, al activar la conectividad, los clústeres resultantes no son necesariamente más compactos ni equilibrados. De hecho, en este caso concreto, los agrupamientos sin restricciones de conectividad muestran una estructura más clara, especialmente al usar métodos de enlace como el simple, el medio o el completo.


Aunque en teoría imponer una conectividad debería ayudar a reflejar mejor la estructura local de los datos, en este ejemplo concreto se observa el efecto contrario. Al activar la conectividad, los agrupamientos tienden a ser más irregulares y los clústeres crecen de forma menos controlada.

Esto se debe a que, al utilizar una matriz de conectividad muy dispersa (como en este caso, basada en los 20 vecinos más próximos), los métodos de enlace como el medio o el completo pierden parte de su estabilidad. La conectividad rompe su forma habitual de calcular distancias entre clústeres y provoca un comportamiento más parecido al del enlace simple, que es más sensible y tiende a formar estructuras alargadas o inestables.

Por tanto, aunque el uso de conectividad puede mejorar el tiempo de ejecución, no siempre garantiza una mejor organización visual o estructural de los grupos, especialmente si la estructura de vecinos no está bien ajustada al tipo de datos.



Clústeres con la conectividad no activada



Clústeres con la conectividad activada

Las restricciones de conectividad y los métodos de enlace pueden combinarse de diferentes maneras según el objetivo del análisis.

En algunos casos, las restricciones se aplican antes de empezar el proceso de enlace. Así se reduce el número de posibles fusiones desde el principio, lo que garantiza que solo se consideren combinaciones aceptables.

En otras situaciones, restricciones y método de enlace se aplican a la vez, integrándose en cada paso del proceso. Aquí, el algoritmo decide las fusiones teniendo en cuenta tanto la distancia entre clústeres como las reglas de conectividad.

También existe la posibilidad, menos común, de aplicar restricciones una vez ya se ha hecho el agrupamiento. Això permetria ajustar els grups resultants separant aquells que no compleixen amb les condicions desitjades de connexió.

Combinación entre restricciones de conectividad y métodos de enlace

Las restricciones de conectividad y los métodos de enlace se pueden utilizar de forma complementaria en el análisis de clústeres. Sin embargo, el momento en que se aplican puede variar según la estrategia del análisis y los objetivos que se persigan.

- En algunos casos, las restricciones de conectividad se aplican antes de comenzar el proceso de enlace. Esto significa que el conjunto de fusiones posibles ya está limitado desde el principio, evitando combinaciones que no cumplen con los criterios de conexión establecidos. Esta opción es útil cuando se desea controlar estrictamente la estructura del agrupamiento.
- En otros escenarios, las restricciones de conectividad y los métodos de enlace se integran y se aplican al mismo tiempo. En cada paso de fusión, el algoritmo tiene en cuenta tanto la distancia entre clústeres como las restricciones impuestas, lo que permite un equilibrio entre proximidad y estructura.
- También existe la posibilidad, menos frecuente, de aplicar las restricciones después de haber ejecutado el agrupamiento. Esta estrategia se puede usar para revisar los clústeres

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




resultantes y separar aquellos que no cumplen con los criterios deseados de conectividad, ajustando así el modelo final.

El dendrograma como representación visual del agrupamiento

Una de las principales herramientas para interpretar el resultado del agrupamiento jerárquico es el dendrograma. Este gráfico en forma de árbol permite visualizar cómo se han ido uniendo los clústeres a lo largo del proceso.

En el eje horizontal se representan los elementos individuales del conjunto de datos, mientras que el eje vertical indica la distancia o similitud en el momento en que se fusionaron. Las líneas que conectan los grupos muestran el orden en que se produjeron las fusiones. Cuanto más alta es la unión en el gráfico, mayor era la distancia entre los clústeres en el momento de combinarse.



Este dendrograma se ha generado aplicando una partición final en 4 clústeres, correspondiente a un nivel de similitud de aproximadamente 40. El primer grupo, situado en el extremo izquierdo, está formado por 7 observaciones (las filas 1, 3, 6, 9, 10, 11 y 15). El segundo grupo, justo a su derecha, incluye 3 observaciones (las filas 4, 12 y 19). El tercer clúster agrupa 7 observaciones (las filas 2, 14, 17, 20, 18, 5 y 8). Finalmente, el cuarto grupo, a la derecha del todo, está compuesto por 3 observaciones (las filas 7, 13 y 16).

Si se cortara el dendrograma a una altura mayor, se obtendrían menos clústeres finales, aunque con un nivel de similitud más bajo entre los elementos agrupados. En cambio, si el corte se realizara a un nivel más bajo del gráfico, se formarían más clústeres, pero la similitud dentro de cada grupo sería mayor.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)




Decisión del número de clústeres finales

En el agrupamiento jerárquico, el número de clústeres finales suele decidirse cortando el dendrograma en un punto determinado. Este corte se elige según los objetivos del análisis y la estructura de los datos, y puede hacerse de forma visual o utilizando métodos automáticos como el método del codo o el índice de silueta, entre otros.

A través de la visualización del dendrograma, se puede identificar el lugar ideal donde cortar buscando el tramo vertical más largo que no haya sido atravesado por ninguna línea horizontal extendida. Aquí, "extendida" significa que las líneas horizontales del gráfico (las que conectan clústeres) se alargan visualmente a ambos lados.

Una vez localizado ese segmento vertical, se traza una línea horizontal imaginaria a su altura. El número de líneas verticales que cruza esa línea imaginaria suele indicar el número óptimo de clústeres que se pueden formar.



Detección del número de clústeres a través del dendrograma

Hiperparámetros del algoritmo Aglomerativo

El algoritmo de agrupamiento aglomerativo en scikit-learn permite ajustar varios hiperparámetros que influyen en el comportamiento y los resultados del modelo. A continuación se describen los más importantes:

- **n_clusters:** Define el número de clústeres que se quieren obtener. Aunque no es obligatorio en este tipo de agrupamiento, se puede usar para indicar directamente cuántos grupos finales se desean. Valor esperado: número entero positivo.
- **linkage:** Especifica el método de enlace que se utilizará para medir la distancia entre clústeres. Valores posibles: 'ward', 'complete', 'average', 'single'.
- **distance_threshold:** Permite establecer una distancia máxima para decidir cuándo dejar de fusionar clústeres. Por ejemplo, si se fija en 10, solo se agruparán elementos que estén a

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



una distancia menor o igual a 10 unidades. Este parámetro es opcional y su valor por defecto es None.

- **compute_full_tree:** Controla si se debe construir todo el árbol jerárquico durante el ajuste. Valores posibles:
 - 'auto' (por defecto), calcula todo el árbol solo si es necesario según el tamaño del conjunto
 - True, fuerza la construcción completa del árbol, con más detalle pero más coste de memoria y tiempo
 - False, construye solo una parte del árbol para optimizar rendimiento, aunque se pierde información estructural
- **connectivity:** Permite definir una estructura de conectividad entre los datos. Aquí es donde se puede pasar una matriz que imponga restricciones sobre qué puntos pueden estar conectados y, por tanto, fusionarse.
- **compute_distances:** Indica si se deben calcular y guardar las distancias entre clústeres durante el agrupamiento. Valores posibles: True (por defecto) o False.