


Lección 3. Agrupación basada en densidad: detección de formas y estructuras complejas

¿Qué es el agrupamiento por densidad y cómo funciona?

El agrupamiento por densidad es una técnica que identifica regiones con alta concentración de datos y agrupa los puntos que pertenecen a esas zonas. En lugar de basarse en la distancia global entre elementos, como hacen otros métodos, este enfoque busca agrupaciones naturales en el espacio según la densidad local de los datos.

Uno de los algoritmos más conocidos que sigue esta lógica es DBSCAN (Density-Based Spatial Clustering of Applications with Noise). A diferencia de K-means, DBSCAN no requiere conocer de antemano cuántos clústeres se quieren formar, y puede detectar grupos con formas complejas, no necesariamente circulares ni regulares.



Formación de clústeres por DBSCAN

Tipos de puntos del algoritmo DBSCAN

El funcionamiento se basa en encontrar zonas del espacio donde haya suficiente concentración de puntos. Estas zonas densas se consideran clústeres, mientras que los puntos aislados, que no pertenecen a ninguna región densa, se clasifican como ruido o excepciones.


Para clasificar los datos, DBSCAN distingue tres tipos de puntos:

- **Puntos núcleo.** Son aquellos que tienen un número mínimo de vecinos en su entorno más próximo. Es decir, hay suficientes puntos alrededor como para considerarlos parte de una zona densa.
- **Puntos frontera.** No tienen suficientes vecinos para ser núcleo, pero están dentro del área de influencia de un punto núcleo. Se consideran parte del clúster, aunque no contribuyen a expandirlo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



- **Puntos ruido.** No cumplen ninguna de las condiciones anteriores. Están demasiado alejados del resto y se consideran fuera de cualquier agrupación.



Tipos de puntos

Funcionamiento del algoritmo DBSCAN

El algoritmo DBSCAN forma clústeres a partir de regiones densas del espacio de datos. A continuación, se resumen sus fases principales de forma ordenada:

1. **Definición de los hiperparámetros:** Antes de comenzar, se establecen dos valores clave: **eps** (radio de vecindad) y **min_samples** (número mínimo de puntos en ese radio para considerar una zona como densa). Estos valores suelen determinarse mediante análisis visual, como el gráfico de k-distancias.
2. **Inicio del procesamiento:** El algoritmo selecciona un punto cualquiera del conjunto. Si ese punto tiene suficientes vecinos dentro del radio **eps**, se considera un punto núcleo y se empieza a formar un clúster. Si no cumple la condición, se marca como ruido y se pasa al siguiente punto.
3. **Expansión del clúster:** Los vecinos del punto núcleo se van incorporando al clúster. Si alguno de ellos también cumple la condición de ser núcleo, se amplía aún más el clúster buscando sus propios vecinos. Este proceso continúa hasta que ya no se pueden añadir más puntos.
4. **Exploración de nuevos clústeres:** Una vez finalizada la expansión del clúster actual, se elige un nuevo punto sin visitar y se repite el proceso. Así, se van creando otros clústeres o identificando más puntos de ruido.
5. **Finalización:** El algoritmo termina cuando ha revisado todos los puntos del conjunto de datos. Cada punto habrá sido asignado a un clúster o marcado como ruido.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Puntos fuertes y limitaciones del algoritmo DBSCAN

El algoritmo DBSCAN presenta una serie de ventajas que lo hacen especialmente útil en tareas exploratorias, sobre todo cuando se trabaja con datos que no siguen una estructura regular. Sin embargo, también tiene limitaciones que conviene conocer para saber cuándo es o no una buena opción.

Entre sus principales puntos fuertes destaca que no requiere indicar el número de clústeres con antelación, lo que lo hace muy útil cuando no se tiene una idea clara de cuántos grupos hay en los datos. Además, puede detectar clústeres con formas arbitrarias, no necesariamente redondas o simétricas, y es robusto frente al ruido, ya que los puntos aislados se clasifican como tales. Tampoco necesita ninguna inicialización de centroides ni hace suposiciones sobre la forma geométrica de los grupos, lo que le da una gran flexibilidad frente a otros algoritmos más rígidos.

Entre sus limitaciones más relevantes, cabe destacar que es muy sensible a los hiperparámetros `eps` y `min_samples`. Una mala elección puede dar lugar a resultados poco representativos. También puede resultar menos eficiente en conjuntos de datos muy grandes o en espacios con muchas dimensiones, donde la noción de cercanía pierde fuerza y afecta a su capacidad para detectar agrupaciones. Además, no siempre identifica bien los outliers si están cerca de zonas densas, y la distancia euclidiana que utiliza por defecto puede no ser adecuada para ciertos tipos de datos como los categóricos o textuales. Por último, el escalado de los atributos influye mucho en los resultados, por lo que es imprescindible preparar correctamente los datos antes de aplicar el algoritmo.

DBSCAN frente a clústeres con densidades variables

Aunque DBSCAN puede detectar clústeres con formas arbitrarias, su rendimiento se ve afectado cuando las densidades entre grupos son muy distintas. Esto se debe a que los hiperparámetros `eps` y `min_samples` se aplican globalmente, y un valor que funciona bien para una zona del espacio puede no ser adecuado para otra. Si un clúster tiene muchos puntos muy juntos y otro está más disperso, DBSCAN puede fallar en detectar correctamente alguno de ellos.

Para mejorar los resultados en este tipo de situaciones, es fundamental realizar una exploración detallada de los hiperparámetros, ajustándolos con cuidado en función de la estructura de los datos. Aun así, cuando las diferencias de densidad son demasiado extremas, puede ser recomendable optar por otras técnicas más adaptables.

Algunas alternativas diseñadas específicamente para manejar clústeres con densidades variables son:

- **HDBSCAN.** Extensión jerárquica de DBSCAN que permite identificar clústeres de distinta densidad de forma más robusta. Ofrece una visión jerárquica y permite trabajar con diferentes niveles de agrupamiento.
- **OPTICS.** Algoritmo que ordena los puntos para identificar estructuras de agrupamiento sin requerir un valor fijo de `eps`. Es especialmente útil cuando la densidad varía mucho entre zonas.
- **Mean Shift.** Método no paramétrico que se adapta de forma automática a la distribución de los datos. No necesita definir cuántos clústeres se esperan y detecta estructuras complejas.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **AHC (Agglomerative Hierarchical Clustering).** Al no depender de parámetros de densidad ni de formas concretas, puede resultar útil para analizar estructuras con densidades variadas a distintos niveles.
- **BIRCH.** Optimizado para grandes volúmenes de datos, utiliza estructuras de árbol para agrupar datos de forma eficaz, incluso cuando hay clústeres con tamaños y densidades dispares.
- **GMM (Modelos de mezcla de gaussianas).** Permite modelar los datos como una combinación de distribuciones gaussianas, siendo flexible ante diferentes concentraciones de puntos.
- **Fuzzy C-Means.** Versión suavizada de K-means que permite pertenencia parcial de un punto a varios clústeres. Útil cuando no hay límites claros entre grupos.
- **DENCLUE.** Utiliza funciones de densidad para modelar la distribución de los datos. Es eficaz para detectar formas complejas y densidades variadas.

Antes de elegir un método de agrupamiento, es fundamental analizar bien las características del conjunto de datos. En muchos casos, combinar diferentes enfoques o probar distintas técnicas puede ayudar a entender mejor la estructura interna y mejorar la calidad del agrupamiento final.

Comparativa con K-means y agrupamiento jerárquico

Aunque los tres algoritmos permiten agrupar datos, cada uno utiliza una lógica diferente para formar los clústeres. **K-means** asigna los puntos al centroide más cercano y ajusta esos centros en cada iteración. El **agrupamiento jerárquico** calcula las similitudes entre puntos y construye una estructura en forma de árbol. Por su parte, **DBSCAN** busca zonas densas y considera clúster a cualquier región donde la concentración de puntos sea suficiente.

En cuanto al **número de clústeres**, K-means requiere definirlo antes de aplicar el modelo. El método jerárquico ofrece flexibilidad, ya que se puede elegir el número de grupos según el nivel de corte en el dendrograma. En cambio, DBSCAN no necesita especificar cuántos clústeres debe encontrar, lo que resulta útil cuando no se tiene una idea clara del número de agrupaciones.

Respecto al **ruido o valores atípicos**, K-means es bastante sensible y puede verse afectado por puntos extremos. El método jerárquico, según el tipo de enlace utilizado, puede manejar mejor este problema. DBSCAN, en cambio, es especialmente eficaz en este aspecto, ya que considera los puntos aislados como ruido desde el principio.

Desde el punto de vista de la **visualización**, K-means es sencillo de interpretar, especialmente en 2D o 3D, ya que cada punto queda asignado a un centroide concreto. El agrupamiento jerárquico se representa mediante un dendrograma, que facilita mucho la comprensión de la estructura interna. DBSCAN también ofrece resultados visualmente claros, con clústeres formados por zonas de alta densidad.

La **selección de hiperparámetros** también es diferente en cada caso. K-means necesita definir el valor de K. El método jerárquico depende del tipo de enlace y del punto donde se corta el dendrograma. DBSCAN requiere ajustar cuidadosamente los valores de **eps** y **min_samples**, ya que estos controlan cómo se detecta la densidad.

En cuanto a la **eficiencia computacional**, K-means puede ser muy rápido si el número de clústeres no es alto. El agrupamiento jerárquico suele ser más costoso en términos de tiempo y memoria,

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



especialmente con muchos puntos. DBSCAN puede ser eficiente, sobre todo en datos con ruido, y presenta una complejidad temporal casi lineal respecto al número de observaciones, lo que lo hace muy útil en muchos contextos prácticos.

Elección de los hiperparámetros eps y min_samples

DBSCAN se basa en dos hiperparámetros principales que determinan cómo se forman los clústeres y cómo se detectan los puntos atípicos. La elección de estos valores influye directamente en la calidad del agrupamiento.

- **eps (epsilon):** Es el radio que define la distancia máxima entre dos puntos para que puedan considerarse vecinos. Todos los puntos que estén dentro de esta distancia desde un punto dado se consideran parte de su vecindad. Si la zona tiene suficiente densidad de puntos, se convierte en un clúster.
- **min_samples:** Indica el número mínimo de puntos que debe haber dentro del radio eps para que se considere que existe una región densa. Si un punto no tiene suficientes vecinos dentro de ese radio, se considera ruido o outlier, y no se asigna a ningún grupo.

Cómo ajustar eps y min_samples con el análisis de k-distancias


Para configurar correctamente el algoritmo DBSCAN, es clave ajustar los valores de [eps](#) y [min_samples](#). Una forma práctica de estimar [eps](#) es mediante el análisis de k-distancias, que ayuda a detectar el punto en el que empieza a bajar la densidad de datos.

El procedimiento consiste en:

1. Calcular la distancia al k-ésimo vecino más cercano para cada punto del conjunto. Por ejemplo, si $k=4$, se toma la distancia al cuarto punto más próximo.
2. Ordenar todas estas distancias de menor a mayor.
3. Representar los valores en una gráfica, donde el eje x muestra el número de puntos ordenados y el eje y la distancia calculada.
4. Buscar el punto de inflexión, es decir, donde la curva empieza a subir bruscamente. Ese cambio indica el límite entre zonas densas y zonas más dispersas.
5. Seleccionar el valor de [eps](#) justo en ese cambio de pendiente. Este será el valor que separa mejor las agrupaciones del ruido.
6. En cuanto a [min_samples](#), se suele fijar igual que el valor de k. Así se asegura que un punto solo se considere núcleo si realmente está rodeado por suficientes vecinos. Si se elige un valor demasiado bajo, se incluirán puntos poco representativos; si es demasiado alto, se podrían perder clústeres válidos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](#)





Análisis gráfico de las distancias al 5º vecino más cercano