

Autora, traducción y adaptación: Mireia Consarnau Pallarés.
Material original elaborado para el IOC.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Aprendizaje no supervisado: modelos de agrupación y análisis de patrones.....	1
Introducción.....	1
Lección 1. ¿Qué es el aprendizaje no supervisado? Conceptos y proceso general.....	2
¿Qué es el aprendizaje no supervisado?.....	2
Proceso general.....	3
¿Para qué sirve? Aplicaciones concretas.....	3
Principales tareas del aprendizaje no supervisado.....	4
Conceptos clave del clustering.....	5
¿Qué es un clúster?.....	5
¿Cómo se mide la similitud?.....	6
Métricas de distancia habituales.....	6
Modelos para formar clústeres.....	7
Reducción de dimensiones con PCA.....	9
¿Qué es el PCA?.....	9
¿Por qué reducir dimensiones?.....	10
¿Cómo funciona?.....	10
Decidir cuántos componentes conservar.....	11
Evaluación de la calidad del modelo.....	12
¿Cómo evaluar un modelo con etiquetas? Métricas externas.....	12
¿Cómo evaluar un modelo sin etiquetas? Métricas internas.....	12
Caso práctico simulado.....	13
¿Se puede mejorar un modelo sin saber la respuesta?.....	14
Lección 2. Agrupación con k-medias y métodos jerárquicos: funcionamiento y aplicación.....	15
¿Qué es el agrupamiento con K-means y cómo funciona?.....	15
Puntos fuertes y limitaciones del algoritmo K-means.....	16
Fases del algoritmo.....	16
¿Cómo decidir cuántos grupos formar? Desarrollo de la fase 1: Determinación del número de clústeres (K).....	18
¿Cómo se eligen los centroides iniciales? Desarrollo de la fase 2: Inicialización estratégica de los centroides.....	19
¿Cómo se asignan los puntos a los clústeres? Desarrollo de la fase 3: Asignación de observaciones a los clústeres.....	20
¿Cómo se actualizan los centroides? Desarrollo de la fase 4: Actualización de los centroides mediante promedios.....	21
¿Cuándo termina el algoritmo? Desarrollo de la fase 5: Iteración hasta la convergencia del modelo.....	21
Hiperparámetros del algoritmo K-means.....	22
¿Qué es el agrupamiento jerárquico y cómo funciona?.....	22
Tipos de enfoque: aglomerativo y divisivo.....	23
Características principales del agrupamiento jerárquico.....	24
Método aglomerativo (Bottom-up).....	25
Criterio de similitud entre clústeres.....	25
Métodos de enlace (linkage).....	26
Combinación entre restricciones de conectividad y métodos de enlace.....	28
El dendrograma como representación visual del agrupamiento.....	29
Decisión del número de clústeres finales.....	30
Hiperparámetros del algoritmo Aglomerativo.....	30

Lección 3. Agrupación basada en densidad: detección de formas y estructuras complejas.....32

¿Qué es el agrupamiento por densidad y cómo funciona?.....	32
Tipos de puntos del algoritmo DBSCAN.....	32
Funcionamiento del algoritmo DBSCAN.....	33
Puntos fuertes y limitaciones del algoritmo DBSCAN.....	33
DBSCAN frente a clústeres con densidades variables.....	34
Comparativa con K-means y agrupamiento jerárquico.....	35
Elección de los hiperparámetros eps y min_samples.....	35
Cómo ajustar eps y min_samples con el análisis de k-distancias.....	36

Aprendizaje no supervisado: modelos de agrupación y análisis de patrones

Introducción

El aprendizaje no supervisado es una técnica que permite descubrir patrones en los datos sin requerir respuestas previas. En esta unidad, nos centraremos en cómo aplicar algunas de las metodologías más comunes para abordar distintos problemas prácticos, como la segmentación de clientes o la reducción de dimensiones.

Nos centraremos especialmente en dos métodos clave: la agrupación de datos y la reducción de dimensiones mediante PCA. Ambas técnicas ayudan a simplificar grandes volúmenes de información, incluso cuando no disponemos de etiquetas previas.

La agrupación consiste en detectar similitudes entre elementos y reunirlos en grupos con características comunes. Esta estrategia resulta útil para explorar la estructura interna de los datos y revelar relaciones no evidentes a simple vista.

En el caso de conjuntos con muchas variables, el Análisis de Componentes Principales (PCA) permite reducir la cantidad de dimensiones sin perder demasiada información, facilitando así tanto la visualización como el análisis.

A lo largo del tema, el alumnado aprenderá cómo funcionan estos algoritmos, en qué situaciones conviene aplicarlos y qué limitaciones presentan. Además, pondrá en práctica su implementación y evaluación con Python y herramientas como scikit-learn.

Lección 1. ¿Qué es el aprendizaje no supervisado? Conceptos y proceso general

¿Qué es el aprendizaje no supervisado?


Cuando trabajamos con datos reales, a menudo no contamos con etiquetas que indiquen a qué categoría pertenece cada elemento. En estos casos, el aprendizaje no supervisado ofrece herramientas para explorar los datos y descubrir posibles agrupaciones o estructuras escondidas, basándose únicamente en sus características.

Este tipo de algoritmos no necesita respuestas conocidas para aprender, ya que no busca ajustar un modelo a unos resultados esperados. En lugar de eso, detecta regularidades dentro del conjunto analizando relaciones como la forma, la densidad o la proximidad entre elementos.

El aprendizaje no supervisado engloba una serie de técnicas diseñadas para trabajar con información no clasificada. Su objetivo principal es identificar patrones, segmentaciones o estructuras internas, a menudo usando criterios estadísticos o espaciales.

A diferencia del aprendizaje supervisado, aquí no se puede medir directamente si una solución es correcta o incorrecta. No hay error ni retroalimentación directa: el sistema debe organizar la información por sí mismo a partir de las relaciones que detecta entre los datos.

Una forma sencilla de visualizar esta diferencia es con una comparación gráfica entre ambos enfoques, donde se observa cómo uno aprende con ejemplos etiquetados y el otro sin referencias previas.




Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Proceso general

A la hora de aplicar técnicas de aprendizaje no supervisado, es importante seguir una secuencia lógica que permita obtener buenos resultados. Estas son las etapas clave:

- A. **Preparar los datos.** Antes de aplicar cualquier técnica, es fundamental limpiar el conjunto: corregir errores, eliminar duplicados, tratar valores ausentes o atípicos que puedan afectar al análisis. También es recomendable escalar o normalizar las variables para que todas contribuyan de forma equilibrada.
- B. **Escoger la técnica adecuada.** La elección del método dependerá del objetivo: agrupar elementos similares, reducir dimensiones, detectar valores atípicos, etc. Es buena práctica comparar distintas opciones y ver cuál ofrece mejores resultados con los datos disponibles.
- C. **Ejecutar el modelo.** Una vez seleccionada la técnica, se aplica sobre el conjunto de datos sin supervisión. El modelo analiza las relaciones internas y organiza la información en función de los patrones que detecta.
- D. **Analizar los resultados.** Tras la ejecución, llega el momento de valorar si los resultados tienen sentido. Según la tarea, se aplican criterios distintos: en agrupamiento se estudia la cohesión y separación de los grupos; en reducción de dimensiones, la proporción de información conservada.
- E. **Interpretar y aplicar.** Finalmente, se interpretan los hallazgos con el objetivo de extraer conclusiones prácticas. Esta fase puede dar lugar a segmentaciones útiles, mejoras en procesos o decisiones estratégicas basadas en patrones detectados.



Esquematzació del procés de aprenentatge no supervisat

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



¿Para qué sirve? Aplicaciones concretas

El aprendizaje no supervisado se aplica en muchos contextos donde no se dispone de etiquetas, pero sí se quiere entender mejor la estructura de los datos. Algunos ejemplos reales:

- **En marketing y negocio**
 - Segmentación de clientes según sus hábitos, preferencias o comportamientos de compra
 - Detección de patrones de consumo y predicción de tendencias del mercado
- **En análisis de datos y documentación**
 - Organización automática de documentos por temas sin necesidad de clasificación previa
 - Identificación de duplicados o registros muy similares en bases de datos
- **En redes sociales y comportamiento humano**
 - Agrupación de usuarios con ideologías u opiniones similares
 - Análisis de estructuras de relación y comunidades dentro de redes sociales
- **En ciencia y tecnología**
 - Clasificación de genes con funciones parecidas
 - Apoyo en la investigación de nuevos medicamentos a partir de patrones en datos biomédicos
 - Exploración y organización de grandes volúmenes de datos astronómicos
- **En procesamiento de datos complejos**
 - Reducción del número de variables en conjuntos muy amplios para facilitar la interpretación sin perder información relevante

Principales tareas del aprendizaje no supervisado

En el aprendizaje no supervisado no se dispone de etiquetas que indiquen la clase de cada ejemplo. En lugar de seguir modelos con respuestas ya definidas, este enfoque examina las características de los datos para descubrir estructuras internas que no son evidentes a simple vista.

Cada elemento se representa como un vector de atributos, y a partir de esa información, los algoritmos intentan encontrar patrones comunes, agrupar casos similares o reducir la complejidad del conjunto.

- Agrupación de datos (clustering).** Esta tarea busca estructurar el conjunto dividiéndolo en grupos formados por elementos internamente similares y externamente diferenciados. El objetivo es que cada grupo contenga elementos con características próximas entre sí, maximizando la cohesión interna y la separación entre grupos.
- Detección de anomalías.** Consiste en identificar elementos que se alejan significativamente del patrón general de los datos. Estos casos no encajan en los agrupamientos formados y se consideran desviaciones respecto al comportamiento común del conjunto.
- Reducción de variables (dimensionalidad).** Se basa en disminuir el número de atributos conservando la mayor parte posible de la información. Para ello, se agrupan características

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



que expresan relaciones similares, lo que permite representar el conjunto de forma más compacta sin alterar sustancialmente su estructura interna.

d. Otras tareas útiles

- **Descubrimiento de relaciones entre variables.** Consiste en identificar patrones de asociación frecuentes entre diferentes características de un conjunto de datos. Este tipo de análisis permite detectar correlaciones o dependencias que no son evidentes inicialmente y que pueden aportar conocimiento estructural sobre el conjunto.
- **Extracción de temas en conjuntos de texto.** En contextos textuales, el aprendizaje no supervisado se puede aplicar para identificar automáticamente grupos de palabras o conceptos que tienden a aparecer conjuntamente. Esta tarea permite representar colecciones de documentos en función de los temas predominantes sin necesidad de clasificaciones previas.

El análisis de clústeres es una técnica fundamental para segmentar conjuntos de datos en agrupaciones coherentes. Su utilidad no se limita únicamente a la formación de grupos, sino que se extiende a otras tareas del análisis no supervisado con las que mantiene una relación directa.

En particular, las tres tareas principales del aprendizaje no supervisado —agrupación, detección de anomalías y reducción de dimensionalidad— comparten un enfoque común basado en la exploración de estructuras internas dentro de los datos.

La detección de anomalías puede entenderse como una extensión del análisis de clústeres, en la que se identifican elementos que presentan un comportamiento significativamente diferente al de los grupos formados. Esta identificación se basa en la comparación entre las características del elemento y los perfiles definidos por los clústeres habituales.

Por su parte, la reducción de dimensionalidad puede interpretarse como un agrupamiento aplicado a las variables en lugar de a los individuos. Agrupar atributos con comportamientos similares permite representar el conjunto de datos de forma más compacta, sin una pérdida excesiva de información. Aunque se trate como una técnica independiente, conceptualmente sigue una lógica muy próxima a la del clustering.

Conceptos clave del clustering

Antes de aplicar algoritmos de agrupación, es importante comprender una serie de conceptos fundamentales que definen cómo funciona el clustering y qué se espera obtener con este tipo de análisis. Estos conceptos permiten interpretar mejor los resultados y tomar decisiones informadas durante el proceso.

A continuación, se presentan las ideas centrales que forman la base teórica de los métodos de clustering: qué es un clúster, cómo se mide la similitud entre elementos y qué papel juega la distancia en la formación de grupos.

¿Qué es un clúster?

En el contexto del aprendizaje no supervisado, un clúster es un conjunto de elementos que presentan similitudes entre sí en función de sus características. Estos elementos se representan como vectores

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



dentro de un espacio multidimensional, y su agrupación se basa en la proximidad o semejanza entre esos vectores.

El propósito principal de este tipo de análisis es organizar los datos en subconjuntos bien diferenciados, sin necesidad de etiquetas previas. Se busca que cada grupo esté formado por elementos internamente similares (alta cohesión) y que al mismo tiempo exista una clara separación respecto a los demás grupos (alta separación). Esta dualidad entre homogeneidad interna y heterogeneidad externa es clave en muchas técnicas de segmentación.

Este enfoque permite detectar estructuras internas en los datos que, de otro modo, pasarían desapercibidas. La validez de las agrupaciones obtenidas dependerá del contexto y de los criterios utilizados, por lo que también requiere juicio analítico.

Uno de los grandes desafíos del clustering consiste en identificar segmentaciones que sean coherentes y significativas, sin contar con información de referencia. El valor del proceso radica precisamente en su capacidad para revelar patrones latentes y facilitar una interpretación más profunda del conjunto analizado.

¿Cómo se mide la similitud?

En los métodos de agrupación, evaluar la similitud entre elementos es fundamental para determinar cómo se organizan los datos. Aunque este concepto puede parecer abstracto, en la práctica se representa habitualmente mediante una medida de distancia: cuanto más cerca se encuentran dos puntos en el espacio de características, más similares se consideran.

La forma en que se calcula esta distancia tiene un impacto directo en el resultado del análisis. Es precisamente esta medida la que guía al algoritmo a decidir qué elementos deben agruparse, por lo que influye en la composición final de los clústeres.

Existen distintas formas de calcular esa distancia —como la euclidiana, la Manhattan o la basada en el coseno— y cada una interpreta las relaciones entre los datos de manera distinta. Por eso, adaptar la métrica al tipo de variables y al objetivo concreto del análisis es un paso clave para obtener agrupaciones consistentes y significativas.

Métricas de distancia habituales

En los algoritmos de clustering, la forma en que se cuantifica la distancia entre elementos determina cómo se agrupan los datos. A continuación se presentan algunas de las métricas más comunes utilizadas para evaluar similitud:

- **Distancia euclidiana.** Calcula la separación directa entre dos puntos en un espacio multidimensional. Refleja la distancia “geométrica” tradicional y es especialmente útil cuando las variables han sido normalizadas.
- **Distancia de Manhattan.** Suma las diferencias absolutas entre las coordenadas de cada dimensión. Representa trayectos en los que solo se puede avanzar en líneas rectas horizontales y verticales, lo que modifica la sensibilidad del agrupamiento respecto a la euclidiana.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Distancia de Minkowski.** Generaliza las dos anteriores mediante un parámetro ajustable que controla la influencia relativa de las dimensiones. Permite adaptar el cálculo de la distancia según el tipo de dispersión que se quiera priorizar.
- **Distancia de Hamming.** Cuenta el número de posiciones en las que difieren dos vectores, y se emplea principalmente con datos categóricos o binarios. Es adecuada cuando lo relevante no es la magnitud de la diferencia, sino el número de discrepancias.
- **Distancia de Mahalanobis.** mide la separación entre un punto y un grupo considerando tanto la media como la covarianza de las variables. Tiene en cuenta la correlación entre dimensiones y es apropiada en contextos con variables relacionadas o redundantes.

La forma en que se define la distancia entre elementos influye directamente en el comportamiento de cualquier algoritmo de agrupación. Esta métrica determina cómo se comparan los puntos dentro del espacio de características y, en consecuencia, condiciona la formación y distribución de los grupos resultantes.

No existe una métrica única que funcione de manera óptima en todos los contextos. Su idoneidad depende de múltiples factores, como la naturaleza de los datos, la escala de las variables, su distribución o la presencia de correlaciones entre ellas.

Algunas métricas ofrecen buenos resultados cuando las variables están correctamente normalizadas y no presentan valores extremos, mientras que otras son más robustas frente a escalas distintas o relaciones entre dimensiones. La elección de una métrica adecuada debe considerar tanto las propiedades del conjunto de datos como los objetivos analíticos.


Además, ciertos algoritmos están diseñados para trabajar con una métrica específica, mientras que otros permiten ajustar este parámetro según las necesidades del análisis. Por todo ello, seleccionar la distancia apropiada no es solo un paso técnico, sino una decisión estratégica que afecta a la interpretación de los resultados y a la validez de las agrupaciones obtenidas.

Modelos para formar clústeres

Los algoritmos de agrupación se pueden clasificar en función de cómo gestionan la pertenencia de los elementos a los distintos grupos. Cada enfoque parte de una concepción distinta sobre qué constituye un clúster, cómo se identifican las similitudes y qué tipo de estructuras se pueden extraer del conjunto de datos.

Algunas técnicas asignan cada elemento a un único grupo de forma exclusiva, mientras que otras permiten una pertenencia parcial o probabilística. Existen también métodos que construyen agrupaciones de forma jerárquica, así como enfoques basados en la densidad local del conjunto.

Esta variedad de estrategias permite adaptar el análisis a diferentes tipos de datos y objetivos, ofreciendo flexibilidad para trabajar con estructuras complejas o distribuciones no lineales.



Diferencias en la manera de agrupar según el algoritmo utilizado
 Adaptación de: Patrik D'haeseleer: "How does gene expression clustering work?", Nature Biotechnology 23, 1499 - 1501 (2005).

A) El conjunto de datos contiene cuatro clústeres de diferentes tamaños, formas y puntos de datos. Se utilizó la distancia euclidiana, que corresponde a la distancia en línea recta entre puntos en este gráfico, para el agrupamiento.

B) El agrupamiento jerárquico encuentra toda una jerarquía de clústeres. El árbol se cortó al nivel indicado para obtener cuatro clústeres. Se pueden apreciar algunos de los superclústeres y subclústeres.

C) El K-means (con $K = 4$) divide el espacio en cuatro subespacios, dependiendo de cuál de los cuatro centroides del clúster (estrellas) es el más cercano.

D) SOM encuentra clústeres, que se organizan en una estructura de cuadrícula (en este caso, una cuadrícula simple de 2 por 2).

- **Algoritmos de partición.** Los métodos de partición inician con una distribución preliminar —habitualmente aleatoria— de los datos en varios grupos. A través de un proceso iterativo, esa asignación se va ajustando con el objetivo de mejorar la coherencia interna de cada agrupación. Estos algoritmos requieren especificar de antemano cuántos grupos se desean obtener.

Existen dos variantes principales dentro de esta familia:

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Partición rígida.** Cada elemento se asigna exclusivamente a un único grupo. Algoritmos como K-means siguen este enfoque, en el que no hay solapamientos ni ambigüedad en la pertenencia.
- **Partición suave o probabilística.** Los métodos basados en modelos de mezclas, como las mezclas gaussianas (GMM), estiman una probabilidad de pertenencia para cada dato respecto a cada grupo. Esto permite reflejar incertidumbre y manejar mejor situaciones donde los límites entre agrupaciones no son claramente definidos.
- **Algoritmos jerárquicos.** Los métodos jerárquicos construyen agrupaciones anidadas, organizando los datos en distintos niveles de detalle. Esta estructura se forma mediante una sucesión de combinaciones o divisiones, y permite observar cómo evolucionan las relaciones entre los elementos a diferentes escalas.

Existen dos enfoques principales:

- **Jerarquía aglomerativa (ascendente).** Se parte de una situación en la que cada elemento constituye su propio grupo. En cada iteración, se fusionan los dos conjuntos más próximos hasta que se alcanza una única agrupación que contiene todos los datos.
- **Jerarquía divisiva (descendente).** Comienza con un único grupo que incluye todo el conjunto, y se va separando de forma progresiva en subconjuntos, eligiendo en cada etapa la partición más significativa.

El resultado se representa habitualmente mediante un dendrograma: un árbol que refleja visualmente cómo se agrupan o se separan los elementos. Las hojas corresponden a instancias individuales y la raíz al conjunto completo. Seleccionar un nivel de corte en el árbol permite obtener una partición concreta según el nivel de granularidad deseado. Estos métodos resultan especialmente útiles cuando se busca interpretar con claridad las relaciones jerárquicas dentro de los datos.

- **Algoritmos basados en densidad.** Este enfoque detecta agrupaciones localizando regiones del espacio donde los datos se concentran de forma significativa. Los elementos situados en zonas densas se consideran parte de un mismo grupo, mientras que aquellos más aislados se tratan como ruido o casos atípicos.

A diferencia de los métodos clásicos, estos algoritmos no requieren especificar el número de clústeres previamente. En su lugar, emplean parámetros como la distancia máxima entre puntos vecinos o el número mínimo de elementos en una región para definir qué constituye una agrupación válida.

Modelos como DBSCAN utilizan este criterio para construir agrupaciones con formas irregulares, detectar automáticamente el número de grupos y manejar con eficacia la presencia de valores atípicos. Este enfoque resulta útil en conjuntos complejos donde la estructura no es evidente a simple vista.

- Otros algoritmos
 - **Algoritmos basados en descomposición espectral.** Utilizan técnicas algebraicas, como la descomposición en valores propios, para analizar matrices de similitud entre

elementos. Esta aproximación permite detectar estructuras complejas o conexiones no evidentes en el espacio original. Se utiliza, por ejemplo, en el clustering espectral.

- **Algoritmos que dividen el espacio en celdas.** Separan el conjunto de datos en regiones pequeñas y regulares, evaluando la densidad local dentro de cada celda. A partir de esta información, se identifican posibles agrupaciones. Este tipo de estrategias es eficiente con grandes volúmenes de datos y se aplica en métodos como los basados en grid.
- **Algoritmos de agrupación difusa.** Permiten que cada elemento tenga diferentes grados de pertenencia a múltiples grupos. A diferencia de los métodos estrictos, no asignan un único clúster por elemento, sino que expresan la afinidad relativa con cada grupo. Este enfoque corresponde a técnicas de clustering fuzzy.
- **Algoritmos fundamentados en lógica difusa.** Incorporan formalmente la teoría de conjuntos difusos para definir la pertenencia de los elementos de manera gradual. En lugar de clasificaciones binarias, ofrecen representaciones continuas, más adecuadas cuando las fronteras entre categorías no están claramente definidas.

Reducción de dimensiones con PCA

En muchos análisis, especialmente cuando se trabaja con conjuntos que contienen un elevado número de variables, resulta necesario simplificar la información para poder interpretarla y procesarla con mayor eficacia. La reducción de dimensiones permite representar los datos en un espacio más compacto, sin perder su estructura esencial.

Entre las técnicas más utilizadas para este fin se encuentra el Análisis de Componentes Principales (PCA), un método que transforma el conjunto original en un nuevo sistema de variables, con el objetivo de conservar la mayor parte de la información relevante en un número reducido de dimensiones.

¿Qué es el PCA?

El PCA es una técnica fundamental en el análisis de datos que reduce la complejidad de grandes conjuntos de variables. Esta metodología convierte las variables originales en un conjunto de nuevas variables, conocidas como componentes principales, que son independientes entre sí y facilitan la interpretación.

Algunas de sus propiedades más destacadas son:

- **Reducción sin pérdida significativa de información.** El PCA permite disminuir el número de variables conservando la estructura principal del conjunto, lo que resulta especialmente útil cuando se trabaja con datos de alta dimensionalidad.
- **Transformación basada en la variabilidad.** El método identifica las direcciones en las que los datos presentan mayor dispersión y define esos ejes como los componentes principales. Cuanto mayor sea la varianza explicada por un componente, más información contiene.
- **Independencia entre componentes.** Los componentes obtenidos están contruidos de forma que no guardan correlación entre ellos. Esto facilita su interpretación y evita redundancias, mejorando también el rendimiento en ciertos modelos predictivos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Conservación de la varianza.** Aunque se reduce el número de dimensiones, el método prioriza conservar la máxima cantidad de variabilidad posible. Los primeros componentes concentran la mayor parte de la información, mientras que los últimos suelen contener detalles menos relevantes o ruido.
- **Aplicaciones diversas.** Además de su uso para simplificar conjuntos complejos, el PCA también se emplea para visualizar datos en dos o tres dimensiones, eliminar redundancias, comprimir información o mejorar la eficiencia computacional en modelos de aprendizaje automático.
- **Importancia de la escala.** Dado que el PCA se basa en la variabilidad de los datos, es imprescindible normalizar las variables antes de aplicarlo. De lo contrario, las que tienen escalas mayores pueden dominar la transformación y alterar los resultados.

¿Por qué reducir dimensiones?

La reducción de dimensiones es crucial cuando se trabajan con datos con muchas variables, ya que un exceso de información puede complicar el análisis y ralentizar los procesos. Al reducir el número de dimensiones, conseguimos simplificar el modelo sin perder la esencia de los datos.

Al disminuir el número de variables, se simplifica el espacio de características, lo que permite:

- Mejorar la eficiencia de los algoritmos al reducir la carga de procesamiento
- Facilitar la visualización e interpretación de los datos
- Evitar redundancias entre variables que aportan información similar
- Eliminar ruido o detalles poco relevantes que dificultan la extracción de patrones útiles

La reducción de dimensiones ayuda a centrarse en la información más significativa sin perder la estructura esencial del conjunto de datos.

¿Cómo funciona?

Para aplicar el PCA, se sigue una serie de pasos que permiten transformar los datos en una forma más simplificada pero manteniendo las relaciones clave entre las variables. Este proceso no solo facilita el análisis, sino que también mejora la eficiencia del procesamiento de datos.

Los pasos habituales son los siguientes:

1. **Preparar los datos.** Antes de empezar, es necesario normalizar las variables para que todas tengan la misma escala. Esto implica ajustar sus valores para que tengan media cero y desviación estándar uno. Si no se estandarizan, las variables con valores mayores influirán de forma desproporcionada en el resultado final.
2. **Analizar la relación entre las variables.** A continuación, se calcula una matriz que recoge la relación entre las diferentes variables. Dependiendo del caso, puede ser una matriz de covarianza (si las variables tienen escalas distintas) o de correlación (si ya han sido normalizadas o están en la misma escala).
3. **Extraer los componentes principales.** Mediante una descomposición matemática de la matriz anterior, se obtienen los vectores propios (direcciones principales de variación) y los valores propios (medida de la varianza que explica cada dirección).

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



4. **Seleccionar los componentes relevantes.** Una vez calculados, los componentes se ordenan en función de la cantidad de varianza que explican. Se eligen los primeros que acumulan un porcentaje elevado de la información total, lo que permite reducir dimensiones sin perder contenido esencial.
5. **Transformar los datos.** Finalmente, el conjunto original se proyecta sobre los ejes definidos por los componentes seleccionados. Esto genera una nueva versión del conjunto de datos, con menos dimensiones, más simple de interpretar y con menor redundancia.

Decidir cuántos componentes conservar

Una de las decisiones clave al aplicar el PCA es seleccionar cuántos componentes mantener en el modelo. Esta elección determina el balance entre la complejidad y la capacidad de representar la variabilidad original de los datos, buscando siempre la mayor eficiencia.

A mayor número de componentes, se preserva más variabilidad de los datos, pero también se incrementa el volumen de información a procesar. En cambio, reducir excesivamente el número de componentes puede simplificar el análisis, pero con el riesgo de perder patrones importantes. Por eso, es fundamental encontrar un equilibrio adecuado entre precisión y simplicidad.

A continuación, se presentan algunas estrategias útiles para tomar esta decisión:

- **Observar la varianza explicada acumulada.** Una opción común es seleccionar los primeros componentes que, en conjunto, explican un porcentaje elevado de la variabilidad total, como el 95 % o el 99 %. También puede optarse por un número fijo si tiene sentido en el contexto del problema o facilita la interpretación.
- **Ajustar según el nivel de detalle necesario.** Reducir mucho el número de componentes simplifica el conjunto resultante, pero puede hacer que se pierda información relevante. En cambio, conservar demasiados componentes puede mantener datos redundantes o ruido. El objetivo es ajustar el número para conservar lo esencial sin sobrecargar el análisis.
- **Comparar diferentes configuraciones.** Probar varias opciones y observar cómo afectan al rendimiento es una estrategia eficaz. Esto se puede hacer midiendo la precisión de un modelo posterior, la claridad en la visualización o la eficiencia del procesamiento. La validación cruzada o el uso de un conjunto de prueba pueden ayudar a valorar las alternativas.
- **Mejorar la eficiencia computacional.** Reducir la dimensionalidad también implica trabajar con menos variables, lo que agiliza los cálculos y mejora la velocidad de procesamiento, especialmente en conjuntos de datos muy grandes. Esto convierte al PCA no solo en una herramienta de análisis, sino también en una forma de optimizar recursos.

Evaluación de la calidad del modelo

Tras aplicar un algoritmo de clustering, es esencial analizar si los grupos formados representan correctamente la estructura subyacente de los datos. Para ello, se utilizan diferentes métricas que permiten evaluar la cohesión y separación de los clústeres generados.

El tipo de métrica a utilizar dependerá de si se dispone de información previa sobre las clases reales. Si existe una referencia externa, se pueden usar medidas comparativas. En cambio, si los datos no tienen etiquetas, habrá que evaluar la calidad interna del agrupamiento en función de su cohesión y separación.

¿Cómo evaluar un modelo con etiquetas? Métricas externas

Cuando se dispone de las clases reales de los datos, es posible comparar directamente las agrupaciones obtenidas con la estructura esperada. Para ello se utilizan métricas externas, que miden el grado de coincidencia entre los clústeres generados y las categorías conocidas:

- **Adjusted Rand Score (ARI).** Evalúa la similitud entre dos asignaciones de clústeres, ajustando por coincidencias aleatorias. Sus valores oscilan entre -1 y 1, donde 1 representa una correspondencia perfecta entre las agrupaciones y las clases reales.
- **Homogeneity.** Mide si cada clúster contiene únicamente elementos de una misma clase. Un valor de 1 indica que todos los puntos dentro de un grupo pertenecen a la misma categoría.
- **Completeness.** Verifica si todos los elementos de una clase concreta están contenidos en un solo clúster. Un valor de 1 indica que cada clase está completamente recogida dentro de un único grupo.
- **V-Measure.** Es la media armónica entre homogeneidad y completitud. Proporciona una visión global que combina la pureza interna de los grupos y la cobertura de las clases.
- **Visualización.** Representar los datos de forma gráfica, por ejemplo con diagramas de dispersión, permite observar de manera intuitiva la distribución de los clústeres y detectar solapamientos o agrupaciones mal definidas.

¿Cómo evaluar un modelo sin etiquetas? Métricas internas

En ausencia de etiquetas externas, se utilizan métricas internas que miden la calidad de los clústeres a partir de sus propias características. Estas métricas evalúan la homogeneidad de los grupos y su separación, ayudando a determinar si el modelo ha encontrado patrones significativos:

- **Índice de silueta (Silhouette Score).** Mide la calidad de la asignación de cada punto a su clúster, comparando la cohesión interna con la separación respecto a otros clústeres. Su valor va de -1 a 1, siendo 1 el mejor valor, que indica que los puntos están bien agrupados y alejados de otros clústeres.
- **Índice de Davies-Bouldin (DBI).** Calcula la relación entre la densidad interna de los clústeres y la distancia entre ellos. Valores más bajos indican una mejor partición, ya que reflejan una mayor separación entre los clústeres y una mayor cohesión dentro de cada uno.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Coeficiente de Calinski-Harabasz.** Evalúa la separación entre los clústeres y su compactación interna. Cuanto más alto sea el valor, mejor será la estructura de los clústeres, ya que indica mayor distancia entre los centros y menor dispersión dentro de los mismos.
- **Índice de Dunn.** Mide la relación entre la distancia mínima entre clústeres y la dispersión dentro de ellos. Valores más altos sugieren una mejor separación entre clústeres y una mayor cohesión interna.
- **Inercia (Inertia).** Calcula la suma de las distancias cuadradas de cada punto a su centroide correspondiente. Un valor bajo de inercia indica que los puntos están más agrupados alrededor del centro de su clúster, lo que es deseable en muchos casos.

Caso práctico simulado

Imaginemos que hemos aplicado un algoritmo de clustering para dividir un conjunto de datos en X grupos. En este caso, hemos utilizado un tipo de agrupamiento exclusivo, donde cada punto pertenece exclusivamente a un solo clúster, sin posibilidad de pertenencia compartida. Aunque existen técnicas que permiten pertenencias múltiples, no se tratan en esta unidad.

Tras aplicar el modelo, los resultados obtenidos son los siguientes:

- **Inercia:** 438.75
- **Adjusted Rand Score:** 0.86
- **Homogeneidad:** 0.81
- **Complejitud:** 0.84
- **V-Measure:** 0.82
- **Silhouette:** 0.53
- **Davies-Bouldin:** 0.68
- **Calinski-Harabasz:** 318.40

Estos resultados reflejan un comportamiento bastante satisfactorio del modelo. A pesar de que siempre es posible mejorar, las métricas indican que los clústeres generados son coherentes y que los grupos identificados capturan de forma precisa la estructura de los datos.

- **Inercia.** El valor obtenido, 438.75, indica que los puntos dentro de cada clúster están razonablemente cercanos entre sí, lo que sugiere que los clústeres son compactos. Aunque la inercia baja generalmente está asociada con agrupaciones más coherentes, se puede seguir ajustando para mejorar la cohesión.
- **Adjusted Rand Score.** Con un valor de 0.86, el *Adjusted Rand Score* muestra una alta similitud entre las agrupaciones obtenidas y las clases reales (si están disponibles). Este buen resultado demuestra que el modelo ha logrado identificar correctamente la estructura de los datos.
- **Homogeneidad, Complejitud y V-Measure.** Las métricas de homogeneidad (0.81), completitud (0.84) y V-Measure (0.82) sugieren que los clústeres están bien definidos: cada grupo contiene puntos que pertenecen mayormente a una misma clase y las clases están correctamente distribuidas en los grupos. La V-Measure, que equilibra ambas métricas, refuerza esta interpretación.
- **Silhouette.** Con un valor de 0.53, el índice de silueta indica que los puntos están más cerca de su propio clúster que de otros, lo que demuestra una separación aceptable. Aunque no

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



perfecta, la separación es lo suficientemente buena como para indicar que el modelo es funcional.

- **Davies-Bouldin.** El valor de 0.68 en el índice de Davies-Bouldin señala que los clústeres están bien separados y que la densidad interna de los mismos es adecuada. Cuanto menor sea este valor, mejor será la calidad del agrupamiento.
- **Calinski-Harabasz.** El alto valor de 318.40 indica una buena separación entre los clústeres y una compactación interna satisfactoria. Esto refuerza la idea de que el modelo ha logrado una segmentación clara y bien definida de los datos.

Los indicadores sugieren que el modelo de clustering ha funcionado correctamente. Aunque se podrían hacer ajustes adicionales, los resultados son lo suficientemente sólidos como para considerar que la segmentación es adecuada. Las métricas permiten asegurar que los clústeres reflejan de manera efectiva la estructura de los datos.

¿Se puede mejorar un modelo sin saber la respuesta?

Mejorar un modelo en un entorno no supervisado no implica compararlo con respuestas conocidas, ya que estas no existen. En lugar de eso, se trata de ajustar el modelo para obtener clústeres coherentes que representen adecuadamente los datos de forma eficiente.

A continuación se presentan algunas estrategias clave para optimizar el modelo:

- **Probar diferentes configuraciones.** En algunos algoritmos, como K-means, las decisiones iniciales influyen significativamente en el resultado final. Por ejemplo, la elección del número de clústeres es un parámetro crítico. Ajustar estos hiperparámetros requiere probar diferentes configuraciones y evaluar cuál da los mejores resultados.
- **Simplificar el espacio de trabajo.** No siempre es necesario utilizar todas las variables disponibles. Técnicas como el PCA permiten reducir el número de dimensiones sin perder la información más relevante. Esto no solo facilita la interpretación, sino que también mejora la eficiencia del procesamiento al reducir la carga computacional.
- **Optimizar el rendimiento.** El objetivo no es solo que el modelo funcione, sino que lo haga de manera eficiente. Reducir el número de variables, elegir algoritmos más ligeros o ajustar los parámetros adecuados puede acelerar significativamente el tiempo de cálculo, lo que es esencial cuando se trabaja con grandes volúmenes de datos.
- **Valorar la calidad sin etiquetas.** Aunque no tengamos etiquetas reales para comparar, se pueden emplear métricas internas, como Silhouette, Davies-Bouldin o Calinski-Harabasz, para evaluar la calidad del clustering. También es útil realizar una inspección visual de los clústeres, observando si las agrupaciones tienen sentido y si los grupos están bien diferenciados o se solapan.

Mejorar un modelo sin supervisión requiere ensayo, análisis y ajustes continuos. Aunque no hay una solución única, ajustar los parámetros, reducir dimensiones y evaluar los resultados desde diferentes perspectivas ayuda a conseguir modelos más robustos y eficientes.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Lección 2. Agrupación con k-medias y métodos jerárquicos: funcionamiento y aplicación

En esta lección exploraremos dos de los enfoques más utilizados para realizar agrupamientos sobre datos no etiquetados: el método de K-means y los métodos jerárquicos. Ambos permiten descubrir patrones y estructuras en los datos, pero lo hacen de forma distinta y con características particulares que conviene conocer.

K-means es un algoritmo eficiente que parte de un número de grupos predefinido y busca asignar cada elemento al grupo más cercano. En cambio, los métodos jerárquicos construyen agrupamientos de forma progresiva, sin necesidad de fijar de antemano el número de clústeres, lo que los hace especialmente útiles para explorar diferentes niveles de agrupación.


A lo largo de la unidad veremos cómo funcionan estos métodos, qué decisiones hay que tomar para aplicarlos correctamente y en qué contextos resulta más adecuado utilizar uno u otro.

¿Qué es el agrupamiento con K-means y cómo funciona?

El algoritmo K-means es una técnica muy utilizada para agrupar datos no etiquetados. Su objetivo es dividir el conjunto de datos en grupos bien definidos o clústeres, de forma que los elementos de cada grupo sean lo más parecidos posible entre sí y diferentes de los elementos de los demás grupos.

Este método funciona de manera iterativa y parte de una idea clave: el número de clústeres deseado (K) debe conocerse o estimarse antes de aplicar el algoritmo. A partir de ahí, el proceso se basa en la cercanía entre los datos y ciertos puntos centrales llamados centroides, que representan el "centro" de cada grupo.

Aunque es un algoritmo sencillo en su planteamiento, su comportamiento depende de varias decisiones que veremos a continuación, como la elección del número de grupos, el modo de iniciar el proceso o el criterio para determinar cuándo ha finalizado.



Clústeres identificados por K-means

Puntos fuertes y limitaciones del algoritmo K-means

K-means destaca por su eficiencia, ya que permite trabajar con conjuntos de datos grandes sin requerir demasiados recursos computacionales. Su simplicidad y facilidad de uso lo hacen accesible incluso para quienes están empezando con técnicas de agrupamiento. Además, ofrece una gran flexibilidad, ya que puede aplicarse a distintos tipos de datos numéricos, así como a representaciones vectoriales de textos o imágenes. Sus resultados son fáciles de interpretar, ya que cada dato queda asociado a un grupo con un centroide representativo, lo que facilita el análisis visual y la comprensión de las agrupaciones obtenidas.

A pesar de sus ventajas, también tiene limitaciones importantes. Es sensible a la inicialización de los centroides, lo que puede llevar a resultados distintos si se parte de posiciones diferentes, y a menudo se queda atrapado en óptimos locales. Requiere decidir de antemano el número de grupos, algo que no siempre es evidente. Funciona bien cuando los clústeres son esféricos, de tamaño y densidad similares, pero pierde precisión cuando los grupos tienen formas irregulares o no están claramente separados. Tampoco es adecuado para conjuntos de datos que no pueden dividirse linealmente, ya que tiende a forzar particiones poco realistas en estos casos.


Fases del algoritmo

1. **Determinación del número de clústeres (K).** El primer paso consiste en definir cuántos grupos se desean formar. Este valor, conocido como K, es fundamental porque condiciona la estructura del agrupamiento y debe establecerse antes de ejecutar el algoritmo. Determinar K requiere criterios adecuados, ya que una mala elección puede producir agrupamientos poco representativos. Más adelante exploraremos métodos como el codo, la silueta o los criterios de información para estimar el valor óptimo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)




2. **Inicialización estratégica de los centroides.** Una vez fijado el número de clústeres, se seleccionan los centroides iniciales, que actuarán como puntos de referencia para formar los grupos. Esta inicialización no es trivial, ya que puede afectar tanto a la velocidad de convergencia como a la calidad final del agrupamiento. Existen varios métodos para este paso, desde la selección aleatoria hasta enfoques más elaborados como K-means++, que mejora la distribución inicial de los centroides para evitar soluciones subóptimas.
3. **Asignación de observaciones a los clústeres.** En esta fase, cada observación del conjunto de datos se asigna al clúster cuyo centroide esté más próximo, normalmente utilizando la distancia euclidiana como métrica. Esta etapa define la estructura provisional de los grupos y es clave para evaluar la coherencia interna del agrupamiento.
4. **Actualización de los centroides mediante promedios.** Una vez asignados los puntos, se actualiza la posición de cada centroide. Esto se hace calculando la media de todos los puntos asignados a cada grupo. En algunos casos, si el modelo no mejora, se puede realizar una nueva inicialización de los centroides para evitar quedar atrapados en una solución subóptima.
5. **Iteración hasta la convergencia del modelo.** Los pasos de asignación y actualización se repiten sucesivamente hasta que el modelo alcanza la convergencia. Esto sucede cuando las asignaciones ya no cambian significativamente entre iteraciones o cuando se minimiza una métrica interna como la inercia. El proceso se detiene si se alcanza una configuración estable o si se llega al número máximo de iteraciones establecido.



Fases del algoritmo K-means


¿Cómo decidir cuántos grupos formar? Desarrollo de la fase 1: Determinación del número de clústeres (K)

El número de clústeres, representado por la letra K, es una de las decisiones más importantes a la hora de aplicar el algoritmo K-means. Este valor determina cuántos grupos se formarán en los datos y afecta directamente a la estructura del resultado. Una K mal elegida puede generar agrupamientos poco representativos: si es demasiado baja, puede unir datos distintos en un mismo grupo; si es demasiado alta, puede dividir excesivamente patrones que en realidad forman una sola categoría.




Elección del valor K que determina el número de clústeres

- Existen varias estrategias para estimar un valor adecuado de K, y en la práctica es habitual combinarlas para tomar una decisión informada. Una de las más conocidas es el método del codo (*elbow method*). Consiste en aplicar K-means con distintos valores de K y representar gráficamente la inercia —es decir, la suma de las distancias cuadradas entre cada punto y su centroide—. A medida que K aumenta, la inercia disminuye, pero llega un momento en que la mejora se vuelve marginal. Ese punto de inflexión se interpreta como el valor óptimo de K.



Ejemplo de estimación del valor óptimo de K mediante el método del codo

- Otra técnica es el método de la silueta, que evalúa la calidad de los clústeres comparando la distancia media entre puntos de un mismo clúster (cohesión) y la distancia a puntos de otros clústeres (separación). El resultado es un valor entre -1 y 1, y cuanto más alto, mejor está definido el agrupamiento. El valor de K que maximiza la silueta media suele ser una buena elección.



Ejemplo de estimación del número óptimo de clústeres mediante el método Silhouette

- También se pueden aplicar criterios de información, como el AIC (Akaike Information Criterion) o el BIC (Bayesian Information Criterion), que permiten comparar modelos penalizando la complejidad excesiva. Estos métodos son útiles cuando se busca el equilibrio entre ajuste y simplicidad.
- En algunos casos se utiliza la validación interna o externa. Si se dispone de etiquetas reales, se puede evaluar el agrupamiento comparándolo con esa información (validación externa). Si no hay etiquetas, se utilizan métricas estadísticas internas como la cohesión o la silueta.
- Finalmente, el análisis exploratorio de los datos o el conocimiento del dominio también pueden dar pistas. Visualizar los datos en dos dimensiones o conocer los patrones esperables en el contexto puede ayudar a acotar el número de clústeres razonable.

No hay una fórmula exacta para decidir K. La clave es combinar diferentes métodos, evaluar los resultados y, si es necesario, probar varios valores para ver cuál ofrece un agrupamiento más coherente y útil para el análisis.

¿Cómo se eligen los centroides iniciales? Desarrollo de la fase 2: Inicialización estratégica de los centroides

En el algoritmo K-means, los centroides iniciales se seleccionan antes de empezar las iteraciones. Esta elección es fundamental, ya que puede influir en el número de pasos necesarios para llegar a una solución y en la calidad final del agrupamiento. A continuación, se presentan algunas de las estrategias más utilizadas para iniciar el proceso:

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Selección aleatoria.** Es la forma más simple de inicialización. Consiste en elegir K puntos del conjunto de datos al azar. Aunque es fácil de aplicar, puede provocar resultados poco consistentes si los puntos elegidos están mal distribuidos o demasiado próximos entre sí.
- **K-means++.** Este método mejora la selección inicial. Empieza eligiendo un punto aleatorio y después selecciona los siguientes dando más probabilidad a los que están más alejados de los ya elegidos. Así se asegura que los centroides iniciales estén bien repartidos por el espacio de datos, lo que mejora la calidad del agrupamiento y acelera la convergencia.
- **Inicialización basada en clústeres jerárquicos.** Consiste en aplicar un método jerárquico para dividir los datos en grupos y usar los centroides de esos grupos como punto de partida para K-means. Es útil cuando es útil combinar diferentes técnicas de agrupamiento.
- **Inicialización basada en densidad.** Se usan algoritmos como DBSCAN para detectar regiones densas en el conjunto de datos. A partir de ahí, se seleccionan centroides en esas zonas con alta concentración, pensando que son buenos puntos representativos.
- **Selección manual o basada en conocimiento experto.** Cuando se conoce bien el dominio de los datos, puede ser útil fijar manualmente los puntos iniciales. Por ejemplo, si ya se sabe que ciertos valores representan casos típicos o centros esperables, se pueden usar como centroides desde el principio.
- **Inicialización basada en información previa.** En algunos casos, se dispone de información histórica o resultados anteriores. Si se han usado centroides con buenos resultados en otros agrupamientos similares, se pueden reutilizar directamente.

Escoger bien los centroides al principio puede evitar problemas posteriores y hacer que el modelo trabaje de forma más eficiente y precisa.

¿Cómo se asignan los puntos a los clústeres? Desarrollo de la fase 3: Asignación de observaciones a los clústeres

Una vez establecidos los centroides iniciales, el siguiente paso consiste en asignar cada punto del conjunto de datos al clúster que tenga el centroide más cercano. Esta etapa es clave, ya que define la estructura inicial de los grupos sobre los que después se recalcularán los centroides.

La asignación se basa en una métrica de distancia, siendo la más común la **distancia euclidiana**. Esta medida calcula la distancia recta entre dos puntos en el espacio. Cuanto más cerca esté un punto de un centroide, más probable será que pertenezca a ese clúster.

El procedimiento es sencillo:

1. Para cada punto, se calcula su distancia a cada uno de los centroides.
2. Se asigna el punto al clúster del centroide más cercano.
3. Esta asignación se repite para todos los puntos del conjunto de datos.

Este proceso se realiza en cada iteración del algoritmo, ya que los centroides se irán actualizando y, por tanto, las asignaciones también pueden cambiar. El objetivo es que, a medida que los centroides se reubican, las observaciones se agrupen junto con los puntos que presenten mayor similitud dentro del conjunto.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Aunque parezca una operación sencilla, su repetición constante en grandes volúmenes de datos requiere una buena optimización para mantener la eficiencia del modelo.

¿Cómo se actualizan los centroides? Desarrollo de la fase 4: Actualización de los centroides mediante promedios

Después de asignar cada punto al centroide más cercano, el siguiente paso consiste en recalcular la posición de cada centroide. Esta actualización se basa en la media de los puntos que pertenecen a su clúster. Es decir, el nuevo centroide se coloca en el centro geométrico de todas las observaciones asignadas a ese grupo.

El procedimiento es el siguiente:

1. Para cada clúster, se identifican todos los puntos que han sido asignados a él en la iteración actual.
2. Se calcula la media de las coordenadas de esos puntos.
3. Esa media define la nueva posición del centroide.

Este proceso garantiza que cada centroide se desplace hacia el centro real del grupo de datos que representa, ajustando su ubicación para reflejar mejor la distribución interna del clúster. A medida que los centroides se reubican, también cambian las asignaciones, por lo que esta operación se repite en varias iteraciones.

La actualización por media es especialmente adecuada cuando los datos son numéricos y los clústeres tienen forma aproximadamente esférica. Si los grupos son muy irregulares o los datos no son numéricos, este cálculo puede no reflejar bien la estructura real del conjunto.

Este paso se repite junto con la asignación de puntos hasta que el modelo se estabiliza, es decir, hasta que los centroides dejan de moverse significativamente.

¿Cuándo termina el algoritmo? Desarrollo de la fase 5: Iteración hasta la convergencia del modelo

El algoritmo K-means se basa en un proceso iterativo en el que, en cada paso, se asignan los puntos a los centroides más cercanos y luego se recalculan esos centroides según los puntos asignados. Este ciclo de asignación (fase 3) y actualización (fase 4) se repite con el objetivo de ajustar progresivamente la posición de los centroides para que representen lo mejor posible a cada grupo de datos.

Este proceso continúa hasta alcanzar una situación estable en la que las asignaciones ya no cambian de forma significativa. A este estado se le llama **convergencia del modelo**, y significa que el algoritmo ha encontrado una estructura coherente de agrupamiento: los centroides se mantienen prácticamente en la misma posición y los puntos asignados a cada grupo ya no varían.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



Durante todo el proceso, una métrica clave para evaluar la calidad del modelo es la **inercia**, que mide lo compactos que están los puntos dentro de cada clúster. Cuanto menor sea esta medida, más cerca estarán los puntos de su centroide y, por tanto, mejor definido estará el agrupamiento. K-means busca precisamente minimizar esta inercia a lo largo de las iteraciones. Cuando los cambios en la inercia dejan de ser significativos o se alcanza el número máximo de iteraciones definido, el algoritmo se detiene y se considera que ha finalizado correctamente.

Hiperparámetros del algoritmo K-means

En Python, el algoritmo K-means incluye varios **hiperparámetros** que permiten ajustar su comportamiento para mejorar la calidad del agrupamiento y la estabilidad de los resultados. Estos parámetros pueden configurarse fácilmente al utilizar la implementación de [scikit-learn](#).


A continuación se detallan los más relevantes:

- **n_clusters:** Es el número de clústeres que se desea encontrar. Representa el valor de K en el algoritmo.
- **init:** Define el método de inicialización de los centroides. Las opciones más comunes son `'k-means++'`, que mejora la distribución inicial, `'random'`, que selecciona centroides al azar, y `'lloyd'`, que es una implementación más reciente y optimizada. También se puede proporcionar manualmente un conjunto de centroides iniciales.
- **n_init:** Indica cuántas veces se ejecutará el algoritmo con diferentes inicializaciones. De todas las ejecuciones, se selecciona la que tenga la menor inercia. Cuanto mayor sea este valor, más probabilidades habrá de obtener un buen resultado.
- **max_iter:** Es el número máximo de iteraciones permitidas en cada ejecución del algoritmo. Sirve para evitar bucles largos si el modelo tarda en converger.
- **tol:** Es el valor de tolerancia utilizado como criterio de parada. Si el cambio en la posición de los centroides entre iteraciones es menor que este umbral, el algoritmo se considera convergente y se detiene.

¿Qué es el agrupamiento jerárquico y cómo funciona?

El agrupamiento jerárquico (*Hierarchical Clustering*) es una técnica que permite clasificar los datos en grupos o clústeres en función de su similitud. Organiza las observaciones en una estructura con forma de árbol, donde cada nivel representa una posible agrupación. Este tipo de representación facilita entender las relaciones entre los elementos del conjunto de datos y explorar diferentes niveles de agrupación según el detalle que se necesite.


Los puntos individuales se agrupan paso a paso en función de su proximidad. La estructura que se forma, conocida como **dendrograma**, representa gráficamente cómo se van uniendo los elementos y permite decidir fácilmente cuántos grupos formar, simplemente cortando el árbol a la altura deseada.



Funcionamiento del agrupamiento jerárquico

Una de las ventajas principales de este tipo de agrupamiento es que permite analizar los datos a distintos niveles de granularidad. Es posible observar tanto una visión general como detalles más específicos, lo que facilita la identificación de patrones, la comprensión de la estructura interna de los datos y la detección de relaciones ocultas.

Además, este tipo de análisis permite detectar **valores atípicos** o puntos que no encajan claramente en ningún grupo. Estos elementos suelen quedar aislados o separados en ramas concretas del dendrograma, lo que facilita su identificación como posibles outliers.



Detección de valores atípicos


Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Tipos de enfoque: aglomerativo y divisivo

El agrupamiento jerárquico se puede aplicar de dos maneras distintas, según el enfoque que se utilice: aglomerativo o divisivo. Ambos construyen la estructura jerárquica, pero lo hacen en direcciones opuestas.

- El **enfoque aglomerativo** (también conocido como *bottom-up*) es el más común. Parte de la idea de que cada observación comienza formando su propio clúster. A partir de ahí, se van uniendo los grupos más similares en cada paso, hasta que todos los elementos quedan unidos en una única agrupación. Este proceso va construyendo la jerarquía desde abajo hacia arriba y se puede visualizar fácilmente en un dendrograma. El algoritmo AGNES (Agglomerative Nesting) es un ejemplo típico de este enfoque.
- Por otro lado, el **enfoque divisivo** (*top-down*) comienza con un único grupo que contiene todos los datos. En cada paso, este gran clúster se va dividiendo en grupos más pequeños, hasta que cada observación queda aislada o se alcanza un número determinado de clústeres. Este método sigue el proceso contrario al aglomerativo y es menos habitual, pero útil en ciertos contextos. El algoritmo DIANA (Divisive Analysis) es un ejemplo representativo de este enfoque.



Diferencia entre el método aglomerativo y el divisivo

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Ambos métodos permiten construir la misma estructura jerárquica, pero con estrategias distintas. La elección entre uno u otro dependerá del tipo de problema, del tamaño del conjunto de datos y de las necesidades específicas del análisis.

Características principales del agrupamiento jerárquico

El agrupamiento jerárquico tiene un conjunto de propiedades que lo hacen especialmente útil en tareas exploratorias. Algunas de estas características aportan ventajas claras respecto a otros métodos, mientras que otras suponen limitaciones que deben tenerse en cuenta según el tipo de datos o el objetivo del análisis.

- **No necesita definir el número de clústeres al inicio.** A diferencia de otros algoritmos como K-means, permite construir toda la estructura jerárquica sin especificar previamente cuántos grupos se desean. Esto permite decidir el número de clústeres más adelante, una vez se ha visualizado la distribución real de los datos.
- **Permite distintos niveles de análisis.** Gracias al formato jerárquico, se puede observar el agrupamiento a diferentes profundidades. Es posible hacer un análisis general o explorar detalles más finos ajustando el nivel de corte del dendrograma.
- **Facilita la detección de dependencias internas.** El modelo permite identificar relaciones entre grupos y subgrupos, cosa que ayuda a entender mejor la organización natural de los datos y a detectar estructuras anidadas.
- **Ofrece visualización clara mediante el dendrograma.** La estructura que se genera es fácil de interpretar gráficamente, especialmente en conjuntos pequeños o medianos. El dendrograma permite identificar grupos compactos, posibles errores o valores atípicos que quedan separados.
- **Tiene limitaciones con conjuntos de datos grandes.** El coste computacional crece rápidamente, ya que es necesario calcular y almacenar todas las distancias entre pares de datos. Esto lo hace menos práctico con volúmenes muy altos.
- **No se puede actualizar de forma incremental.** Una vez construido, el modelo no admite incorporar nuevos datos sin repetir todo el proceso. No es apto para contextos donde los datos se actualizan de forma continua.
- **Las decisiones tempranas no se corrigen.** Cada fusión o división que se produce es irreversible. Si se toman malas decisiones en los primeros pasos, estas afectarán directamente al resultado final.
- **Es sensible a la distancia y al método de enlace usados.** Diferentes configuraciones pueden generar dendrogramas muy distintos. Es recomendable probar varias combinaciones y validar con métricas de calidad para asegurar un buen agrupamiento.

Método aglomerativo (Bottom-up)

El agrupamiento aglomerativo, también llamado *bottom-up*, es el enfoque jerárquico más utilizado. Este método parte de que cada observación constituye inicialmente su propio clúster. A medida que avanza el algoritmo, los clústeres más cercanos se van fusionando sucesivamente, hasta que se forma una única agrupación que contiene todos los datos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Una ventaja de este método es que permite trabajar con grandes volúmenes de datos, especialmente si se usa junto con una **matriz de conectividad**. Esta matriz define qué puntos son vecinos según una estructura previa, y actúa como restricción: solo pueden fusionarse entre sí los clústeres que estén conectados. Si no se imponen estas restricciones, el algoritmo debe considerar todas las combinaciones posibles en cada paso, lo cual puede resultar muy costoso a nivel computacional.

El uso de restricciones de conectividad es especialmente útil cuando se trabaja con datos estructurados espacial o secuencialmente. Por ejemplo, se pueden limitar las fusiones a observaciones adyacentes en una rejilla, en una imagen o en una serie temporal, mejorando la coherencia de los agrupamientos.

Criterio de similitud entre clústeres

En el agrupamiento jerárquico aglomerativo, la forma en que se decide qué clústeres deben unirse en cada paso depende de cómo se mida la similitud entre ellos. Esta similitud se calcula a partir de la distancia entre los elementos de cada grupo, pero el modo concreto de hacerlo puede variar según el método que se elija.

A esta forma de calcular la distancia entre clústeres se le conoce como criterio de enlace o método de vinculación. La elección de este criterio es importante, ya que determina cómo evoluciona el agrupamiento y qué estructura final tendrá el dendrograma. Según el criterio usado, se priorizarán uniones más compactas, más dispersas o con menor variación interna.

Métodos de enlace (linkage)

Durante el agrupamiento jerárquico, el algoritmo necesita decidir en cada paso qué clústeres se deben unir. Para tomar esta decisión, utiliza lo que se conoce como método de enlace, que es una forma de calcular la distancia o la similitud entre dos clústeres.

Cada método de enlace tiene su propia lógica, y según el que se utilice, se formarán agrupaciones con formas y tamaños distintos.

- **Enlace completo.** La distancia entre dos clústeres se define como la mayor distancia entre cualquier par de puntos, uno de cada clúster. Esto provoca que los grupos resultantes sean más compactos y estén bien separados entre sí. Es útil cuando se quiere evitar que dos clústeres se unan por un único punto cercano.
- **Enlace simple.** La distancia se calcula como la menor distancia entre dos puntos, uno de cada clúster. Es decir, si hay al menos un punto cercano entre los dos grupos, se pueden unir. Este método puede generar clústeres alargados o en forma de cadena, ya que solo necesita un punto de conexión.
- **Enlace medio.** Calcula la distancia media entre todos los puntos de un clúster y los del otro. Tiene un comportamiento intermedio entre el enlace simple y el completo, y suele producir agrupaciones más equilibradas.
- **Método de Ward.** En lugar de mirar distancias entre puntos, este método se basa en minimizar el aumento de la variación interna cuando se unen dos clústeres. Busca que cada fusión provoque el menor cambio posible dentro del nuevo grupo, lo que da como resultado clústeres de tamaño y forma parecidos.

Es importante tener en cuenta cómo influye el método de enlace en el tamaño y forma de los clústeres. Algunos algoritmos presentan un comportamiento conocido como *rich get richer*, en el que los clústeres grandes tienden a seguir creciendo más que los pequeños. Esto puede dar lugar a agrupaciones muy desequilibradas.

El enlace completo tiende a favorecer este efecto, permitiendo que los clústeres grandes absorban a los pequeños. El resultado son grupos alargados o de tamaño muy desigual, lo que puede dificultar la interpretación.

Por el contrario, el método de Ward genera agrupaciones más regulares. Al minimizar la variación interna en cada fusión, los clústeres tienden a tener tamaños más parecidos y formas más homogéneas. Esto hace que sea una opción recomendable en muchos casos.

Sin embargo, Ward tiene una limitación importante: no es adecuado cuando se trabaja en espacios no euclídeos o con métricas distintas a la distancia euclidiana. En estas situaciones, el enlace medio es una alternativa útil, ya que funciona mejor con otros tipos de distancias.

Restricciones de conectividad

En el agrupamiento jerárquico aglomerativo, es posible añadir restricciones que limitan qué clústeres pueden fusionarse. Estas restricciones de conectividad ayudan a conservar cierta estructura o coherencia entre los datos, ya que solo permiten unir elementos que cumplan condiciones específicas, como proximidad espacial, relación temporal o vínculos conocidos.

Aplicar restricciones puede ser útil cuando se quiere que los grupos resultantes tengan un significado concreto o cuando se trabaja con datos estructurados, como mapas, series temporales o redes. Por ejemplo, si se agrupan personas en una red social, se podría establecer que solo se unan si son amigas y comparten intereses similares. Esto impide fusiones poco coherentes desde el punto de vista del contexto.

Existen diferentes formas de aplicar estas restricciones:

- **Restricciones espaciales.** Se utilizan para evitar que se fusionen clústeres que no están próximos en el espacio. Son útiles en análisis geográficos o en imágenes, donde solo deberían unirse zonas contiguas.
- **Restricciones temporales.** Limitan la fusión de clústeres a los que ocurren en un mismo intervalo de tiempo o en una secuencia determinada. Son habituales en análisis de series temporales.
- **Restricciones basadas en redes.** Se aplican en contextos donde los datos están conectados entre sí, como en grafos o xarxes socials. Solo se permite la fusión si existe alguna relación directa entre los elementos de los clústeres.
- **Restricciones de contigüidad.** Exigen que los elementos agrupados mantengan continuidad estructural. Es decir, que los clústeres no queden divididos o desconectats de forma artificial. Això és especialment rellevant en mapes o en dades físiques amb una estructura lògica.
- **Restricciones personalizadas.** Se pueden definir reglas específicas según el objetivo del análisis. Por ejemplo, limitar la unión de clústeres basándose en características concretas del conjunt de dades o en coneixement previ del domini.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Aplicar este tipo de restricciones no solo permite obtener clústeres más coherentes, sino que también mejora la eficiencia del algoritmo. Al limitar las posibles fusiones, el proceso de agrupamiento se vuelve más rápido, especialmente cuando se trabaja con grandes volúmenes de datos.


Estas restricciones se gestionan mediante una matriz de conectividad, que indica qué puntos pueden conectarse. Esta matriz suele ser muy dispersa, es decir, tiene la mayoría de valores en cero, ya que solo se indican las conexiones relevantes. Por eso, se almacena de forma optimizada, guardando únicamente las posiciones donde hay conexiones reales.

En las figuras comparativas puede observarse que, al activar la conectividad, los clústeres resultantes no son necesariamente más compactos ni equilibrados. De hecho, en este caso concreto, los agrupamientos sin restricciones de conectividad muestran una estructura más clara, especialmente al usar métodos de enlace como el simple, el medio o el completo.


Aunque en teoría imponer una conectividad debería ayudar a reflejar mejor la estructura local de los datos, en este ejemplo concreto se observa el efecto contrario. Al activar la conectividad, los agrupamientos tienden a ser más irregulares y los clústeres crecen de forma menos controlada.

Esto se debe a que, al utilizar una matriz de conectividad muy dispersa (como en este caso, basada en los 20 vecinos más próximos), los métodos de enlace como el medio o el completo pierden parte de su estabilidad. La conectividad rompe su forma habitual de calcular distancias entre clústeres y provoca un comportamiento más parecido al del enlace simple, que es más sensible y tiende a formar estructuras alargadas o inestables.

Por tanto, aunque el uso de conectividad puede mejorar el tiempo de ejecución, no siempre garantiza una mejor organización visual o estructural de los grupos, especialmente si la estructura de vecinos no está bien ajustada al tipo de datos.



Clústeres con la conectividad no activada



Clústeres con la conectividad activada

Las restricciones de conectividad y los métodos de enlace pueden combinarse de diferentes maneras según el objetivo del análisis.

En algunos casos, las restricciones se aplican antes de empezar el proceso de enlace. Así se reduce el número de posibles fusiones desde el principio, lo que garantiza que solo se consideren combinaciones aceptables.

En otras situaciones, restricciones y método de enlace se aplican a la vez, integrándose en cada paso del proceso. Aquí, el algoritmo decide las fusiones teniendo en cuenta tanto la distancia entre clústeres como las reglas de conectividad.

También existe la posibilidad, menos común, de aplicar restricciones una vez ya se ha hecho el agrupamiento. Això permetria ajustar els grups resultants separant aquells que no compleixen amb les condicions desitjades de connexió.

Combinación entre restricciones de conectividad y métodos de enlace

Las restricciones de conectividad y los métodos de enlace se pueden utilizar de forma complementaria en el análisis de clústeres. Sin embargo, el momento en que se aplican puede variar según la estrategia del análisis y los objetivos que se persigan.

- En algunos casos, las restricciones de conectividad se aplican antes de comenzar el proceso de enlace. Esto significa que el conjunto de fusiones posibles ya está limitado desde el principio, evitando combinaciones que no cumplen con los criterios de conexión establecidos. Esta opción es útil cuando se desea controlar estrictamente la estructura del agrupamiento.
- En otros escenarios, las restricciones de conectividad y los métodos de enlace se integran y se aplican al mismo tiempo. En cada paso de fusión, el algoritmo tiene en cuenta tanto la distancia entre clústeres como las restricciones impuestas, lo que permite un equilibrio entre proximidad y estructura.
- También existe la posibilidad, menos frecuente, de aplicar las restricciones después de haber ejecutado el agrupamiento. Esta estrategia se puede usar para revisar los clústeres

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)




resultantes y separar aquellos que no cumplen con los criterios deseados de conectividad, ajustando así el modelo final.

El dendrograma como representación visual del agrupamiento

Una de las principales herramientas para interpretar el resultado del agrupamiento jerárquico es el dendrograma. Este gráfico en forma de árbol permite visualizar cómo se han ido uniendo los clústeres a lo largo del proceso.

En el eje horizontal se representan los elementos individuales del conjunto de datos, mientras que el eje vertical indica la distancia o similitud en el momento en que se fusionaron. Las líneas que conectan los grupos muestran el orden en que se produjeron las fusiones. Cuanto más alta es la unión en el gráfico, mayor era la distancia entre los clústeres en el momento de combinarse.



Este dendrograma se ha generado aplicando una partición final en 4 clústeres, correspondiente a un nivel de similitud de aproximadamente 40. El primer grupo, situado en el extremo izquierdo, está formado por 7 observaciones (las filas 1, 3, 6, 9, 10, 11 y 15). El segundo grupo, justo a su derecha, incluye 3 observaciones (las filas 4, 12 y 19). El tercer clúster agrupa 7 observaciones (las filas 2, 14, 17, 20, 18, 5 y 8). Finalmente, el cuarto grupo, a la derecha del todo, está compuesto por 3 observaciones (las filas 7, 13 y 16).

Si se cortara el dendrograma a una altura mayor, se obtendrían menos clústeres finales, aunque con un nivel de similitud más bajo entre los elementos agrupados. En cambio, si el corte se realizara a un nivel más bajo del gráfico, se formarían más clústeres, pero la similitud dentro de cada grupo sería mayor.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)




Decisión del número de clústeres finales

En el agrupamiento jerárquico, el número de clústeres finales suele decidirse cortando el dendrograma en un punto determinado. Este corte se elige según los objetivos del análisis y la estructura de los datos, y puede hacerse de forma visual o utilizando métodos automáticos como el método del codo o el índice de silueta, entre otros.

A través de la visualización del dendrograma, se puede identificar el lugar ideal donde cortar buscando el tramo vertical más largo que no haya sido atravesado por ninguna línea horizontal extendida. Aquí, "extendida" significa que las líneas horizontales del gráfico (las que conectan clústeres) se alargan visualmente a ambos lados.

Una vez localizado ese segmento vertical, se traza una línea horizontal imaginaria a su altura. El número de líneas verticales que cruza esa línea imaginaria suele indicar el número óptimo de clústeres que se pueden formar.



Detección del número de clústeres a través del dendrograma

Hiperparámetros del algoritmo Aglomerativo

El algoritmo de agrupamiento aglomerativo en scikit-learn permite ajustar varios hiperparámetros que influyen en el comportamiento y los resultados del modelo. A continuación se describen los más importantes:

- **n_clusters:** Define el número de clústeres que se quieren obtener. Aunque no es obligatorio en este tipo de agrupamiento, se puede usar para indicar directamente cuántos grupos finales se desean. Valor esperado: número entero positivo.
- **linkage:** Especifica el método de enlace que se utilizará para medir la distancia entre clústeres. Valores posibles: 'ward', 'complete', 'average', 'single'.
- **distance_threshold:** Permite establecer una distancia máxima para decidir cuándo dejar de fusionar clústeres. Por ejemplo, si se fija en 10, solo se agruparán elementos que estén a

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



una distancia menor o igual a 10 unidades. Este parámetro es opcional y su valor por defecto es None.


- **compute_full_tree:** Controla si se debe construir todo el árbol jerárquico durante el ajuste. Valores posibles:
 - 'auto' (por defecto), calcula todo el árbol solo si es necesario según el tamaño del conjunto
 - True, fuerza la construcción completa del árbol, con más detalle pero más coste de memoria y tiempo
 - False, construye solo una parte del árbol para optimizar rendimiento, aunque se pierde información estructural
- **connectivity:** Permite definir una estructura de conectividad entre los datos. Aquí es donde se puede pasar una matriz que imponga restricciones sobre qué puntos pueden estar conectados y, por tanto, fusionarse.
- **compute_distances:** Indica si se deben calcular y guardar las distancias entre clústeres durante el agrupamiento. Valores posibles: True (por defecto) o False.

Lección 3. Agrupación basada en densidad: detección de formas y estructuras complejas

¿Qué es el agrupamiento por densidad y cómo funciona?

El agrupamiento por densidad es una técnica que identifica regiones con alta concentración de datos y agrupa los puntos que pertenecen a esas zonas. En lugar de basarse en la distancia global entre elementos, como hacen otros métodos, este enfoque busca agrupaciones naturales en el espacio según la densidad local de los datos.

Uno de los algoritmos más conocidos que sigue esta lógica es DBSCAN (Density-Based Spatial Clustering of Applications with Noise). A diferencia de K-means, DBSCAN no requiere conocer de antemano cuántos clústeres se quieren formar, y puede detectar grupos con formas complejas, no necesariamente circulares ni regulares.



Formación de clústeres por DBSCAN

Tipos de puntos del algoritmo DBSCAN

El funcionamiento se basa en encontrar zonas del espacio donde haya suficiente concentración de puntos. Estas zonas densas se consideran clústeres, mientras que los puntos aislados, que no pertenecen a ninguna región densa, se clasifican como ruido o excepciones.


Para clasificar los datos, DBSCAN distingue tres tipos de puntos:

- **Puntos núcleo.** Son aquellos que tienen un número mínimo de vecinos en su entorno más próximo. Es decir, hay suficientes puntos alrededor como para considerarlos parte de una zona densa.
- **Puntos frontera.** No tienen suficientes vecinos para ser núcleo, pero están dentro del área de influencia de un punto núcleo. Se consideran parte del clúster, aunque no contribuyen a expandirlo.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **Puntos ruido.** No cumplen ninguna de las condiciones anteriores. Están demasiado alejados del resto y se consideran fuera de cualquier agrupación.



Tipos de puntos

Funcionamiento del algoritmo DBSCAN

El algoritmo DBSCAN forma clústeres a partir de regiones densas del espacio de datos. A continuación, se resumen sus fases principales de forma ordenada:

1. **Definición de los hiperparámetros:** Antes de comenzar, se establecen dos valores clave: **eps** (radio de vecindad) y **min_samples** (número mínimo de puntos en ese radio para considerar una zona como densa). Estos valores suelen determinarse mediante análisis visual, como el gráfico de k-distancias.
2. **Inicio del procesamiento:** El algoritmo selecciona un punto cualquiera del conjunto. Si ese punto tiene suficientes vecinos dentro del radio **eps**, se considera un punto núcleo y se empieza a formar un clúster. Si no cumple la condición, se marca como ruido y se pasa al siguiente punto.
3. **Expansión del clúster:** Los vecinos del punto núcleo se van incorporando al clúster. Si alguno de ellos también cumple la condición de ser núcleo, se amplía aún más el clúster buscando sus propios vecinos. Este proceso continúa hasta que ya no se pueden añadir más puntos.
4. **Exploración de nuevos clústeres:** Una vez finalizada la expansión del clúster actual, se elige un nuevo punto sin visitar y se repite el proceso. Así, se van creando otros clústeres o identificando más puntos de ruido.
5. **Finalización:** El algoritmo termina cuando ha revisado todos los puntos del conjunto de datos. Cada punto habrá sido asignado a un clúster o marcado como ruido.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



Puntos fuertes y limitaciones del algoritmo DBSCAN

El algoritmo DBSCAN presenta una serie de ventajas que lo hacen especialmente útil en tareas exploratorias, sobre todo cuando se trabaja con datos que no siguen una estructura regular. Sin embargo, también tiene limitaciones que conviene conocer para saber cuándo es o no una buena opción.

Entre sus principales puntos fuertes destaca que no requiere indicar el número de clústeres con antelación, lo que lo hace muy útil cuando no se tiene una idea clara de cuántos grupos hay en los datos. Además, puede detectar clústeres con formas arbitrarias, no necesariamente redondas o simétricas, y es robusto frente al ruido, ya que los puntos aislados se clasifican como tales. Tampoco necesita ninguna inicialización de centroides ni hace suposiciones sobre la forma geométrica de los grupos, lo que le da una gran flexibilidad frente a otros algoritmos más rígidos.

Entre sus limitaciones más relevantes, cabe destacar que es muy sensible a los hiperparámetros `eps` y `min_samples`. Una mala elección puede dar lugar a resultados poco representativos. También puede resultar menos eficiente en conjuntos de datos muy grandes o en espacios con muchas dimensiones, donde la noción de cercanía pierde fuerza y afecta a su capacidad para detectar agrupaciones. Además, no siempre identifica bien los outliers si están cerca de zonas densas, y la distancia euclidiana que utiliza por defecto puede no ser adecuada para ciertos tipos de datos como los categóricos o textuales. Por último, el escalado de los atributos influye mucho en los resultados, por lo que es imprescindible preparar correctamente los datos antes de aplicar el algoritmo.

DBSCAN frente a clústeres con densidades variables

Aunque DBSCAN puede detectar clústeres con formas arbitrarias, su rendimiento se ve afectado cuando las densidades entre grupos son muy distintas. Esto se debe a que los hiperparámetros `eps` y `min_samples` se aplican globalmente, y un valor que funciona bien para una zona del espacio puede no ser adecuado para otra. Si un clúster tiene muchos puntos muy juntos y otro está más disperso, DBSCAN puede fallar en detectar correctamente alguno de ellos.

Para mejorar los resultados en este tipo de situaciones, es fundamental realizar una exploración detallada de los hiperparámetros, ajustándolos con cuidado en función de la estructura de los datos. Aun así, cuando las diferencias de densidad son demasiado extremas, puede ser recomendable optar por otras técnicas más adaptables.

Algunas alternativas diseñadas específicamente para manejar clústeres con densidades variables son:

- **HDBSCAN.** Extensión jerárquica de DBSCAN que permite identificar clústeres de distinta densidad de forma más robusta. Ofrece una visión jerárquica y permite trabajar con diferentes niveles de agrupamiento.
- **OPTICS.** Algoritmo que ordena los puntos para identificar estructuras de agrupamiento sin requerir un valor fijo de `eps`. Es especialmente útil cuando la densidad varía mucho entre zonas.
- **Mean Shift.** Método no paramétrico que se adapta de forma automática a la distribución de los datos. No necesita definir cuántos clústeres se esperan y detecta estructuras complejas.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/)



- **AHC (Agglomerative Hierarchical Clustering).** Al no depender de parámetros de densidad ni de formas concretas, puede resultar útil para analizar estructuras con densidades variadas a distintos niveles.
- **BIRCH.** Optimizado para grandes volúmenes de datos, utiliza estructuras de árbol para agrupar datos de forma eficaz, incluso cuando hay clústeres con tamaños y densidades dispares.
- **GMM (Modelos de mezcla de gaussianas).** Permite modelar los datos como una combinación de distribuciones gaussianas, siendo flexible ante diferentes concentraciones de puntos.
- **Fuzzy C-Means.** Versión suavizada de K-means que permite pertenencia parcial de un punto a varios clústeres. Útil cuando no hay límites claros entre grupos.
- **DENCLUE.** Utiliza funciones de densidad para modelar la distribución de los datos. Es eficaz para detectar formas complejas y densidades variadas.

Antes de elegir un método de agrupamiento, es fundamental analizar bien las características del conjunto de datos. En muchos casos, combinar diferentes enfoques o probar distintas técnicas puede ayudar a entender mejor la estructura interna y mejorar la calidad del agrupamiento final.

Comparativa con K-means y agrupamiento jerárquico

Aunque los tres algoritmos permiten agrupar datos, cada uno utiliza una lógica diferente para formar los clústeres. **K-means** asigna los puntos al centroide más cercano y ajusta esos centros en cada iteración. El **agrupamiento jerárquico** calcula las similitudes entre puntos y construye una estructura en forma de árbol. Por su parte, **DBSCAN** busca zonas densas y considera clúster a cualquier región donde la concentración de puntos sea suficiente.

En cuanto al **número de clústeres**, K-means requiere definirlo antes de aplicar el modelo. El método jerárquico ofrece flexibilidad, ya que se puede elegir el número de grupos según el nivel de corte en el dendrograma. En cambio, DBSCAN no necesita especificar cuántos clústeres debe encontrar, lo que resulta útil cuando no se tiene una idea clara del número de agrupaciones.

Respecto al **ruido o valores atípicos**, K-means es bastante sensible y puede verse afectado por puntos extremos. El método jerárquico, según el tipo de enlace utilizado, puede manejar mejor este problema. DBSCAN, en cambio, es especialmente eficaz en este aspecto, ya que considera los puntos aislados como ruido desde el principio.

Desde el punto de vista de la **visualización**, K-means es sencillo de interpretar, especialmente en 2D o 3D, ya que cada punto queda asignado a un centroide concreto. El agrupamiento jerárquico se representa mediante un dendrograma, que facilita mucho la comprensión de la estructura interna. DBSCAN también ofrece resultados visualmente claros, con clústeres formados por zonas de alta densidad.

La **selección de hiperparámetros** también es diferente en cada caso. K-means necesita definir el valor de K. El método jerárquico depende del tipo de enlace y del punto donde se corta el dendrograma. DBSCAN requiere ajustar cuidadosamente los valores de **eps** y **min_samples**, ya que estos controlan cómo se detecta la densidad.

En cuanto a la **eficiencia computacional**, K-means puede ser muy rápido si el número de clústeres no es alto. El agrupamiento jerárquico suele ser más costoso en términos de tiempo y memoria,

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](https://creativecommons.org/licenses/by-nc-sa/3.0/es/)



especialmente con muchos puntos. DBSCAN puede ser eficiente, sobre todo en datos con ruido, y presenta una complejidad temporal casi lineal respecto al número de observaciones, lo que lo hace muy útil en muchos contextos prácticos.

Elección de los hiperparámetros eps y min_samples

DBSCAN se basa en dos hiperparámetros principales que determinan cómo se forman los clústeres y cómo se detectan los puntos atípicos. La elección de estos valores influye directamente en la calidad del agrupamiento.

- **eps (epsilon):** Es el radio que define la distancia máxima entre dos puntos para que puedan considerarse vecinos. Todos los puntos que estén dentro de esta distancia desde un punto dado se consideran parte de su vecindad. Si la zona tiene suficiente densidad de puntos, se convierte en un clúster.
- **min_samples:** Indica el número mínimo de puntos que debe haber dentro del radio eps para que se considere que existe una región densa. Si un punto no tiene suficientes vecinos dentro de ese radio, se considera ruido o outlier, y no se asigna a ningún grupo.

Cómo ajustar eps y min_samples con el análisis de k-distancias


Para configurar correctamente el algoritmo DBSCAN, es clave ajustar los valores de [eps](#) y [min_samples](#). Una forma práctica de estimar [eps](#) es mediante el análisis de k-distancias, que ayuda a detectar el punto en el que empieza a bajar la densidad de datos.

El procedimiento consiste en:

1. Calcular la distancia al k-ésimo vecino más cercano para cada punto del conjunto. Por ejemplo, si $k=4$, se toma la distancia al cuarto punto más próximo.
2. Ordenar todas estas distancias de menor a mayor.
3. Representar los valores en una gráfica, donde el eje x muestra el número de puntos ordenados y el eje y la distancia calculada.
4. Buscar el punto de inflexión, es decir, donde la curva empieza a subir bruscamente. Ese cambio indica el límite entre zonas densas y zonas más dispersas.
5. Seleccionar el valor de [eps](#) justo en ese cambio de pendiente. Este será el valor que separa mejor las agrupaciones del ruido.
6. En cuanto a [min_samples](#), se suele fijar igual que el valor de k. Así se asegura que un punto solo se considere núcleo si realmente está rodeado por suficientes vecinos. Si se elige un valor demasiado bajo, se incluirán puntos poco representativos; si es demasiado alto, se podrían perder clústeres válidos.

Este trabajo está licenciado bajo la [Licencia Creative Commons Reconocimiento - No Comercial - Compartir Igual 3.0 España \(CC BY-NC-SA 3.0\)](#)





Análisis gráfico de las distancias al 5º vecino más cercano